Predicción espacial de accidentes de tránsito en la Zona Metropolitana de Monterrey

Angel Eduardo Luna[a]

[a]Tecnológico de Monterrey, Monterrey, Nuevo León, México

INFORMACIÓN

Palabras clave:
accidentes de tránsito
geoestadística
modelo jerárquico bayesiano
CAR
Monterrey

RESUMEN

1. Introducción
2. Datos
2.1. Fuente y recorte a la ZMM
2.2. Calidad y propiedades de la base
2.3. Selección de variables
3. Metodología

La metodología es una escalera: cada peldaño se diseñó para contestar una pregunta que el anterior dejó abierta, y la especificación del modelo final salió de los diagnósticos de los modelos más simples, no de una elección previa. El análisis exploratorio (§3.2) decide si hay estructura espacial que modelar y si persiste en el tiempo; los modelos de conteo frecuentistas (§3.3) deciden la verosimilitud y dónde vive el error; el modelo jerárquico (§3.4) convierte ese diagnóstico en estructura. Todos comparten la misma partición del territorio (§3.1) y el mismo protocolo de validación (§3.5). Cada peldaño corresponde a un *notebook* del repositorio: `analisis_espacial`, `modelo_conteo` y `modelo_jerarquico`.

3.1. Unidad espacial

Proyección. Las coordenadas del INEGI vienen en WGS 84, en grados. A la latitud de Monterrey un grado de longitud mide ∼100 km y uno de latitud ∼111 km, de modo que una distancia en grados no es una distancia. Antes de cualquier cálculo de áreas, vecindades o rejillas los puntos se proyectan a UTM zona 14 Norte (EPSG:32614), cuya franja ($-102°$ a $-96°$) contiene toda la ZMM.

Por qué no el AGEB. La unidad propuesta inicialmente fue el AGEB urbano. Se descartó como unidad de análisis por tres razones. Primera, sus límites se trazan con frecuencia sobre vialidades principales, que es justamente donde se concentran los accidentes: un choque sobre una avenida cae en la frontera entre dos polígonos y su asignación es arbitraria. Es el problema de la unidad de área modificable (MAUP) [Openshaw(1984)] en una forma que afecta directamente la asignación de los accidentes viales. Segunda, el área de los AGEB es heterogénea, y comparar conteos exigiría un denominador de superficie o de exposición. Tercera, en polígonos irregulares el número de vecinos varía considerablemente, y la matriz de pesos espaciales hereda esa irregularidad. Tampoco se trabajó directamente sobre los puntos: como se documentó en §2.2, ATUS geocodifica la intersección reportada y no el sitio físico del choque, así que el dato es un conteo sobre nodos de la red y no un patrón de puntos continuo en el plano.

La rejilla. Los accidentes se agregan a una rejilla regular de hexágonos con orientación de vértice lateral (*flat-top*) y lado $\ell = 500\,\text{m}$, con un área por celda de $\frac{3\sqrt{3}}{2}\ell^2 \approx 0.65\,\text{km}^2$, comparable a un AGEB urbano. El hexágono tiene tres propiedades que el AGEB no tiene: área constante (el conteo *es* la densidad), ausencia de sesgo de frontera (la rejilla no sabe dónde están las calles) y una vecindad sin ambigüedad (seis vecinos que comparten arista, sin la distinción entre vecindad por arista y por vértice de la malla cuadrada) [Birch et al.(2007)Birch, Oom and Beecham]. La contraparte es que el hexágono no trae covariables censales. Esas tendrán que interpolarse desde el marco geoestadístico cuando se incorporen.

Cada accidente se asigna a la celda que lo contiene. Se conservan solo las celdas con al menos un accidente en los seis años: en 379,294 registros, una celda vacía no tiene red vial donde pueda ocurrir uno (es un cerro, una presa o un baldío), y tratarla como riesgo cero inflaría artificialmente los agrupamientos de valores bajos. Se retiran además las celdas *isla*, cuyas seis vecinas no tienen ningún accidente. No tienen con quién correlacionarse, y cualquier estadístico local sobre ellas degenera. El resultado son **2,241 celdas**. A cada celda se le asigna el municipio modal entre sus accidentes; esa es la pertenencia que usa el nivel municipal del modelo jerárquico.

Vecindad. Dos celdas son vecinas si comparten arista. Para los estadísticos exploratorios la matriz de pesos W se estandariza por fila ($w_{ik} = 1/|\mathcal{N}_i|$ si $k \in \mathcal{N}_i$), de modo que el rezago espacial de una celda es el promedio de sus vecinas. El modelo jerárquico usa la adyacencia binaria A, sin estandarizar.

Una sola partición. La rejilla, el filtrado y la matriz de pesos viven en una función del paquete (`geostats.espacial.celdas`) y no en los notebooks. Así el análisis exploratorio y los modelos usan exactamente la misma partición, y cada notebook verifica con una aserción que obtiene las mismas 2,241 celdas sin islas.

Elección de escala. Los 500 m son un compromiso: es suficiente resolución para distinguir corredores viales y suficiente agregación para que la celda típica acumule decenas

de eventos y no uno. Como todo estadístico sobre datos agregados depende de la agregación, la concentración y la autocorrelación global se recalculan con lados de 250 y 1,000 m. El criterio es que la conclusión cualitativa no cambie con la escala, aunque la magnitud lo haga.

3.2. Análisis espacial exploratorio

Sea n_i el total de accidentes 2019–2024 en la celda i. La distribución de n_i tiene una cola pesada (dos órdenes de magnitud entre la mediana y el máximo), y en un estadístico basado en productos cruzados unas cuantas celdas decidirían el resultado. Por eso la autocorrelación se calcula sobre $y_i = \log(1 + n_i)$, que comprime la cola sin reordenar las celdas. El I de Moran global se repite sobre el conteo crudo para comprobar que la conclusión no depende de la transformación.

Concentración. La curva de Lorenz ordena las celdas de menor a mayor conteo y grafica la fracción acumulada de accidentes contra la de celdas. El coeficiente de Gini resume la distancia a la diagonal. Como medida operativa se reporta además qué fracción de los accidentes concentra el 1, 5, 10 y 20 % de las celdas con más eventos. Las mismas medidas se calculan a escala de intersección para ver si la concentración es una propiedad de la rejilla o del fenómeno.

Autocorrelación global. El I de Moran [Moran(1950)],

$$I = \frac{N}{S_0} \frac{\sum_i \sum_k w_{ik}\, z_i z_k}{\sum_i z_i^2}, \qquad z_i = y_i - \bar{y}, \tag{1}$$

con $S_0 = \sum_{i,k} w_{ik}$, es la pendiente de la regresión del rezago espacial sobre el valor de la celda. Bajo independencia su esperanza es $-1/(N-1) \approx 0$. La inferencia es por permutación condicional: se barajan los valores entre celdas 999 veces y se ubica el I observado en esa distribución de referencia, lo que evita suponer normalidad. Con 999 permutaciones, el menor p alcanzable es 0,001. En el texto, "$p \leq 0{,}001$" significa que el observado quedó fuera de todas las simulaciones, no una probabilidad de un milésimo.

Estructura local. Dos estadísticos con lógica distinta. El LISA [Anselin(1995)] descompone el I global en una contribución por celda,

$$I_i = \frac{z_i}{m_2} \sum_k w_{ik}\, z_k, \qquad m_2 = \frac{1}{N} \sum_i z_i^2, \tag{2}$$

y clasifica cada celda significativa según su valor y el de sus vecinas: Alto–Alto (núcleo de un agrupamiento), Bajo–Bajo, y los dos atípicos Alto–Bajo y Bajo–Alto. El G_i^* de Getis–Ord [Getis and Ord(1992), Ord and Getis(1995)] pregunta algo más laxo y más operativo: si la suma de la celda y sus vecinas (el asterisco indica que la celda se incluye a sí misma) es alta respecto al total. Un z positivo grande es un punto caliente y uno negativo, un punto frío. Ambos usan inferencia por permutación condicional, con 999 permutaciones y semilla fija.

Comparaciones múltiples. Un estadístico local es una prueba por celda. Con 2,241 pruebas al 5 %, el azar solo produce del orden de 112 rechazos. Todo mapa local se corrige por tasa de falsos descubrimientos con el procedimiento de Benjamini–Hochberg [Benjamini and Hochberg(1995)] al 5 %, y se reporta cuántas celdas son significativas antes y después de la corrección. Se prefirió FDR a Bonferroni porque el objetivo es un mapa (controlar la proporción de celdas falsamente marcadas) y no una afirmación sobre cada celda por separado.

Persistencia. La autocorrelación dice que hay estructura en un momento dado. Para predecir hace falta que la estructura se mantenga de un año a otro. Se mide de dos formas: el I de Moran de cada año por separado (¿la estructura existe todos los años?) y la matriz de correlaciones de Spearman entre los conteos por celda de cada par de años (¿es la *misma* estructura?). La prueba operativa es el PAI del ranking histórico (definido en §3.5): ordenar las celdas por su total 2019–2023 y medir qué fracción de los accidentes de 2024 cae en la cabeza del ranking. Es un predictor sin parámetros, y por eso es la cota que cualquier modelo tiene que superar.

Lo que no se hizo. La función K de Ripley y la estimación de densidad por núcleo, en sus versiones planas, suponen que un evento puede ocurrir en cualquier punto del plano. Aquí solo puede ocurrir sobre la red vial, y contrastar contra un nulo plano sobreestimaría el agrupamiento. Las versiones restringidas a red [Okabe and Sugihara(2012)] exigen la geometría de las calles, que todavía no forma parte del repositorio. Se decidió no correrlas: contestarían una pregunta que los estadísticos de rejilla ya responden (si hay agrupamiento y a qué escalas) a un costo computacional y de datos que se estima en horas de cómputo y en la geometría vial faltante.

3.3. Modelos de conteo

El panel. La unidad de observación es la celda-mes: 2 241 celdas × 72 meses = 161 352 filas. Los meses sin accidentes se incluyen explícitamente con $Y_{it} = 0$. Son observaciones tan reales como las demás, y omitirlas haría que el modelo aprendiera solo de los meses con eventos y sobreestimara todo.

Covariables. Siguiendo el criterio de §2.3, solo entran variables estructurales, que existen haya o no accidente:

- **Mes** como factor, para la estacionalidad.
- **Periodo** en tres niveles: prepandemia (hasta febrero de 2020), pandemia (marzo de 2020 a diciembre de 2021) y 2022 en adelante. El tercer corte corresponde al cambio en el procedimiento de georreferenciación del INEGI que sugiere el análisis espacial. Sin él, el modelo leería ese salto como tendencia.
- **Historia de la celda**, $\log h_i$, con h_i el promedio mensual de la celda calculado *solo* con el periodo de entrenamiento (más medio accidente en todo el periodo,

para que el logaritmo exista en celdas sin eventos de entrenamiento). Es un efecto de celda resumido en un solo parámetro en lugar de 2 241. Su coeficiente se interpreta así: $\beta_h = 1$ significa que la historia entra como *offset*, y $\beta_h < 1$ significaría encogimiento hacia la media.

Poisson. El primer modelo es un GLM de Poisson con enlace logarítmico, estimado por máxima verosimilitud:

$$\begin{aligned} Y_{it} &\sim \text{Poisson}(\mu_{it}), \\ \log \mu_{it} &= \beta_0 + \gamma_{\text{mes}(t)} + \delta_{\text{per}(t)} + \beta_h \log h_i. \end{aligned} \tag{3}$$

Se ajusta sabiendo que el supuesto de equidispersión, $\text{Var}(Y) = \mu$, va a fallar. Sus coeficientes siguen siendo consistentes bajo sobredispersión (lo que se rompe son los errores estándar), así que sirve como referencia y como diagnóstico. La sobredispersión se mide de dos formas: con el cociente $\chi^2_{\text{Pearson}}/\text{gl}$, y con la prueba de Cameron–Trivedi [Cameron and Trivedi(1990)], que estima por mínimos cuadrados la regresión auxiliar

$$\frac{(y_{it} - \hat{\mu}_{it})^2 - y_{it}}{\hat{\mu}_{it}} = \alpha\, \hat{\mu}_{it} + \varepsilon_{it}. \tag{4}$$

Bajo Poisson $\alpha = 0$. Un $\alpha > 0$ significativo es la firma de la varianza cuadrática de la Binomial Negativa. Hay que distinguir la sobredispersión *marginal* (razón varianza/media del panel crudo), que mezcla la heterogeneidad entre celdas, de la *condicional* a las covariables, que es la que decide la verosimilitud.

Binomial Negativa. La mezcla Poisson–Gamma (NB2) supone que la tasa de cada celda-mes es una variable Gamma alrededor de μ_{it}. Ahí viven los factores no observados: obras, un semáforo descompuesto, la lluvia.

$$Y_{it} \sim \text{BinomialNegativa}(\mu_{it}, \theta), \quad \text{Var}(Y_{it}) = \mu_{it} + \frac{\mu_{it}^2}{\theta}. \tag{5}$$

Es la especificación habitual para la frecuencia de accidentes [Lord and Mannering(2010)]. Se compara con NB1, que tiene la varianza lineal en μ, por AIC. La prueba de razón de verosimilitudes entre Poisson y NB2 no es una χ^2_1 ordinaria. La nula $1/\theta = 0$ está en la frontera del espacio de parámetros, y la distribución nula correcta es una mezcla 50:50 de una masa en cero y una χ^2_1 [Self and Liang(1987)], de modo que el valor p es la mitad del de tablas.

Diagnósticos de ajuste. Los residuales de Pearson y de devianza son discretos y sesgados en conteos con muchos ceros, así que no sirven para diagnosticar. Se usan dos herramientas específicas. El rootograma colgante [Kleiber and Zeileis(2016)] compara, para cada valor k, la raíz de la frecuencia esperada con la de la observada; las barras que no tocan el cero señalan los valores sub- o sobrepredichos. Los residuales cuantil aleatorizados [Dunn and Smyth(1996)] toman un punto uniforme entre $F(y-1)$ y $F(y)$ y lo pasan por la normal inversa. Si el modelo es correcto, son exactamente $\mathcal{N}(0, 1)$.

Tabla 1
Escalera de modelos a escala celda × mes. Todos los GLM incluyen mes y periodo; difieren en la verosimilitud y en la historia.

Modelo	Especificación
M0	Media mensual 2019–2023 de la celda
M0r	Media mensual 2022–2023 de la celda
M1	Poisson, $\log h$
M2	NB2, $\log h$
M3	NB2, $\log h$ + rezago espacial de h
M4	NB2, $\log h^{\text{rec}}$ (2022–2023)
M5	NB2, $\log h + \log h^{\text{rec}}$

Promediados por celda, permiten calcular el I de Moran del residual y ver si queda estructura espacial sin modelar. También permiten descomponer esa estructura en una parte entre municipios y otra dentro de cada municipio, restando la media municipal.

Ceros. Los modelos inflados en ceros (ZIP, ZINB) [Lambert(1992)] suponen dos procesos: uno que decide si la observación puede tener eventos (cero estructural) y un conteo. La partición ya retira las celdas sin red vial, que eran el cero estructural obvio. Para el exceso que pudiera quedar, el ZINB no se usa como modelo candidato sino como instrumento de medición. Se ajusta con una probabilidad de inflación constante para cuantificar el exceso, y luego se pregunta *de dónde sale*: se compara, por par municipio × periodo, el número de ceros observados con el esperado bajo NB2. Si el exceso estuviera disperso entre celdas, el ZINB sería la respuesta. Si se concentrara en municipios y periodos concretos, sería un fenómeno de reporte, que corresponde a un término municipal del modelo jerárquico y no a una segunda ecuación.

La escalera de modelos. La tabla 1 resume los modelos de este peldaño. M3 adelanta una pregunta del modelo jerárquico: si la vecindad aporta algo que la celda sola no tenga. Para eso añade el logaritmo del rezago espacial de h, es decir, el promedio de la historia de las vecinas. M4 y M5 prueban la ventana de la historia. Como h_i se construye con la propia respuesta, dos ventanas distintas dan verosimilitudes que no miden lo mismo. **El AIC solo se usa entre modelos con la misma historia**; la elección de ventana se decide fuera de muestra.

3.4. Modelo jerárquico bayesiano

Los modelos de conteo dejan tres decisiones para este peldaño (los detalles están en §4.2). La verosimilitud es binomial negativa, sin inflación de ceros. El error de predicción tiene forma de municipio y cambia de un año a otro. Y la historia de la celda deja de ser una covariable precalculada y pasa a ser un efecto aleatorio estimado con todos los años.

Panel anual. El modelo se ajusta sobre celda × año (2,241 × 5 = 11,205 observaciones de entrenamiento), no celda × mes. Hay dos razones. La razón estadística es que el efecto de mes es común a todas las celdas y aportó poco sobre

un promedio bien elegido, mientras que la estructura de interés (el régimen municipal y el perfil de cada celda) vive en el nivel anual. Es el supuesto de separabilidad espacio–tiempo: el patrón espacial no cambia de forma dentro del año. Si hiciera falta el detalle mensual, se repone con un perfil estacional multiplicativo fijo. La computacional es que el muestreo sobre 161 mil observaciones con ∼2,300 parámetros tarda horas; sobre 11 mil, minutos. Eso decide si el modelo se puede iterar.

Especificación. Para la celda i, en el municipio $j(i)$, en el año a:

$$\begin{aligned} Y_{ia} &\sim \text{BinomialNegativa}(\mu_{ia},\ \theta), \\ \log \mu_{ia} &= \beta_0 + m_{j(i),a} + u_i . \end{aligned} \tag{6}$$

β_0 es el nivel metropolitano. El efecto municipal $m_{j,a}$ absorbe *cuánto se reporta* en cada municipio y año. El efecto de celda u_i, constante en el tiempo, absorbe *dónde, dentro del municipio, se concentra* el riesgo.

Nivel municipal. Caminata aleatoria con innovaciones de colas pesadas:

$$\begin{aligned} m_{j,2019} &= \sigma_m z_j, & z &\sim \text{NormalSumaCero}(1), \\ m_{j,a} &= m_{j,a-1} + \sigma_{rw}\,\varepsilon_{j,a}, & \varepsilon_{j,a} &\sim t_3 . \end{aligned} \tag{7}$$

La restricción de suma cero en el nivel inicial identifica β_0: sin ella, subir todos los municipios y bajar β_0 da la misma verosimilitud. Las innovaciones son t de Student con tres grados de libertad, y no normales, porque las series municipales muestran que la mayoría de los municipios cambia poco de un año a otro y unos pocos saltan órdenes de magnitud. Una normal tendría que elegir entre una escala grande que no describe a nadie y una pequeña que no admite los saltos. La t admite ambos.

Nivel de celda: CAR propio. El perfil de las celdas sigue un modelo condicional autorregresivo propio [Besag(1974)]:

$$\mathbf{u} \sim \mathcal{N}\left(\mathbf{0},\ \sigma_u^2\,(D - \alpha A)^{-1}\right), \tag{8}$$

con A la adyacencia binaria de los hexágonos, D la matriz diagonal con el número de vecinos de cada celda y $\alpha \in (0, 1)$ la dependencia espacial. Con $\alpha = 0$ las celdas son independientes, y conforme $\alpha \to 1$ cada una se parece más al promedio de sus vecinas. Es este término el que produce el *shrinkage*: una celda con pocos datos toma prestada información de sus vecinas, en proporción a lo poco que sabe de sí misma.

Por qué CAR propio y no BYM2. La propuesta original era el modelo BYM [Besag et al.(1991)Besag, York and Mollié] en la reparametrización BYM2 [Riebler et al.(2016)Riebler, Sørbye, Simpson and Rue]: $u_i = \sigma\left(\sqrt{1-\phi}\,v_i + \sqrt{\phi}\,s_i\right)$, con v independiente, s un ICAR escalado y ϕ interpretable como la fracción espacial de la varianza. Se intentó en sus parametrizaciones centrada y no centrada, y no se identificó: el muestreador colapsó a $\phi \to 0$ en una y a $\phi \to 1$ en la otra, sin convergencia (§4.3). El motivo es de estructura, no de ajuste fino. Con cinco años de conteos por celda, los datos fijan cada u_i casi por completo, y su reparto entre una parte "espacial" y otra "independiente" solo lo sostienen los priors. El CAR propio tiene una sola varianza y un solo parámetro de dependencia, es un prior propio y se identifica con datos fuertes. α responde la misma pregunta que ϕ (cuánto se parecen las vecinas) de forma directamente estimable. Es la alternativa usual cuando BYM no converge [Banerjee et al.(2015)Banerjee, Carlin and Gelfand].

Tabla 2
Priors del modelo jerárquico y los alternativos del análisis de sensibilidad.

Parámetro	Prior	Alternativo
β_0	$\mathcal{N}(\log(\bar{y}+1),\ 2)$	—
σ_m	Semi-normal(1,5)	—
σ_{rw}	Semi-normal(0,5)	—
α	Beta(2, 1)	Beta(1, 1)
σ_u	Semi-normal(1,5)	Semi-normal(3)
θ	Gamma(2; 0,1), media 20	Gamma(2; 0,4), media 5

Priors. La tabla 2 los resume. Son débilmente informativos: fijan la escala del problema sin decidir el resultado. Su influencia se verifica reajustando con priors alternativos.

El prior Beta(2, 1) de α se inclina a dependencia positiva porque el análisis exploratorio ya la midió. La alternativa uniforme comprueba que esa inclinación no es la que produce el resultado. La escala de σ_{rw} corresponde a un cambio anual típico de menos del 60 %.

Ajuste. El modelo se implementó en PyMC [Abril-Pla et al.(2023)Abril- y se muestreó con NUTS [Hoffman and Gelman(2014)] mediante `nutpie`: cuatro cadenas, 1,000 iteraciones de calentamiento y 2,000 muestras por cadena, semilla 42. El reajuste de sensibilidad usa 500 muestras por cadena.

Diagnósticos. Se exigen tres criterios: $\hat{R} < 1.01$ con la versión normalizada por rangos [Vehtari et al.(2021)Vehtari, Gelman, Sir un tamaño efectivo de muestra suficiente y cero transiciones divergentes. Se diagnostican las cantidades *identificadas*: los 11,205 predictores lineales $\log \mu_{ia}$ y los hiperparámetros. β_0 por separado no lo está del todo, porque compite con la media de $\mathbf{u}$, que el CAR propio solo ata débilmente a cero. Por eso ninguna conclusión se apoya en β_0 solo, sino en $m_{j,a}$, u_i y μ_{ia}. Las trayectorias municipales a posteriori se contrastan con las series observadas como verificación del supuesto de caminata aleatoria (apéndice A).

Especificaciones alternativas. Se evaluó también una variante con deriva lineal por municipio (tendencia local además de la caminata), para capturar el crecimiento sostenido de la periferia. Se comparó con la especificación base con el mismo protocolo de validación.

3.5. Validación fuera de muestra

Protocolo. Todos los modelos se ajustan con 2019–2023 y se evalúan en 2024, que ninguno vio. La regla se fijó desde el principio: *ningún modelo se compara en los datos con que se ajustó*. La razón es más fuerte en el jerárquico que en los GLM: con 2,241 efectos de celda reproduce el periodo de entrenamiento con un error mínimo, que no valida la predicción. Todas las cantidades derivadas de la respuesta, como h_i, h_i^{rec} y los promedios de los *baselines*, se calculan solo con entrenamiento. La partición es temporal y no aleatoria porque la pregunta es predictiva: anticipar el año siguiente con lo que se sabe hasta el anterior.

Pronóstico del modelo jerárquico. Para cada muestra a posteriori se fija el nivel municipal de 2024 en el de 2023, $m_{j,2024} = m_{j,2023}$, se combina con β_0 y u_i, y se simula un conteo binomial negativo con el θ de esa muestra. El ensamble de simulaciones propaga la incertidumbre de todos los parámetros y la dispersión NB. No se añade una innovación t_3 para 2024, aunque es lo que el modelo sugiere. Para cualquier t de Student, $\mathbb{E}[e^T] = \infty$, así que con esa innovación ni la media predictiva ni el CRPS existirían. El pronóstico es, por tanto, **condicional a que ningún municipio cambie de régimen de reporte en 2024**, y sus intervalos son un piso de la incertidumbre real.

Baselines. Los modelos se comparan contra predictores sin parámetros: la media histórica de la celda en 2019–2023 (M0) y en 2022–2023 (M0r). Con ellos el PAI no requiere modelo, solo contar y ordenar. Sus intervalos predictivos son Poisson con esa media. En la validación del jerárquico, M0, M0r y M4 se recalculan a escala anual para que la comparación sea sobre la misma unidad. Las métricas de las dos escalas (celda-mes y celda-año) no son comparables entre sí.

Métricas. Cada una contesta una pregunta distinta.

- **Devianza de Poisson y MAE**: ¿acierta la predicción puntual? El MAE se calcula sobre la media de los GLM y sobre la mediana del ensamble en el jerárquico.
- **CRPS** [Gneiting and Raftery(2007)]: ¿acierta la distribución predictiva entera? Para una predictiva con función de distribución F y un conteo observado y,

$$\mathrm{CRPS}(F, y) = \sum_{k \geq 0} \big(F(k) - \mathbb{1}\{y \leq k\}\big)^2, \qquad (9)$$

  que en los GLM se evalúa en forma cerrada truncando la suma. Para el ensamble del jerárquico, con simulaciones X, X' independientes de la predictiva, se usa la forma equivalente $\mathbb{E}|X-y| - \frac{1}{2}\mathbb{E}|X-X'|$. Es una regla de puntuación propia: penaliza tanto errar el centro como errar la incertidumbre, y es la métrica principal para elegir entre modelos.
- **Cobertura del intervalo del 90 %**: ¿qué fracción de los conteos de 2024 cae entre los cuantiles 5 y 95 de la predictiva? Un intervalo que no cubre lo que dice cubrir no sirve para decidir. Con conteos discretos y muchos ceros, la cobertura tiende a quedar por encima del nominal.
- **PAI** (índice de precisión predictiva) [Chainey et al.(2008)Chainey, ¿sirve el modelo para elegir dónde intervenir? Se seleccionan las celdas con mayor predicción hasta cubrir una fracción a del territorio y

$$\mathrm{PAI}_a = \frac{n_{\text{sel}}/n}{a}, \qquad (10)$$

  con n_{sel} los accidentes observados de 2024 en las celdas seleccionadas y n el total. PAI = 1 es el azar. Se reporta con a igual al 5 y al 10 %. Como todas las celdas tienen la misma área, la fracción de territorio es la fracción de celdas.

El PAI depende solo del orden de las celdas, no de los niveles predichos. Un modelo puede reducir el CRPS en una fracción apreciable (indicar el porcentaje) sin mover el PAI si no cambia el orden de las celdas. Por eso se reportan ambos y no se resume el desempeño en un solo número.

4. Resultados

4.1. Estructura espacial de la siniestralidad
4.2. Modelos de conteo
4.3. Modelo jerárquico
4.4. Validación en 2024

5. Discusión

6. Conclusiones y trabajo futuro

A. Supuestos del modelo jerárquico y su verificación

B. Reproducibilidad

Referencias

[Abril-Pla et al.(2023)Abril-Pla, Andreani, Carroll, Dong, Fonnesbeck, P
Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C.J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C.C., Martin, O.A., Osthege, M., Vieira, R., Wiecki, T., Zinkov, R., 2023. PyMC: a modern, and comprehensive probabilistic programming framework in Python. PeerJ Computer Science 9, e1516. doi:10.7717/peerj-cs.1516.

[Anselin(1995)] Anselin, L., 1995. Local indicators of spatial association—LISA. Geographical Analysis 27, 93–115. doi:10.1111/j.1538-4632.1995.tb00338.x.

[Banerjee et al.(2015)Banerjee, Carlin and Gelfand]
Banerjee, S., Carlin, B.P., Gelfand, A.E., 2015. Hierarchical Modeling and Analysis for Spatial Data. 2 ed., Chapman and Hall/CRC, Boca Raton. doi:10.1201/b17115.

[Benjamini and Hochberg(1995)] Benjamini, Y., Hochberg, Y., 1995. Controlling the false discovery rate: a practical and powerful approach to multiple testing. Journal of the Royal Statistical Society: Series B (Methodological) 57, 289–300. doi:10.1111/j.2517-6161.1995.tb02031.x.

[Besag(1974)] Besag, J., 1974. Spatial interaction and the statistical analysis of lattice systems. Journal of the Royal Statistical Society: Series B (Methodological) 36, 192–236. doi:10.1111/j.2517-6161.1974.tb00999.x.

[Besag et al.(1991)Besag, York and Mollié] Besag, J., York, J., Mollié, A., 1991. Bayesian image restoration, with two applications in spatial statistics. Annals of the Institute of Statistical Mathematics 43, 1–20. doi:10.1007/BF00116466.

[Birch et al.(2007)Birch, Oom and Beecham] Birch, C.P.D., Oom, S.P., Beecham, J.A., 2007. Rectangular and hexagonal grids used for observation, experiment and simulation in ecology. Ecological Modelling 206, 347–359. doi:10.1016/j.ecolmodel.2007.03.041.

[Cameron and Trivedi(1990)] Cameron, A.C., Trivedi, P.K., 1990. Regression-based tests for overdispersion in the Poisson model. Journal of Econometrics 46, 347–364. doi:10.1016/0304-4076(90)90014-K.

[Chainey et al.(2008)Chainey, Tompson and Uhlig] Chainey, S., Tompson, L., Uhlig, S., 2008. The utility of hotspot mapping for predicting spatial patterns of crime. Security Journal 21, 4–28. doi:10.1057/palgrave.sj.8350066.

[Dunn and Smyth(1996)] Dunn, P.K., Smyth, G.K., 1996. Randomized quantile residuals. Journal of Computational and Graphical Statistics 5, 236–244. doi:10.1080/10618600.1996.10474708.

[Getis and Ord(1992)] Getis, A., Ord, J.K., 1992. The analysis of spatial association by use of distance statistics. Geographical Analysis 24, 189–206. doi:10.1111/j.1538-4632.1992.tb00261.x.

[Gneiting and Raftery(2007)] Gneiting, T., Raftery, A.E., 2007. Strictly proper scoring rules, prediction, and estimation. Journal of the American Statistical Association 102, 359–378. doi:10.1198/016214506000001437.

[Hoffman and Gelman(2014)] Hoffman, M.D., Gelman, A., 2014. The No-U-Turn sampler: adaptively setting path lengths in Hamiltonian Monte Carlo. Journal of Machine Learning Research 15, 1593–1623.

[Instituto Nacional de Estadística y Geografía(2025)] Instituto Nacional de Estadística y Geografía, 2025. Accidentes de tránsito terrestre en zonas urbanas y suburbanas (ATUS). https://www.inegi.org.mx/programas/accidentes/.

[Kleiber and Zeileis(2016)] Kleiber, C., Zeileis, A., 2016. Visualizing count data regressions using rootograms. The American Statistician 70, 296–303. doi:10.1080/00031305.2016.1173590.

[Lambert(1992)] Lambert, D., 1992. Zero-inflated Poisson regression, with an application to defects in manufacturing. Technometrics 34, 1–14. doi:10.2307/1269547.

[Lord and Mannering(2010)] Lord, D., Mannering, F., 2010. The statistical analysis of crash-frequency data: a review and assessment of methodological alternatives. Transportation Research Part A: Policy and Practice 44, 291–305. doi:10.1016/j.tra.2010.02.001.

[Moran(1950)] Moran, P.A.P., 1950. Notes on continuous stochastic phenomena. Biometrika 37, 17–23. doi:10.2307/2332142.

[Okabe and Sugihara(2012)] Okabe, A., Sugihara, K., 2012. Spatial Analysis Along Networks: Statistical and Computational Methods. John Wiley & Sons, Chichester. doi:10.1002/9781119967101.

[Openshaw(1984)] Openshaw, S., 1984. The Modifiable Areal Unit Problem. Number 38 in Concepts and Techniques in Modern Geography, Geo Books, Norwich.

[Ord and Getis(1995)] Ord, J.K., Getis, A., 1995. Local spatial autocorrelation statistics: distributional issues and an application. Geographical Analysis 27, 286–306. doi:10.1111/j.1538-4632.1995.tb00912.x.

[Riebler et al.(2016)Riebler, Sørbye, Simpson and Rue] Riebler, A., Sørbye, S.H., Simpson, D., Rue, H., 2016. An intuitive Bayesian spatial model for disease mapping that accounts for scaling. Statistical Methods in Medical Research 25, 1145–1165. doi:10.1177/0962280216660421.

[Self and Liang(1987)] Self, S.G., Liang, K.Y., 1987. Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. Journal of the American Statistical Association 82, 605–610. doi:10.1080/01621459.1987.10478472.

[Vehtari et al.(2021)Vehtari, Gelman, Simpson, Carpenter and Bürkner] Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., Bürkner, P.C., 2021. Rank-normalization, folding, and localization: an improved $\widehat{R}$ for assessing convergence of MCMC. Bayesian Analysis 16, 667–718. doi:10.1214/20-BA1221.