Predicción espacial de accidentes de tránsito en la Zona Metropolitana de Monterrey

Angel Eduardo Luna[a]

[a]*Tecnológico de Monterrey, Monterrey, Nuevo León, México*

INFORMACIÓN

Palabras clave:
accidentes de tránsito
geoestadística
modelo jerárquico bayesiano
CAR
Monterrey

RESUMEN

1. Introducción

2. Datos

2.1. Fuente y recorte a la ZMM

La fuente es la base georreferenciada de Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS) del Instituto Nacional de Estadística y Geografía (INEGI) (Instituto Nacional de Estadística y Geografía, 2025), años 2019–2024: 1,317,810 accidentes, una fila por accidente, con coordenadas en WGS 84. La consolidación deja 50 columnas: descarta `OID`, presente solo en los archivos de 2022–2024, y agrega `CVE_MUN`, la clave municipal de cinco dígitos. La cobertura no es nacional: la base incluye solo municipios con zonas urbanas seleccionadas, 198 en total.

El análisis se restringe a los 18 municipios de la Zona Metropolitana de Monterrey (ZMM) según el Sistema Urbano Nacional (Secretaría de Desarrollo Agrario, Territorial y Urbano & Consejo Nacional de Población, 2018), listados en `zonas.ZMM_MONTERREY`: 379,294 accidentes (28.8 % de la base) en `atus_zmm.parquet`, con 51 columnas tras agregar `NOM_MUN`. Esos 18 municipios son los únicos de Nuevo León en ATUS, de modo que `EDO == 19` produce el mismo recorte. Se conserva la lista explícita para que el recorte no dependa de esa coincidencia: el código falla si falta un municipio.

`ID` no es llave: 268,920 filas repiten un valor ya presente, porque es un folio numérico en 2019–2020 y un identificador compuesto desde 2021. La llave es (`ANIO`, `EDO`, `MPIO`, `ID`), sin duplicados en la base ni en el recorte; la consolidación falla si aparece alguno.

2.2. Calidad y propiedades de la base

Integridad. Las diez pruebas de coherencia interna del *notebook* `calidad_datos` dan cero violaciones en los 379,294 registros: los totales de víctimas cuadran con sus componentes, `CLASE` es coherente con las víctimas, `URBANA` y `SUBURBANA` se excluyen, todo accidente tiene al menos un vehículo, las edades válidas caen en 12–98, la llave no se repite y ningún registro cae fuera de la ZMM. Los problemas de la base están en la captura, no en la consistencia del archivo.

Codificación. Los CSV se leen como CP1252, con un manejador de errores que aplica latin-1 a los bytes que CP1252 no define. Se descartó latin-1 directo porque convierte en caracteres de control los 719 caracteres del rango `0x80`–`0x9F` que CP1252 sí define. Los 740 bytes indefinidos (`0x81` y `0x8D`) se conservan sin sustitución, pero conservarlos no repara el texto: los 740 siguen a `Í`, `Ã` o `Â`, como en `RUÍ` más `0x8D` por `RUÍZ`, patrón compatible con doble codificación en el origen. Afectan a 704 registros de la base y a 82 de la ZMM, siempre en `CALLE1`, `CALLE2` o `CARRETERA`, campos que los modelos no usan.

Tabla 1
Registros y municipios por año en la base georreferenciada y en la ZMM.

	Base		ZMM	
Año	Registros	Mun.	Registros	Mun.
2019	180,219	91	63,134	18
2020	150,886	93	54,041	18
2021	199,224	169	55,639	18
2022	250,891	180	65,257	18
2023	262,768	198	69,902	18
2024	273,822	198	71,321	18

Panel desbalanceado en la base, balanceado en la ZMM. La base pasa de 91 a 198 municipios (cuadro 1). El salto 2020→2021, de 48,338 registros (32.0 %), es sobre todo cobertura y no siniestralidad: 33,771 de esos registros (69.9 %) provienen de 76 municipios ausentes en 2020, y los 91 municipios presentes los seis años crecen 9.3 %. En la ZMM, con los mismos 18 municipios, el aumento es de 3.0 %. Por eso las series de tiempo se construyen sobre `atus_zmm.parquet` y no se comparan con el agregado de la base.

El balance de la ZMM es de presencia, no de captura. Las 108 combinaciones de municipio y año tienen registros, pero Santa Catarina pasa de 3 en 2020 a 2,910 en 2023; §5.1 desarrolla esa inestabilidad. Lo que el panel balanceado garantiza es que un cambio en la ZMM no proviene de la entrada o la salida de municipios.

Centinelas. El INEGI codifica la ausencia de dato como un valor del catálogo, así que `isna()` solo detecta faltantes en `CALLE1` (434), `CALLE2` (5,979) y `CARRETERA` (373,649). El cuadro 2 reúne los centinelas presentes en la ZMM; los de `HORA`, `MINUTOS`, `DIA` y `DIASEMANA` no aparecen en ningún registro. `SEXO = 1` y `EDAD = 0` marcan los mismos 36,973 accidentes, aquellos en que el conductor se fugó. Solo 96,739 registros (25.5 %) están completos en `CINTURON`, `ALIENTO`, `EDAD`, `SEXO`, `HORA` y `DIA`. Otros huecos son estructurales: `CARRETERA` solo aplica a los 6,578 accidentes suburbanos (1.7 %), y `CALLE2`

Tabla 2
Faltante por centinela en la ZMM, en porcentaje de registros: total (N = 379,294), por clase de accidente (*Daños*: solo daños) y en los años extremos. Entre paréntesis, el código.

		Clase			Año	
Campo	Total	Fatal	No fatal	Daños	2019	2024
CINTURON (9)	72.3	86.0	79.3	71.8	62.2	75.4
EDAD (0, 99)	27.9	43.8	26.5	27.9	19.6	35.9
ALIENTO (6)	14.7	35.0	18.4	14.4	12.0	18.5
SEXO (1)	9.7	24.3	13.4	9.5	10.3	9.7

solo es un faltante real en los 3,072 accidentes marcados en intersección que no la traen.

El faltante no es aleatorio. La tasa de faltante depende de la gravedad: en accidentes fatales ALIENTO se ignora en 35.0 % de los casos contra 14.4 % en los de solo daños, 2.4 veces más seguido ($\chi^2(2) = 597.7$, $p < 0.001$, sobre las tres clases). La fuga explica una parte, porque los 36,973 accidentes con fuga tienen ALIENTO = 6, pero el gradiente persiste sin ellos: 14.1 % en 814 accidentes fatales contra 5.4 % en 323,800 de solo daños. EDAD no es monótona (26.5 % en no fatales contra 27.9 % en solo daños), de modo que el contraste vale entre los extremos.

Esa dependencia descarta que el dato falte completamente al azar (MCAR, *missing completely at random*), pero no distingue por sí sola entre faltante al azar condicional en lo observado (MAR, *missing at random*) y faltante no aleatorio (MNAR, *missing not at random*) (Rubin, 1976), porque el valor ausente no se observa. El análisis adopta MNAR como supuesto de trabajo: ninguna prueba sobre la base lo descarta, y es el único de los tres que no autoriza el borrado ni la imputación estándar. De ahí se siguen dos decisiones. Se descartó `dropna()`: conserva 10.2 % de los accidentes fatales contra 25.9 % de los de solo daños. Se descartó imputar, porque los métodos estándar suponen MAR. `geostats.limpieza` no borra filas ni imputa: conserva las 51 columnas y agrega 22 derivadas, entre ellas versiones de estos campos con el centinela convertido en NA.

La captura difiere entre municipios. En 2024, entre los 15 municipios con más de 500 accidentes, el faltante de CINTURON va de 10.4 % en San Pedro Garza García a 100.0 % en Monterrey, que aporta 172,275 registros (45.4 % de la ZMM) y solo 414 con dato real en seis años. Tampoco es estable: Guadalupe pasa de 20.3 % en 2019 a 96.8 % en 2020. Con un panel balanceado esos cambios no son de cobertura, y una comparación de estos campos entre municipios o años mide la práctica de captura antes que la conducta vial. Lo mismo ocurre con la serie de EDAD, cuyo faltante sube de 19.6 % a 35.9 %.

La coordenada es un nodo de la red. La coordenada se comporta como la de la intersección reportada y no como la del sitio físico del choque, por lo que el dato es un conteo sobre nodos de la red vial. 366,484 accidentes (96.6 %) están marcados en intersección, y 98.2 % de las 118,626 coordenadas exactas de intersección con dos vialidades corresponde a un solo par de calles. Las 131,180 coordenadas distintas se reducen a 54,742 nodos con una tolerancia de 10 m (`id_punto_4d`). Esta lectura se apoya en esos patrones: el repositorio no contiene documentación del procedimiento de geocodificación del INEGI.

La precisión cambia en 2021: todas las coordenadas de 2019–2020 tienen cinco decimales o menos, y desde 2021 cerca del 99 % de las longitudes tiene seis o más. Los registros que comparten coordenada exacta caen de 86.7 % en 2019 a 49.8 % en 2024, mientras que a 10 m se mantienen entre 83.3 % y 87.3 %. La caída mide un cambio de método y no una dispersión de los accidentes, de modo que una comparación entre años exige `id_punto_4d` o una unidad mayor, como la rejilla de §3.1. Ese cambio de precisión de 2021 es un hecho distinto del corte de 2022 asociado a OID (§5.3).

Tabla 3
Clasificación de las 51 columnas de `atus_zmm.parquet`.

Familia	Col.	Contenido
Estructural	16	Llave y municipio (ID, ANIO, EDO, MPIO, CVE_MUN, NOM_MUN); tiempo (MES, DIA, DIASEMANA, HORA); lugar (URBANA, SUBURBANA, CALLE1, CALLE2, LONGITUD, LATITUD)
Consecuente	25	CLASE, TIPACCID, 13 conteos de vehículos, 8 conteos de conductores, pasajeros, peatones y ciclistas muertos o heridos, TOTMUERTOS, TOTHERIDOS
Con reservas	5	SEXO, EDAD, ALIENTO, CAUSAACCI, CARRETERA
Descartada	5	CINTURON, CAPAROD, MINUTOS, OTROMUERTO, OTROHERIDO

2.3. Selección de variables

El criterio separa lo que existe haya o no accidente de lo que solo existe después del hecho. Las variables *estructurales* describen el dónde y el cuándo y son las únicas admisibles como predictores de un conteo. Las *consecuentes* describen el accidente: solo existen porque hubo un choque y no pueden explicar cuántos habrá, de modo que sirven para estratificar, para el descriptivo o como desenlace de un modelo de severidad. El cuadro 3 reparte las 51 columnas.

Los campos con reservas son consecuentes con una advertencia. SEXO, EDAD y ALIENTO tienen el faltante de §2.2; CAUSAACCI atribuye la causa al conductor en 94.6 % de los registros, y CARRETERA está vacío en 98.5 % de los registros. Las descartadas no aportan señal utilizable en la ZMM: CINTURON falta en 72.3 % de los registros, con Monterrey casi sin dato; CAPAROD marca 99.96 % como pavimentada; OTROMUERTO y OTROHERIDO son distintos de cero en 7 y 74 registros; y MINUTOS concentra 11.5 % en 0 y 30, contra 3.3 % esperado sin redondeo. Descartar es una decisión de análisis y no de archivo: `atus_zmm_limpio.parquet` conserva todas las columnas, por lo que la selección es reversible.

URBANA no indica si la zona es urbana: distingue accidentes en intersección (código 1, 366,484) de accidentes fuera de ella (código 2, 6,232), y el código 0 marca los 6,578

suburbanos. Es la variable que separa el análisis de cruces del de tramos.

Los modelos usan una fracción de las columnas estructurales: la celda, derivada de `LONGITUD` y `LATITUD`; `ANIO` y `MES`, y `NOM_MUN` (§3.3). Ninguna tiene centinelas en la ZMM, así que el faltante de §2.2 no afecta a las covariables de los modelos.

3. Metodología

La metodología es una escalera: cada peldaño se diseñó para contestar una pregunta que el anterior dejó abierta, y la especificación del modelo final salió de los diagnósticos de los modelos más simples, no de una elección previa. El análisis exploratorio (§3.2) decide si hay estructura espacial que modelar y si persiste en el tiempo; los modelos de conteo frecuentistas (§3.3) deciden la verosimilitud y dónde vive el error; el modelo jerárquico (§3.4) convierte ese diagnóstico en estructura. Todos comparten la misma partición del territorio (§3.1) y el mismo protocolo de validación (§3.5). Cada peldaño corresponde a un *notebook* del repositorio: `analisis_espacial`, `modelo_conteo` y `modelo_jerarquico`.

3.1. Unidad espacial

Proyección. Las coordenadas del INEGI vienen en WGS 84, en grados. A la latitud de Monterrey un grado de longitud mide ∼100 km y uno de latitud ∼111 km, de modo que una distancia en grados no es una distancia. Antes de cualquier cálculo de áreas, vecindades o rejillas los puntos se proyectan a UTM zona 14 Norte (EPSG:32614), cuya franja ($-102°$ a $-96°$) contiene toda la ZMM.

Por qué no el AGEB. La unidad propuesta inicialmente fue el AGEB urbano. Se descartó como unidad de análisis por tres razones. Primera, sus límites se trazan con frecuencia sobre vialidades principales, que es justamente donde se concentran los accidentes: un choque sobre una avenida cae en la frontera entre dos polígonos y su asignación es arbitraria. Es el problema de la unidad de área modificable (MAUP) (Openshaw, 1984) en una forma que afecta directamente la asignación de los accidentes viales. Segunda, el área de los AGEB es heterogénea, y comparar conteos exigiría un denominador de superficie o de exposición. Tercera, en polígonos irregulares el número de vecinos varía considerablemente, y la matriz de pesos espaciales hereda esa irregularidad. Tampoco se trabajó directamente sobre los puntos: como se documentó en §2.2, la coordenada se comporta como la de la intersección reportada y no como la del sitio físico del choque, así que el dato se trata como un conteo sobre nodos de la red y no como un patrón de puntos continuo en el plano. Esa lectura procede de los patrones de la base: el repositorio no documenta el procedimiento de geocodificación del INEGI.

La rejilla. Los accidentes se agregan a una rejilla regular de hexágonos con orientación de vértice lateral (*flat-top*) y lado $\ell = 500$ m, con un área por celda de $\frac{3\sqrt{3}}{2}\ell^2 \approx 0.65\,\text{km}^2$, comparable a un AGEB urbano. El hexágono tiene tres propiedades que el AGEB no tiene: área constante (el conteo *es* la densidad), ausencia de sesgo de frontera (la rejilla no sabe dónde están las calles) y una vecindad sin ambigüedad (seis vecinos que comparten arista, sin la distinción entre vecindad por arista y por vértice de la malla cuadrada) (Birch et al., 2007). La contraparte es que el hexágono no trae covariables censales. Esas tendrán que interpolarse desde el marco geoestadístico cuando se incorporen.

Cada accidente se asigna a la celda que lo contiene. Se conservan solo las celdas con al menos un accidente en los seis años: en 379,294 registros, una celda vacía no tiene red vial donde pueda ocurrir uno (es un cerro, una presa o un baldío), y tratarla como riesgo cero inflaría artificialmente los agrupamientos de valores bajos. Se retiran además las celdas *isla*, cuyas seis vecinas no tienen ningún accidente. No tienen con quién correlacionarse, y cualquier estadístico local sobre ellas degenera. El resultado son **2,270 celdas**. A cada celda se le asigna el municipio modal entre sus accidentes; esa es la pertenencia que usa el nivel municipal del modelo jerárquico.

Vecindad. Dos celdas son vecinas si comparten arista. Para los estadísticos exploratorios la matriz de pesos W se estandariza por fila ($w_{ik} = 1/|\mathcal{N}_i|$ si $k \in \mathcal{N}_i$), de modo que el rezago espacial de una celda es el promedio de sus vecinas. El modelo jerárquico usa la adyacencia binaria A, sin estandarizar. `libpysal` reconoce la contigüidad solo cuando dos polígonos comparten coordenadas idénticas, así que los vértices se calculan sobre una retícula entera de semilados y semialturas: dos hexágonos que comparten un vértice llegan al mismo par de flotantes. El grafo resultante tiene 5,325 aristas (4.69 vecinas por celda) y se contrasta con los pares de centroides a distancia $\sqrt{3}\,\ell$, que no dependen de la geometría de los polígonos. No es conexo: tiene 35 componentes, y la mayor reúne 2,126 celdas (93.7 %).

Una sola partición. La rejilla, el filtrado y la matriz de pesos viven en una función del paquete (`geostats.espacial.celdas`) y no en los notebooks. Así el análisis exploratorio y los modelos usan exactamente la misma partición, y cada notebook verifica con una aserción que obtiene las mismas 2,270 celdas sin islas.

Elección de escala. Los 500 m son un compromiso: es suficiente resolución para distinguir corredores viales y suficiente agregación para que la celda típica acumule decenas de eventos y no uno. Como todo estadístico sobre datos agregados depende de la agregación, la concentración y la autocorrelación global se recalculan con lados de 250 y 1,000 m. El criterio es que la conclusión cualitativa no cambie con la escala, aunque la magnitud lo haga.

3.2. Análisis espacial exploratorio

Sea n_i el total de accidentes 2019–2024 en la celda i. La distribución de n_i tiene una cola pesada (dos órdenes de magnitud entre la mediana y el máximo), y en un estadístico basado en productos cruzados unas cuantas celdas decidirían el resultado. Por eso la autocorrelación se calcula sobre

$y_i = \log(1 + n_i)$, que comprime la cola sin reordenar las celdas. El I de Moran global se repite sobre el conteo crudo para comprobar que la conclusión no depende de la transformación.

Concentración. La curva de Lorenz ordena las celdas de menor a mayor conteo y grafica la fracción acumulada de accidentes contra la de celdas. El coeficiente de Gini resume la distancia a la diagonal. Como medida operativa se reporta además qué fracción de los accidentes concentra el 1, 5, 10 y 20 % de las celdas con más eventos. Las mismas medidas se calculan a escala de intersección para ver si la concentración es una propiedad de la rejilla o del fenómeno.

Autocorrelación global. El I de Moran (Moran, 1950),

$$I = \frac{N}{S_0} \frac{\sum_i \sum_k w_{ik}\, z_i z_k}{\sum_i z_i^2}, \qquad z_i = y_i - \bar{y}, \tag{1}$$

con $S_0 = \sum_{i,k} w_{ik}$, es la pendiente de la regresión del rezago espacial sobre el valor de la celda. Bajo independencia su esperanza es $-1/(N-1) \approx 0$. La inferencia es por permutación condicional: se barajan los valores entre celdas 999 veces y se ubica el I observado en esa distribución de referencia, lo que evita suponer normalidad. Con 999 permutaciones, el menor p alcanzable es 0.001. En el texto, "$p \leq 0.001$" significa que el observado quedó fuera de todas las simulaciones, no una probabilidad de un milésimo.

Estructura local. Dos estadísticos con lógica distinta. El LISA (Anselin, 1995) descompone el I global en una contribución por celda,

$$I_i = \frac{z_i}{m_2} \sum_k w_{ik}\, z_k, \qquad m_2 = \frac{1}{N} \sum_i z_i^2, \tag{2}$$

y clasifica cada celda significativa según su valor y el de sus vecinas: Alto–Alto (núcleo de un agrupamiento), Bajo–Bajo, y los dos atípicos Alto–Bajo y Bajo–Alto. El G_i^* de Getis–Ord (Getis & Ord, 1992; Ord & Getis, 1995) pregunta algo más laxo y más operativo: si la suma de la celda y sus vecinas (el asterisco indica que la celda se incluye a sí misma) es alta respecto al total. Un z positivo grande es un punto caliente y uno negativo, un punto frío. Ambos usan inferencia por permutación condicional, con 999 permutaciones y semilla fija. El I de Moran, el LISA y el G_i^* se calcularon con `esda` y la matriz de pesos con `libpysal`, ambos paquetes de PySAL (Rey & Anselin, 2007; Rey et al., 2022).

Comparaciones múltiples. Un estadístico local es una prueba por celda. Con 2,270 pruebas al 5 %, el azar solo produce del orden de 113 rechazos. Todo mapa local se corrige por tasa de falsos descubrimientos con el procedimiento de Benjamini–Hochberg (Benjamini & Hochberg, 1995) al 5 %, y se reporta cuántas celdas son significativas antes y después de la corrección. Se prefirió FDR a Bonferroni porque el objetivo es un mapa (controlar la proporción de celdas falsamente marcadas) y no una afirmación sobre cada celda por separado.

Persistencia. La autocorrelación dice que hay estructura en un momento dado. Para predecir hace falta que la estructura se mantenga de un año a otro. Se mide de dos formas: el I de Moran de cada año por separado (¿la estructura existe todos los años?) y la matriz de correlaciones de Spearman entre los conteos por celda de cada par de años (¿es la *misma* estructura?). La prueba operativa es el PAI del ranking histórico (definido en §3.5): ordenar las celdas por su total 2019–2023 y medir qué fracción de los accidentes de 2024 cae en la cabeza del ranking. Es un predictor sin parámetros, y por eso es la cota que cualquier modelo tiene que superar.

Lo que no se hizo. La función K de Ripley y la estimación de densidad por núcleo, en sus versiones planas, suponen que un evento puede ocurrir en cualquier punto del plano. Aquí solo puede ocurrir sobre la red vial, y contrastar contra un nulo plano sobreestimaría el agrupamiento. Las versiones restringidas a red (Okabe & Sugihara, 2012) exigen la geometría de las calles, que todavía no forma parte del repositorio. Se decidió no correrlas: contestarían una pregunta que los estadísticos de rejilla ya responden (si hay agrupamiento y a qué escalas) a un costo computacional y de datos que se estima en horas de cómputo y en la geometría vial faltante.

3.3. Modelos de conteo

El panel. La unidad de observación es la celda-mes: 2,270 celdas × 72 meses = 163,440 filas. Los meses sin accidentes se incluyen explícitamente con $Y_{it} = 0$. Son observaciones tan reales como las demás, y omitirlas haría que el modelo aprendiera solo de los meses con eventos y sobreestimara todo.

Covariables. Siguiendo el criterio de §2.3, solo entran variables estructurales, que existen haya o no accidente:

- **Mes** como factor, para la estacionalidad.
- **Periodo** en tres niveles: prepandemia (hasta febrero de 2020), pandemia (marzo de 2020 a diciembre de 2021) y 2022 en adelante. El tercer corte corresponde al cambio en el procedimiento de georreferenciación del INEGI que sugiere el análisis espacial. Sin él, el modelo leería ese salto como tendencia. El corte alternativo en 2021, cuando cambia la precisión de las coordenadas, ajusta peor (§5.3).
- **Historia de la celda**, $\log h_i$, con h_i el promedio mensual de la celda calculado *solo* con el periodo de entrenamiento (más medio accidente en todo el periodo, para que el logaritmo exista en celdas sin eventos de entrenamiento). Es un efecto de celda resumido en un solo parámetro en lugar de 2,270. Su coeficiente se interpreta así: $\beta_h = 1$ significa que la historia entra como *offset*, y $\beta_h < 1$ significaría encogimiento hacia la media.

Poisson. El primer modelo es un GLM de Poisson con enlace logarítmico, estimado por máxima verosimilitud:

$$\begin{aligned} Y_{it} &\sim \text{Poisson}(\mu_{it}), \\ \log \mu_{it} &= \beta_0 + \gamma_{\text{mes}(t)} + \delta_{\text{per}(t)} + \beta_h \log h_i. \end{aligned} \tag{3}$$

Se ajusta sabiendo que el supuesto de equidispersión, $\text{Var}(Y) = \mu$, va a fallar. Sus coeficientes siguen siendo consistentes bajo sobredispersión (lo que se rompe son los errores estándar), así que sirve como referencia y como diagnóstico. La sobredispersión se mide de dos formas: con el cociente $\chi^2_{\text{Pearson}}/\text{gl}$, y con la prueba de Cameron–Trivedi (Cameron & Trivedi, 1990), que estima por mínimos cuadrados la regresión auxiliar

$$\frac{(y_{it} - \hat{\mu}_{it})^2 - y_{it}}{\hat{\mu}_{it}} = \alpha\, \hat{\mu}_{it} + \varepsilon_{it}. \tag{4}$$

Bajo Poisson $\alpha = 0$. Un $\alpha > 0$ significativo es la firma de la varianza cuadrática de la Binomial Negativa. Hay que distinguir la sobredispersión *marginal* (razón varianza/media del panel crudo), que mezcla la heterogeneidad entre celdas, de la *condicional* a las covariables, que es la que decide la verosimilitud.

Binomial Negativa. La mezcla Poisson–Gamma (NB2) supone que la tasa de cada celda-mes es una variable Gamma alrededor de μ_{it}. Ahí viven los factores no observados: obras, un semáforo descompuesto, la lluvia.

$$Y_{it} \sim \text{BinomialNegativa}(\mu_{it}, \theta), \qquad \text{Var}(Y_{it}) = \mu_{it} + \frac{\mu_{it}^2}{\theta}. \tag{5}$$

Es la especificación habitual para la frecuencia de accidentes (Lord & Mannering, 2010). Se compara con NB1, que tiene la varianza lineal en μ, por AIC. La prueba de razón de verosimilitudes entre Poisson y NB2 no es una χ^2_1 ordinaria. La nula $1/\theta = 0$ está en la frontera del espacio de parámetros, y la distribución nula correcta es una mezcla 50:50 de una masa en cero y una χ^2_1 (Self & Liang, 1987), de modo que el valor p es la mitad del de tablas.

Diagnósticos de ajuste. Los residuales de Pearson y de devianza son discretos y sesgados en conteos con muchos ceros, así que no sirven para diagnosticar. Se usan dos herramientas específicas. El rootograma colgante (Kleiber & Zeileis, 2016) compara, para cada valor k, la raíz de la frecuencia esperada con la de la observada; las barras que no tocan el cero señalan los valores sub- o sobrepredichos. Los residuales cuantil aleatorizados (Dunn & Smyth, 1996) toman un punto uniforme entre $F(y-1)$ y $F(y)$ y lo pasan por la normal inversa. Si el modelo es correcto, son exactamente $\mathcal{N}(0,1)$. Promediados por celda, permiten calcular el I de Moran del residual y ver si queda estructura espacial sin modelar. También permiten descomponer esa estructura en una parte entre municipios y otra dentro de cada municipio, restando la media municipal.

Ceros. Los modelos inflados en ceros (ZIP, ZINB) (Lambert, 1992) suponen dos procesos: uno que decide si la observación puede tener eventos (cero estructural) y un conteo. La partición ya retira las celdas sin red vial, que eran el cero estructural obvio. Para el exceso que pudiera quedar, el ZINB no se usa como modelo candidato sino como instrumento de medición. Se ajusta con una probabilidad de inflación constante para cuantificar el exceso, y luego se pregunta *de dónde sale*: se compara, por par municipio × periodo, el número de ceros observados con el esperado bajo NB2. Si el exceso estuviera disperso entre celdas, el ZINB sería la respuesta. Si se concentrara en municipios y periodos concretos, sería un fenómeno de reporte, que corresponde a un término municipal del modelo jerárquico y no a una segunda ecuación.

Tabla 4
Escalera de modelos a escala celda × mes. Todos los GLM incluyen mes y periodo; difieren en la verosimilitud y en la historia.

Modelo	Especificación
M0	Media mensual 2019–2023 de la celda
M0r	Media mensual 2022–2023 de la celda
M1	Poisson, $\log h$
M2	NB2, $\log h$
M3	NB2, $\log h$ + rezago espacial de h
M4	NB2, $\log h^{\text{rec}}$ (2022–2023)
M5	NB2, $\log h + \log h^{\text{rec}}$

La escalera de modelos. La tabla 4 resume los modelos de este peldaño. M3 adelanta una pregunta del modelo jerárquico: si la vecindad aporta algo que la celda sola no tenga. Para eso añade el logaritmo del rezago espacial de h, es decir, el promedio de la historia de las vecinas. M4 y M5 prueban la ventana de la historia. Como h_i se construye con la propia respuesta, dos ventanas distintas dan verosimilitudes que no miden lo mismo. **El AIC solo se usa entre modelos con la misma historia**; la elección de ventana se decide fuera de muestra.

3.4. Modelo jerárquico bayesiano

Los modelos de conteo dejan tres decisiones para este peldaño (los detalles están en §4.2). La verosimilitud es binomial negativa, sin inflación de ceros. El error de predicción tiene forma de municipio y cambia de un año a otro. Y la historia de la celda deja de ser una covariable precalculada y pasa a ser un efecto aleatorio estimado con todos los años.

Panel anual. El modelo se ajusta sobre celda × año (2,270 × 5 = 11,350 observaciones de entrenamiento), no celda × mes. Hay dos razones. La razón estadística es que el efecto de mes es común a todas las celdas y aportó poco sobre un promedio bien elegido, mientras que la estructura de interés (el régimen municipal y el perfil de cada celda) vive en el nivel anual. Es el supuesto de separabilidad espacio–tiempo: el patrón espacial no cambia de forma dentro del año. Si hiciera falta el detalle mensual, se repone con un perfil estacional multiplicativo fijo. La computacional es que el muestreo sobre 161 mil observaciones con ∼2,300

parámetros tarda horas; sobre 11 mil, minutos. Eso decide si el modelo se puede iterar.

Especificación. Para la celda i, en el municipio $j(i)$, en el año a:

$$\begin{aligned} Y_{ia} &\sim \text{BinomialNegativa}(\mu_{ia},\ \theta), \\ \log \mu_{ia} &= \beta_0 + m_{j(i),a} + u_i. \end{aligned} \tag{6}$$

β_0 es el nivel metropolitano. El efecto municipal $m_{j,a}$ absorbe *cuánto se reporta* en cada municipio y año. El efecto de celda u_i, constante en el tiempo, absorbe *dónde, dentro del municipio, se concentra* el riesgo.

Nivel municipal. Caminata aleatoria con innovaciones de colas pesadas:

$$\begin{aligned} m_{j,2019} &= \sigma_m z_j, & z &\sim \text{NormalSumaCero}(1), \\ m_{j,a} &= m_{j,a-1} + \sigma_{rw}\,\varepsilon_{j,a}, & \varepsilon_{j,a} &\sim t_3. \end{aligned} \tag{7}$$

La restricción de suma cero en el nivel inicial identifica β_0: sin ella, subir todos los municipios y bajar β_0 da la misma verosimilitud. Las innovaciones son t de Student con tres grados de libertad, y no normales, porque las series municipales muestran que la mayoría de los municipios cambia poco de un año a otro y unos pocos saltan órdenes de magnitud. Una normal tendría que elegir entre una escala grande que no describe a nadie y una pequeña que no admite los saltos. La t admite ambos.

Nivel de celda: CAR propio. El perfil de las celdas sigue un modelo condicional autorregresivo propio (Besag, 1974):

$$\mathbf{u} \sim \mathcal{N}\left(\mathbf{0},\ \sigma_u^2\,(D - \alpha A)^{-1}\right), \tag{8}$$

con A la adyacencia binaria de los hexágonos, D la matriz diagonal con el número de vecinos de cada celda y $\alpha \in (0, 1)$ la dependencia espacial. Con $\alpha = 0$ las celdas son independientes, y conforme $\alpha \to 1$ cada una se parece más al promedio de sus vecinas. Es este término el que produce el *shrinkage*: una celda con pocos datos toma prestada información de sus vecinas, en proporción a lo poco que sabe de sí misma.

Por qué CAR propio y no BYM2. La propuesta original era el modelo BYM (Besag et al., 1991) en la reparametrización BYM2 (Riebler et al., 2016), $u_i = \sigma\left(\sqrt{1-\phi}\,v_i + \sqrt{\phi}\,s_i\right)$, con v independiente, s un ICAR escalado y ϕ interpretable como la fracción espacial de la varianza. Se intentó en sus parametrizaciones centrada y no centrada, y no se identificó: el muestreador colapsó a $\phi \to 0$ en una y a $\phi \to 1$ en la otra, sin convergencia (§4.3). El motivo es de estructura, no de ajuste fino. Con cinco años de conteos por celda, los datos fijan cada u_i casi por completo, y su reparto entre una parte "espacial" y otra "independiente" solo lo sostienen los priors. El CAR propio tiene una sola varianza y un solo parámetro de dependencia, es un prior propio y se identifica con datos fuertes. α responde la misma pregunta que ϕ (cuánto se parecen las vecinas) de forma directamente estimable. Es la alternativa usual cuando BYM no converge (Banerjee et al., 2014).

Tabla 5
Priors del modelo jerárquico y los alternativos del análisis de sensibilidad.

Parámetro	Prior	Alternativo
β_0	$\mathcal{N}(\log(\bar{y}+1),\ 2)$	—
σ_m	Semi-normal(1.5)	—
σ_{rw}	Semi-normal(0.5)	—
α	Beta(2, 1)	Beta(1, 1)
σ_u	Semi-normal(1.5)	Semi-normal(3)
θ	Gamma(2, 0.1), media 20	Gamma(2, 0.4), media 5

Priors. La tabla 5 los resume. Son débilmente informativos: fijan la escala del problema sin decidir el resultado. Su influencia se verifica reajustando con priors alternativos.

El prior Beta(2, 1) de α se inclina a dependencia positiva porque el análisis exploratorio ya la midió. La alternativa uniforme comprueba que esa inclinación no es la que produce el resultado. La escala de σ_{rw} corresponde a un cambio anual típico de menos del 60 %.

Ajuste. El modelo se implementó en PyMC (Abril-Pla et al., 2023) y se muestreó con NUTS (Hoffman & Gelman, 2014) mediante `nutpie`: cuatro cadenas, 3,000 iteraciones de calentamiento y 4,000 muestras por cadena, semilla 42. El reajuste de sensibilidad usa 1,000 muestras por cadena.

Diagnósticos. Se exigen tres criterios a las cantidades *identificadas*, los 11,350 predictores lineales $\log \mu_{ia}$: $\hat{R} < 1.01$ con la versión normalizada por rangos (Vehtari et al., 2021), un tamaño efectivo de muestra mínimo de 400 y cero transiciones divergentes. Para los hiperparámetros se reportan $\hat{R}$ y ESS sin exigir el umbral. β_0 por separado no está identificado del todo, porque compite con la media de $\mathbf{u}$, que el CAR propio solo ata débilmente a cero, y α comparte información con σ_u cuando la dependencia se acerca a 1. Por eso ninguna conclusión se apoya en β_0 ni en α solos, sino en $m_{j,a}$, u_i y μ_{ia}. Las trayectorias municipales a posteriori se contrastan con las series observadas como verificación del supuesto de caminata aleatoria (apéndice A).

Especificaciones alternativas. Se evaluó también una variante con deriva lineal por municipio (tendencia local además de la caminata), para capturar el crecimiento sostenido de la periferia. Se comparó con la especificación base con el mismo protocolo de validación.

3.5. Validación fuera de muestra

Protocolo. Todos los modelos se ajustan con 2019–2023 y se evalúan en 2024, que ninguno vio. La regla se fijó desde el principio: *ningún modelo se compara en los datos con que se ajustó*. La razón es más fuerte en el jerárquico que en los GLM: con 2,270 efectos de celda reproduce

el periodo de entrenamiento con un error mínimo, que no valida la predicción. Todas las cantidades derivadas de la respuesta, como h_i, h_i^{rec} y los promedios de los *baselines*, se calculan solo con entrenamiento. La partición es temporal y no aleatoria porque la pregunta es predictiva: anticipar el año siguiente con lo que se sabe hasta el anterior.

Pronóstico del modelo jerárquico. Para cada muestra a posteriori se fija el nivel municipal de 2024 en el de 2023, $m_{j,2024} = m_{j,2023}$, se combina con β_0 y u_i, y se simula un conteo binomial negativo con el θ de esa muestra. El ensamble de simulaciones propaga la incertidumbre de todos los parámetros y la dispersión NB. No se añade una innovación t_3 para 2024, aunque es lo que el modelo sugiere. Para cualquier t de Student, $\mathbb{E}[e^T] = \infty$, así que con esa innovación ni la media predictiva ni el CRPS existirían. El pronóstico es, por tanto, **condicional a que ningún municipio cambie de régimen de reporte en 2024**, y sus intervalos son un piso de la incertidumbre real.

Baselines. Los modelos se comparan contra predictores sin parámetros: la media histórica de la celda en 2019–2023 (M0) y en 2022–2023 (M0r). Con ellos el PAI no requiere modelo, solo contar y ordenar. Sus intervalos predictivos son Poisson con esa media. En la validación del jerárquico, M0, M0r y M4 se recalculan a escala anual para que la comparación sea sobre la misma unidad. Las métricas de las dos escalas (celda-mes y celda-año) no son comparables entre sí.

Métricas. Cada una contesta una pregunta distinta.

- **Devianza de Poisson y MAE**: ¿acierta la predicción puntual? El MAE se calcula sobre la media de los GLM y sobre la mediana del ensamble en el jerárquico.
- **CRPS** (Gneiting & Raftery, 2007): ¿acierta la distribución predictiva entera? Para una predictiva con función de distribución F y un conteo observado y,

$$\text{CRPS}(F, y) = \sum_{k \geq 0} \big(F(k) - \mathbb{1}\{y \leq k\}\big)^2, \qquad (9)$$

  que en los GLM se evalúa en forma cerrada truncando la suma. Para el ensamble del jerárquico, con simulaciones X, X' independientes de la predictiva, se usa la forma equivalente $\mathbb{E}|X-y| - \frac{1}{2}\mathbb{E}|X-X'|$. Es una regla de puntuación propia: penaliza tanto errar el centro como errar la incertidumbre, y es la métrica principal para elegir entre modelos.
- **Cobertura del intervalo del 90 %**: ¿qué fracción de los conteos de 2024 cae entre los cuantiles 5 y 95 de la predictiva? Un intervalo que no cubre lo que dice cubrir no sirve para decidir. Con conteos discretos y muchos ceros, la cobertura tiende a quedar por encima del nominal.
- **PAI** (índice de precisión predictiva) (Chainey et al., 2008): ¿sirve el modelo para elegir dónde intervenir? Se seleccionan las celdas con mayor predicción hasta cubrir una fracción a del territorio y

$$\text{PAI}_a = \frac{n_{\text{sel}}/n}{a}, \qquad (10)$$

  con n_{sel} los accidentes observados de 2024 en las celdas seleccionadas y n el total. PAI = 1 es el azar. Se reporta con a igual al 5 y al 10 %. Como todas las celdas tienen la misma área, la fracción de territorio es la fracción de celdas.

El PAI depende solo del orden de las celdas, no de los niveles predichos. La NB2 reduce el CRPS de M0 en 2.6 % con el mismo PAI, porque conserva el orden de las celdas (§4.2). Por eso se reportan ambos y no se resume el desempeño en un solo número.

4. Resultados

Los resultados se presentan en el orden en que condicionaron las decisiones siguientes: primero la estructura espacial que justifica un enfoque territorial (§4.1); después la comparación de modelos de conteo, que reveló que el error dominante es municipal (§4.2); luego el ajuste del modelo jerárquico que se construyó en respuesta (§4.3), y al final la validación de todos contra 2024 (§4.4). Todas las cifras se refieren a la partición de 2,270 celdas hexagonales de 500 m de lado descrita en §3.1.

4.1. Estructura espacial de la siniestralidad

Concentración. Los accidentes de 2019–2024 se reparten de forma desigual entre las celdas (figura 1): la mediana por celda es 30 y el máximo 3,741. La curva de Lorenz da un **coeficiente de Gini de 0.766**. El 1 % de las celdas concentra el 14.9 % de los accidentes; el 5 %, el 43.7 %, y el 10 %, el 61.7 %. A escala de intersección el Gini es 0.752 y el 5 % de los puntos concentra el 58 % (figura 2). La concentración es similar en las dos escalas: es la firma de una distribución de cola pesada y no un artefacto de la agregación.

Autocorrelación global. Con pesos de contigüidad estandarizados por fila sobre $\log(1+n)$, el I **de Moran es 0.654**, con $z = 45$ frente a 999 permutaciones (figura 3); ninguna permutación se acerca al valor observado. Sobre el conteo crudo el estadístico es 0.58, de modo que la conclusión no depende de la transformación. Las celdas vecinas se parecen: un modelo que las trate como independientes subestimará sus errores estándar.

Sensibilidad a la escala. Repetir el análisis con lados de 250 y 1,000 m (cuadro 6) muestra el efecto de escala esperado en el I de Moran, que crece con la agregación de 0.53 a 0.72, mientras que el 5 % superior concentra 43–45 % de los accidentes en las tres rejillas. La autocorrelación es una propiedad del fenómeno y no de la rejilla elegida.

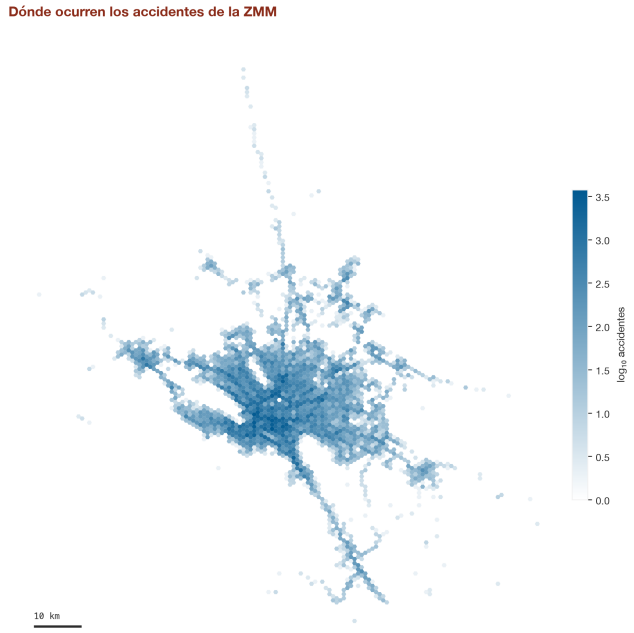


Figura 1: Accidentes por celda hexagonal, 2019–2024, en escala logarítmica.

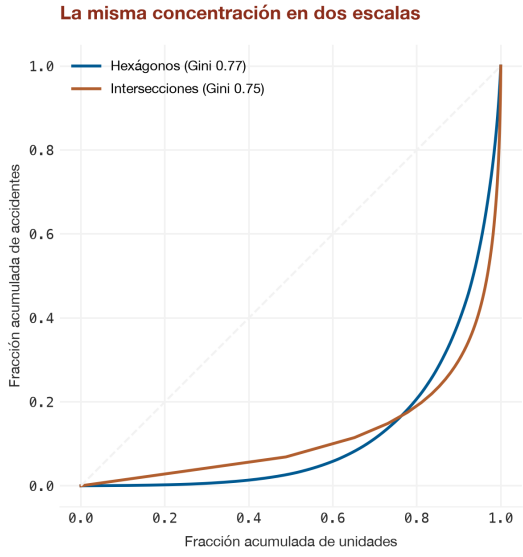


Figura 2: Curvas de Lorenz por celda hexagonal y por intersección.

Estructura local. Con 2,270 pruebas al 5 % se esperan del orden de 113 falsos positivos por azar, por lo que los estadísticos locales se corrigieron con Benjamini–Hochberg (Benjamini & Hochberg, 1995). Con la corrección, **el LISA (Anselin, 1995) pasa de 705 celdas significativas a 400** (−43 %), y el G_i^* (Ord & Getis, 1995), de 749 a 470. Lo que sobrevive (figura 4) es un núcleo compacto de 370 celdas Alto–Alto sobre la mancha urbana consolidada, 26 Bajo–Bajo en la periferia y solo cuatro atípicos espaciales (uno Alto–Bajo y tres Bajo–Alto). No aparecen puntos calientes aislados: el riesgo se organiza en corredores, no en esquinas sueltas. Las 384 celdas calientes del G_i^* —el 16.9 % del territorio con red vial, 249 km^2— concentran el 64.7 % de los accidentes.

Tabla 6
Sensibilidad de la autocorrelación y la concentración al tamaño de la celda.

Lado (m)	Celdas	I	Gini	Top 5 %
250	6,200	0.528	0.748	44.9 %
500	2,270	0.654	0.758	42.8 %
1,000	849	0.716	0.795	44.7 %

Persistencia. La estructura no es propia de un año. El I de Moran anual se mantiene entre 0.61 y 0.69 de 2019 a 2024, y el ranking de celdas de 2019 tiene una **correlación de Spearman de 0.83 con el de 2024**, con la pandemia de por medio (figura 5). La matriz de correlaciones tiene además dos bloques: ∼0.90 dentro de 2019–2021 y dentro de 2022–2024, y ∼0.82 entre bloques. El corte coincide con la aparición del campo `OID` en los archivos del INEGI a partir de 2022; por eso los modelos incluyen un indicador de periodo.

La prueba operativa de persistencia es el índice de precisión predictiva (PAI) (Chainey et al., 2008): la fracción de accidentes capturada dividida entre la fracción de territorio seleccionada. **Eligiendo el 5 % de las celdas con más accidentes en 2019–2023 se captura el 42 % de los accidentes de 2024: PAI de 8.4.** Este resultado no usa ningún modelo —solo contar y ordenar— y es la referencia que cualquier modelo tiene que superar.

4.2. Modelos de conteo

Sobredispersión. En el panel de celda×mes (163,440 filas, 56.9 % de ceros) la razón varianza/media marginal es 12.9. Condicionando en la historia de la celda, $\log h_i$, el estadístico $\chi^2_{\text{Pearson}}/gl$ del GLM de Poisson cae a 1.37: la historia absorbe casi toda la heterogeneidad, pero lo que queda es inequívoco. La prueba de Cameron y Trivedi (1990) estima $\hat{\alpha} = 0.096$ con $t = 60$. La Binomial Negativa NB2 estima $\theta = 5.5$ y mejora el AIC en unos 13,000 puntos respecto a Poisson y en 600 respecto a NB1. Como $1/\theta = 0$ está en la frontera del espacio paramétrico, la razón de verosimilitudes se evalúa contra una mezcla 50:50 de una masa en cero y una χ^2_1 (Self & Liang, 1987); el rechazo de Poisson se mantiene con cualquier convención.

El rootograma colgante (Kleiber & Zeileis, 2016) hace visible la diferencia (figura 6): Poisson subpredice los ceros en unas 4,600 celdas-mes y sobrepredice los unos en 2,900; NB2 corrige casi todo el desajuste. Los residuales cuantil aleatorizados de NB2 sobre 2024 (Dunn & Smyth, 1996) tienen desviación estándar de 1.11 en lugar de 1, con una cola derecha más pesada que la normal (figura 7): queda dispersión que el modelo no captura, y la sección siguiente muestra de dónde viene.

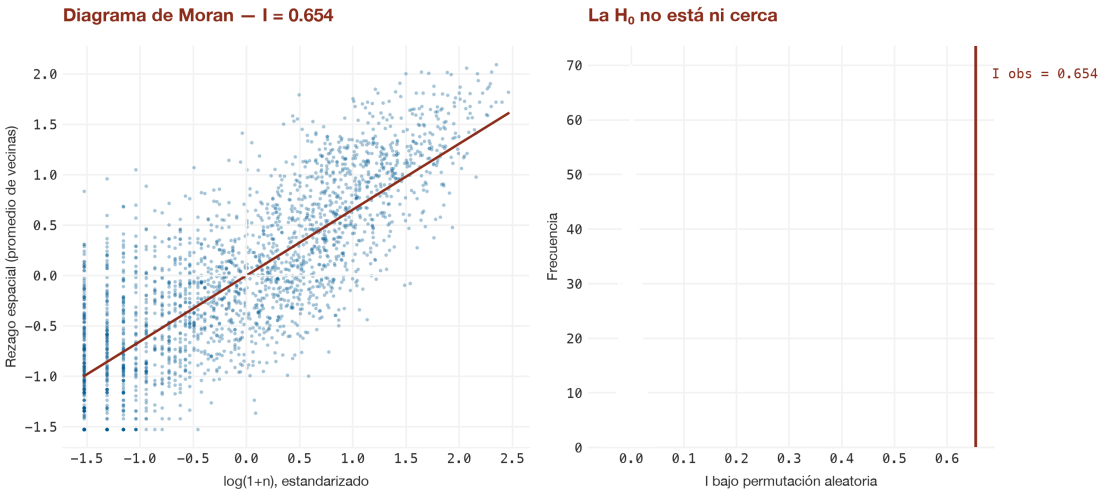


Figura 3: Izquierda: diagrama de dispersión de Moran sobre $\log(1+n)$ estandarizado; la pendiente es $I = 0.654$. Derecha: distribución de I bajo 999 permutaciones aleatorias, concentrada alrededor de cero, frente al valor observado.

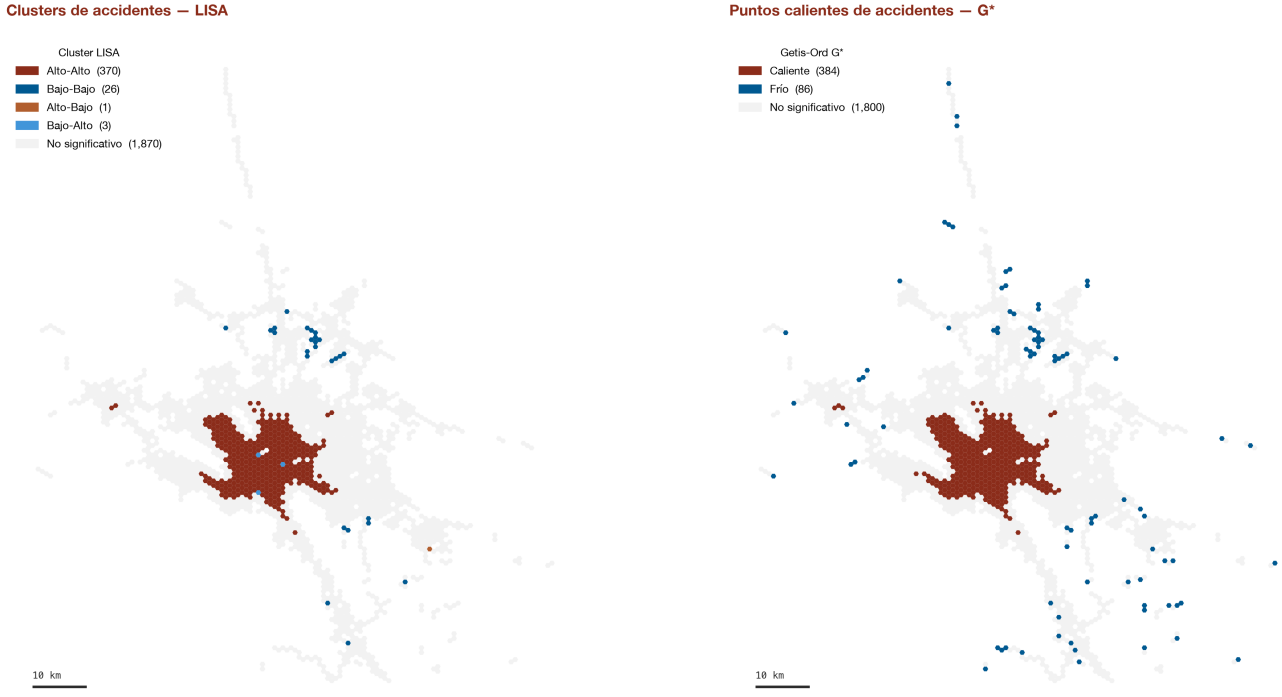


Figura 4: Izquierda: conglomerados LISA. Derecha: puntos calientes y fríos del G_i^* de Getis–Ord. Ambos mapas sobre la misma rejilla de celdas hexagonales, con control de la tasa de falsos descubrimientos al 5 %.

Exceso de ceros. A NB2 le falta el 3.2 % de los ceros. Un ZINB con inflación constante estima $\hat{\pi} = 0.026$ y mejora el AIC en 1,200, pero el exceso no está repartido: ocho pares municipio×periodo explican dos tercios de él, con Santa Catarina en prepandemia y pandemia a la cabeza. Ese municipio registró 128, 3 y 77 accidentes en 2019, 2020 y 2021, y 1,795 en 2022. Los ceros "estructurales" son celdas de municipios que no reportaban, no celdas sin riesgo, por lo que no se adoptó un modelo de inflación de ceros.

Comparación fuera de muestra. El cuadro 7 resume la validación en 2024 de los modelos de conteo a escala celda×mes.

Cuatro resultados se desprenden de esta comparación:

1. **El PAI es idéntico en M0–M3.** Con $\beta_h = 1.01$ y covariables que solo varían en el tiempo, la predicción de cada celda es h_i multiplicada por un factor común, y el ranking de celdas coincide con el del histórico

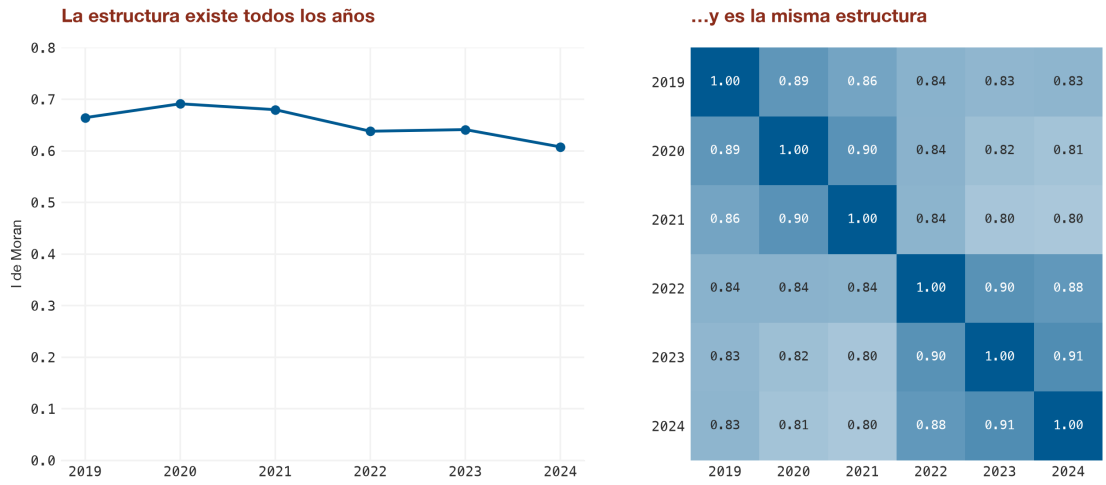


Figura 5: Izquierda: I de Moran por año. Derecha: correlación de Spearman entre los conteos por celda de cada par de años; se distinguen los bloques 2019–2021 y 2022–2024.

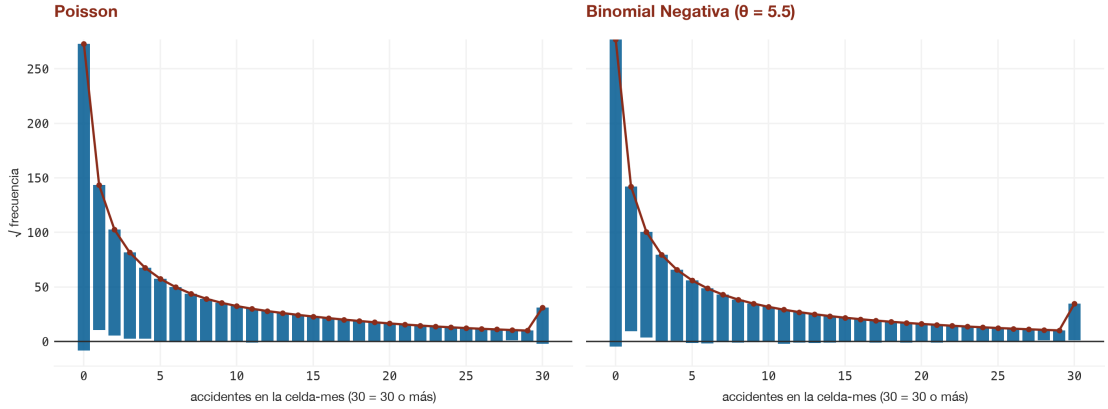


Figura 6: Rootogramas colgantes de Poisson y NB2 en el panel celda×mes. Las barras cuelgan de la frecuencia esperada (línea); si su base toca el cero, el modelo ajusta ese valor.

(Spearman = 1.000). Un GLM con covariables temporales cambia el *cuánto* y la incertidumbre, pero no el *dónde*.

2. **El rezago espacial no aporta nada**: su coeficiente es −0.002 ($t = -0.5$), pese a la autocorrelación de 0.65 en los conteos.
3. **Dos años recientes predicen mejor que cinco**: el CRPS de M4 es 0.838 contra 0.876 de M2, y el promedio simple de 2022–2023 (M0r) es el mejor de la tabla. Cuando el modelo recibe ambas historias elige la completa, porque en entrenamiento explica mejor 2019–2021 al contenerlos; solo la validación fuera de muestra revela que generaliza peor.
4. **El residual tiene forma de municipio.** El I de Moran del residual de NB2 en 2024 es 0.30 y cae a 0.06 al restar la media de cada municipio (figura 8). La

Tabla 7
Validación en 2024 a escala celda×mes. Devianza y MAE miden el acierto en la media; CRPS y cobertura, en la distribución; PAI, en la selección del 5 % de celdas. En negritas, el mejor CRPS.

Modelo	Devianza	MAE	CRPS	Cobertura 90 %	PAI 5 %
M0: histórico 2019–2023	40,949	1.232	0.899	89.8 %	8.44
M0r: histórico 2022–2023	35,843	1.184	**0.835**	92.0 %	8.42
M1: Poisson	39,917	1.233	0.885	90.3 %	8.44
M2: NB2	39,914	1.240	0.876	93.9 %	8.44
M3: NB2 + rezago espacial	39,913	1.240	0.876	93.9 %	8.44
M4: NB2, historia 2022–2023	35,899	1.186	0.838	92.1 %	8.42

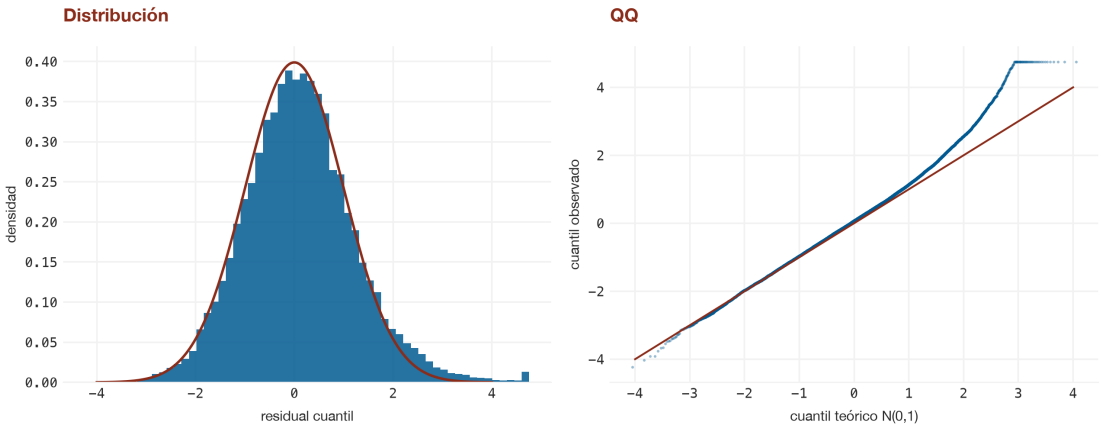


Figura 7: Residuales cuantil aleatorizados de NB2 sobre 2024: histograma frente a la densidad $N(0,1)$ y gráfico QQ.

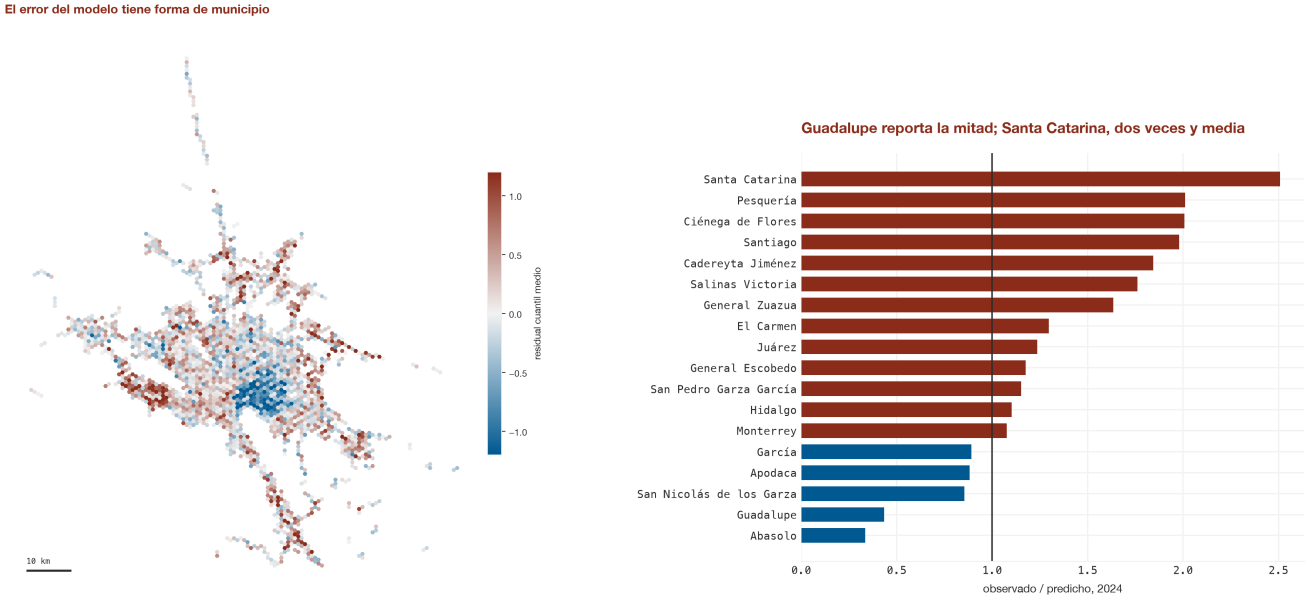


Figura 8: Izquierda: residual cuantil medio por celda en 2024 (NB2). Derecha: cociente entre accidentes observados y predichos por municipio en 2024.

autocorrelación residual no es un proceso espacial fino: son 18 bloques con un nivel propio. Por eso el rezago no ayudó: las vecinas de una celda de Guadalupe también están en Guadalupe y se equivocan en la misma dirección.

Las series anuales por municipio (figura 9) explican el patrón: Santa Catarina pasa de 3 accidentes en 2020 a 2,905 en 2023; Guadalupe alcanza su máximo en plena pandemia y cae a un tercio en 2024; Salinas Victoria alterna 287, 829, 351 y 823. Ninguna dinámica vial produce saltos de esa magnitud: lo que cambia de un año a otro es la práctica de captura de cada municipio. El supuesto de subregistro estable no se sostiene, y esta es la fuente dominante del error de predicción (§5).

4.3. Modelo jerárquico

BYM2 no se identifica La especificación con efecto espacial BYM2 (Riebler et al., 2016) se ajustó en sus dos parametrizaciones y ninguna convergió (cuadro 8). En la no centrada, la fracción espacial colapsa a $\phi \to 0.0001$; en la centrada, $\sigma_s \to 13$ y $\phi \to 0.9998$. Con cinco años de conteos por celda los datos fijan cada u_i casi por completo, y su reparto entre componente espacial e independiente solo lo sostienen los *priors*. La estructura espacial existe —el I de Moran de la tasa por celda, neta de la media municipal, es 0.41—, pero no hay información para dividirla entre dos componentes. El modelo final usa un CAR propio, con una sola varianza y un solo parámetro de dependencia.

Diagnósticos de convergencia El modelo final (cuatro cadenas NUTS con `nutpie`, 3,000 iteraciones de calentamiento y 4,000 muestras por cadena) se ajustó en 12 minutos

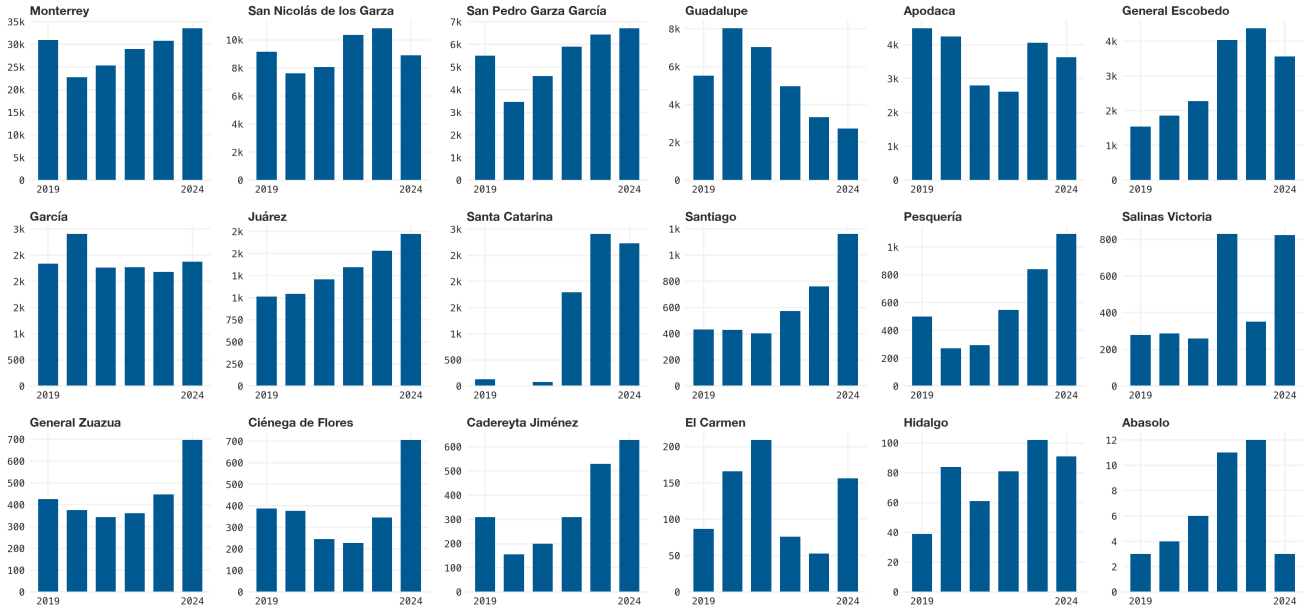


Figura 9: Accidentes registrados por año en cada uno de los 18 municipios de la ZMM, 2019–2024. Cada panel tiene su propia escala vertical.

Tabla 8
Intentos de ajuste de BYM2.

Parametrización	Resultado	$\hat{R}(\phi)$
No centrada	$\phi \to 0.0001$: desaparece la parte espacial	2.06
Centrada	$\phi \to 0.9998$, $\sigma_s \to 13$: desaparece la parte independiente	1.65

Tabla 9
Hiperparámetros a posteriori del modelo jerárquico.

Parámetro	Media	IC 94 %	$\hat{R}$	ESS
α	0.92	[0.89, 0.95]	1.02	219
θ	12.2		1.00	10,692
σ_{rw}	0.29		1.01	259
σ_u	2.61		1.00	2,357

sin divergencias. Sobre las 11,350 cantidades log μ_{ia} —las que el modelo identifica— el $\hat{R}$ máximo (Vehtari et al., 2021) es 1.002 y el tamaño efectivo de muestra mínimo es 4,289. Los hiperparámetros no cumplen todos el umbral de 1.01: σ_u y θ quedan en 1.00 y σ_{rw} en 1.01, pero α, β_0 y σ_m quedan en 1.02, con ESS de 219, 149 y 78. Con la mitad de iteraciones, α daba 1.04; duplicarlas no alcanzó el umbral. β_0 y σ_m comparten información con el nivel medio de $\mathbf{u}$, y α con σ_u cuando la dependencia se acerca a 1. La media de α es estable (0.917 y 0.919 en las dos corridas, 0.921 con priors alternativos), y ninguna conclusión depende de esos parámetros por separado.

Hiperparámetros El cuadro 9 resume la posterior. La dependencia espacial neta del municipio es fuerte ($\alpha = 0.92$). La sobredispersión a escala anual es moderada ($\theta = 12.2$, frente a 5.5 a escala mensual). El municipio típico cambia su nivel de reporte en un factor de $e^{0.29} \approx 1.33$ al año, y dentro de un mismo municipio las celdas difieren en órdenes de magnitud ($\sigma_u = 2.61$). Al reajustar con *priors* alternativos (α uniforme, σ_u con escala doble, θ con media 5 en lugar de 20), θ cambia 0.6 % (12.215 a 12.146) y los otros tres, a lo sumo 0.002: los datos dominan a los priors. El reajuste deja dos transiciones divergentes. Con innovaciones normales en la caminata municipal, σ_{rw} se estimaba en 0.61, inflada por unos pocos saltos; con innovaciones t_3 baja a 0.29.

Trayectorias municipales. Los efectos $m_{j,a}$ reproducen las series observadas (figura 10): el salto de Santa Catarina en 2022, el descenso sostenido de Guadalupe desde 2020 y el pico aislado de Salinas Victoria. El intervalo es angosto en los municipios grandes (Monterrey, San Nicolás de los Garza) y ancho en los pequeños (Abasolo, Ciénega de Flores), como corresponde a la cantidad de información de cada uno.

Perfil espacial neto del municipio. El efecto u_i mide cuánto más o menos riesgo tiene cada celda que el promedio de su municipio, estimado con la información de la celda y la de sus vecinas (figura 11). Es el primer mapa del proyecto que no depende de cuánto reporta cada municipio: cada celda se compara con su propio municipio. Los corredores viales principales aparecen con $u_i > 0$, y las colonias interiores y los bordes de la mancha urbana, con $u_i < 0$.

En las 643 celdas con cinco accidentes o menos en cinco años, el modelo encoge poco la estimación puntual respecto al estimador ingenuo (15 %), pero su incertidumbre es casi

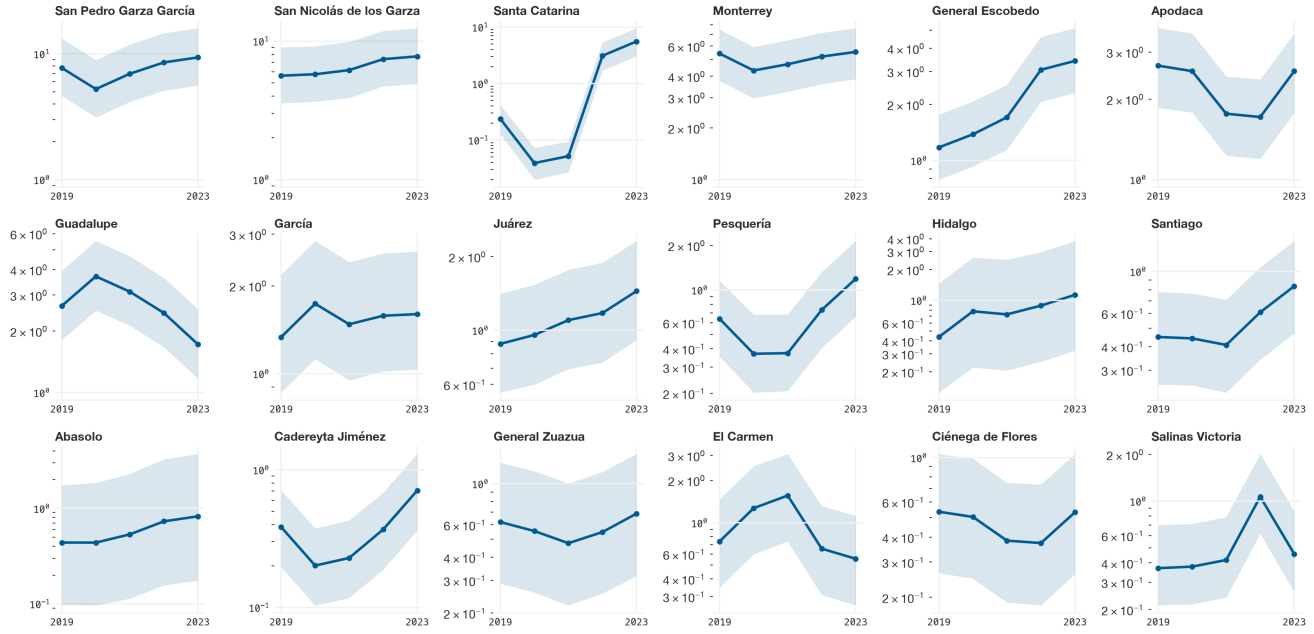


Figura 10: Efecto municipal $e^{m_{j,a}}$ a posteriori, 2019–2023: mediana e intervalo del 90 %, en escala logarítmica. Cada panel es un régimen de reporte.

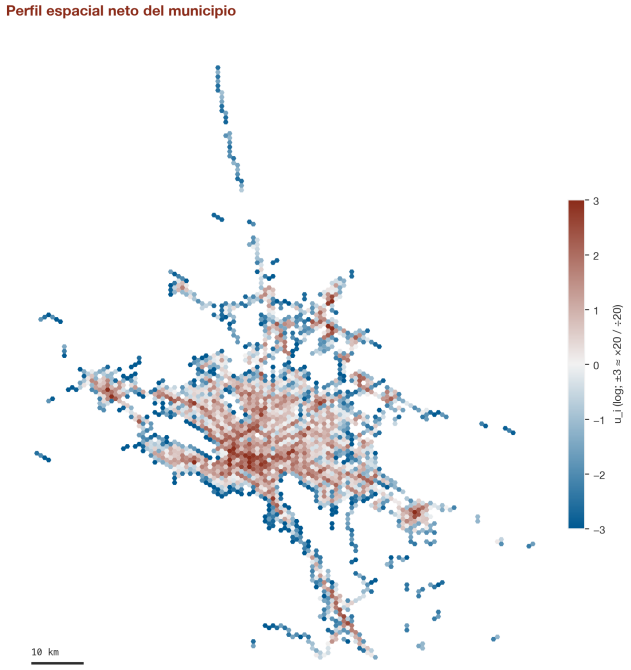


Figura 11: Mediana a posteriori de u_i, riesgo relativo de cada celda respecto a su municipio (escala log; ±3 equivale a un factor de ≈ 20).

el triple que la de las celdas con más de cien accidentes (desviación posterior de 0.79 contra 0.28 en escala log; figura 12). Dos celdas con el mismo u_i y distinta incertidumbre no justifican la misma intervención.

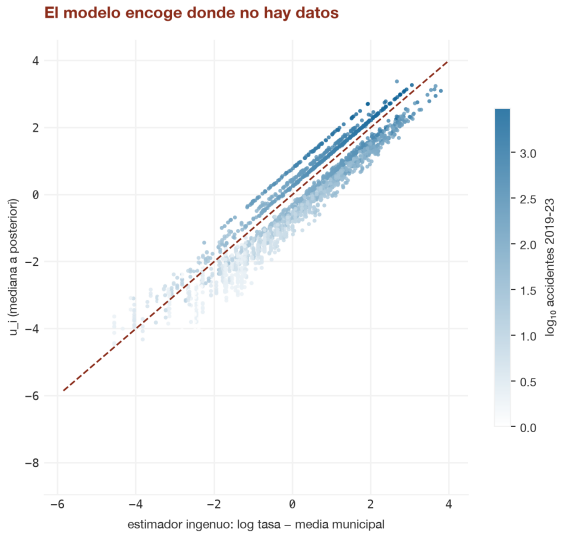


Figura 12: Estimador ingenuo (log tasa menos media municipal) contra la mediana a posteriori de u_i. El color indica los accidentes de cada celda en entrenamiento; las celdas con pocos datos se encogen hacia su municipio y sus vecinas.

4.4. Validación en 2024

El pronóstico del modelo jerárquico se obtiene por simulación: para cada muestra posterior se toma el nivel municipal de 2023, se combina con u_i y se simula un conteo Binomial Negativo. Es, por tanto, un pronóstico por persistencia del régimen municipal (§3.5). Los *baselines* se recalculan a escala celda×año para que la comparación sea directa (cuadro 10).

Tabla 10
Validación en 2024 a escala celda×año. M6 es el modelo jerárquico con CAR y efecto municipal.

Modelo	MAE	CRPS	Cob. 90 %	PAI
M0	9.49	7.96	64 %	8.44
M0r	8.06	6.49	69 %	8.42
M4	8.07	6.85	**90 %**	8.42
M6	8.10	**6.10**	87 %	8.44

- **Calibración del total.** El jerárquico predice 70,810 accidentes para 2024 contra 71,295 observados: un error del 0.7 %.
- **Media.** Empata con M0r en MAE (8.10 contra 8.06). Lo predecible de 2024 es el nivel reciente de cada municipio debido al perfil estable de cada celda, y un promedio bien elegido ya captura esa media.
- **Distribución.** Mejora el CRPS (Gneiting & Raftery, 2007) del mejor *baseline* en un 6 % (6.10 contra 6.49). El intervalo del 90 % de M0r cubre solo el 69 % de las celdas, porque supone un Poisson sin sobredispersión ni régimen; el del jerárquico cubre el 87 %, cerca de su nivel nominal, aun sin incorporar el riesgo de cambio de régimen. M4 cubre el 90 % a costa de un CRPS peor (6.85): sus intervalos son más anchos de lo necesario.
- **Selección de zonas.** El PAI al 5 % es 8.44, el mismo que el del histórico. El *shrinkage* reordena la cola de la distribución de celdas, no la cabeza, que es donde se decide la selección.

Dos variantes se evaluaron y descartaron. La primera pronosticaba 2024 con una innovación t_3 adicional en el nivel municipal; como $\mathbb{E}[e^T] = \infty$ para cualquier t de Student, la media predictiva no existe, y numéricamente la suma de medias dio 2.8 millones de accidentes contra 71 mil observados, con valores que cambiaban con la semilla. La segunda añadía una deriva por municipio para capturar el crecimiento periférico: la posterior la encogió a cero ($\sigma_d = 0.07$), produjo 46 divergencias y no mejoró el CRPS. Con cinco años y saltos de régimen, los datos no distinguen una tendencia de una racha de innovaciones.

El PAI al 5 % se mantuvo en 8.4 en todos los modelos, desde el conteo histórico hasta el jerárquico: el *dónde* lo determina el historial de cada celda. Lo que el modelo jerárquico añade es una distribución predictiva calibrada y un perfil espacial neto del régimen de reporte municipal.

5. Discusión

Los resultados de la sección 4 cuentan dos historias que conviene separar. Una es espacial y es robusta: la siniestralidad registrada en la ZMM se concentra en corredores, la estructura persiste entre años y sobrevive a la escala y a la corrección por pruebas múltiples. La otra es temporal y es administrativa: el nivel de cada municipio cambia de un año a otro por razones que no tienen que ver con el tránsito.

5.1. El régimen de reporte municipal como fuente principal de error

El supuesto implícito de cualquier modelo de conteos sobre registros administrativos es que el subregistro existe pero es estable: si un municipio captura la mitad de sus accidentes, los captura así todos los años, y el sesgo se absorbe en el intercepto. La literatura vial documenta que el subregistro es la norma y no la excepción, y que su nivel varía con la severidad y con el país (Elvik & Mysen, 1999). Lo que esta base muestra es que en la ZMM tampoco es estable en el tiempo. Santa Catarina pasa de 3 registros en 2020 a cerca de tres mil en 2023; Guadalupe alcanza su máximo en plena pandemia y cae a un tercio en 2024; Salinas Victoria alterna entre dos niveles año con año. Ninguna dinámica vial produce saltos de ese tamaño en un solo periodo: lo que cambia es la práctica de captura.

Tres resultados independientes apuntan a la misma causa. Primero, el residual de la Binomial Negativa tiene forma de municipio: su I de Moran cae de 0.30 a 0.06 al quitar la media municipal (sección 4.2), de modo que lo que parecía un proceso espacial fino que faltaba modelar eran 18 bloques con un nivel distinto cada uno. Eso explica también por qué el rezago espacial no aportó nada: las vecinas de una celda comparten municipio y se equivocan en la misma dirección. Segundo, el exceso de ceros sobre la Binomial Negativa se concentra en unos pocos pares municipio×periodo, con Santa Catarina antes de 2022 a la cabeza; son celdas cuyo municipio no reportaba, no celdas sin riesgo. Lord et al. (2005) advierten que la inflación de ceros en datos de accidentes suele ser un artefacto de subregistro o de una unidad de análisis mal elegida y no un segundo proceso generador; aquí el diagnóstico es explícito. Tercero, dos años recientes de historia predicen 2024 mejor que cinco, lo que solo tiene sentido si los años viejos describen un régimen de reporte que ya no rige.

La consecuencia de diseño fue convertir el diagnóstico en estructura: el modelo jerárquico separa un efecto municipal dinámico $m_{j,a}$, que absorbe *cuánto se reporta*, de un efecto espacial u_i por celda, que absorbe *dónde, dentro del municipio, se concentra*. La separación tiene un precio que hay que declarar: $m_{j,a}$ no es siniestralidad. Es la mezcla inseparable de riesgo real y de intensidad de captura, y con esta base no hay forma de repartirla. Lo que sí se gana es que u_i queda neto del régimen: es el primer producto del proyecto que compara a Guadalupe con Guadalupe.

La misma lógica pone un techo al pronóstico. El régimen de 2024 no está en los datos de 2019–2023, y ningún modelo entrenado con el pasado puede anticipar que un municipio empiece o deje de reportar. El pronóstico del jerárquico es por persistencia —toma el nivel municipal de 2023— y sus intervalos son, por construcción, un piso de la incertidumbre real: no incluyen el riesgo de cambio de régimen. La alternativa natural, propagar una innovación t_3 más, no está disponible: $\mathbb{E}[e^T] = \infty$ para cualquier t

de Student, y la media predictiva y el CRPS dejarían de existir. Que el jerárquico cubra el 87 % con un intervalo nominal del 90 % aun sin ese término indica que el resto de la incertidumbre está bien representada; el faltante es precisamente el régimen.

5.2. Lo que la base puede y no puede decir

La distinción anterior permite delimitar con precisión el alcance de los resultados.

Lo que puede decir. Dónde se concentra el *reporte* de accidentes, con qué estructura espacial y con qué persistencia. El índice de Gini, el I de Moran y los mapas locales con FDR coinciden a 250, 500 y 1 000 m de lado, lo que descarta que la estructura sea un artefacto de la rejilla (Openshaw, 1984). El ranking de celdas de 2019 correlaciona 0.83 con el de 2024, con una pandemia de por medio. Y, dentro de cada municipio, la base sostiene un perfil de riesgo relativo u_i con la incertidumbre que corresponde a cada celda: las celdas con pocos accidentes no se encogen mucho en su estimación puntual, pero su intervalo es casi tres veces más ancho que el de las celdas con más de cien, y esa diferencia es información para decidir.

Lo que no puede decir. Primero, no distingue un municipio donde bajó el riesgo de uno que dejó de capturar accidentes; quien use $m_{j,a}$ o las series municipales como indicador de seguridad vial tiene que resolver esa ambigüedad por fuera, con otra fuente. Segundo, no anticipa cambios de régimen. Tercero, no dice *por qué* una celda es riesgosa: sin exposición (tránsito, kilómetros de vialidad) un corredor con muchos accidentes puede ser un corredor peligroso o un corredor transitado. La exposición es la covariable central de los modelos de frecuencia de accidentes (Lord & Mannering, 2010); sin ella, lo que aquí se estima es frecuencia y no tasa. Cuarto, no permite inferencia causal sobre intervenciones: todas las covariables son estructurales y ninguna es manipulable.

El PAI como síntesis. El índice de precisión predictiva al 5 % vale 8.4 en todos los modelos, desde el conteo histórico hasta el jerárquico. Es la expresión cuantitativa de los dos párrafos anteriores. El *dónde* lo decide el historial, que es lo que la base mide bien; las mejoras del jerárquico están en el *cuánto* y en el *con qué certeza* (CRPS 6.10 contra 6.49), que es donde el régimen pesa. El PAI es la métrica habitual para juzgar mapas de puntos calientes (Chainey et al., 2008), y moverlo exige covariables que varíen por celda y que el historial no contenga, y esas no están en ATUS.

5.3. Limitaciones

Geocodificación por intersección. La coordenada se comporta como la de la intersección reportada y no como la del punto físico del choque: 98.2 % de las 118,626 coordenadas exactas de intersección con dos vialidades corresponde a un solo par de calles (§2.2). El procedimiento del INEGI no está documentado en el repositorio. La rejilla de 500 m tolera ese error de posición, pero un análisis a escala de cuadra o de tramo hereda un dato discreto sobre 54,742 nodos a 10 m de tolerancia, no un patrón de puntos continuo.

Cambio de procedimiento en 2022. La matriz de Spearman entre años tiene dos bloques, 2019–2021 y 2022–2024, que coinciden con la aparición del campo `OID` en los archivos del INEGI. La precisión decimal de las coordenadas, en cambio, cambia desde 2021. Las dos señales no fechan lo mismo: la precisión afecta la posición del punto, y el indicador de periodo controla el volumen. Con el corte en 2021, la NB2 empeora el AIC en 798 puntos y el CRPS de 2024 de 0.876 a 0.883; un nivel propio para 2021 mejora el AIC en 35 puntos sin mover el CRPS ni el PAI. El indicador conserva el corte de 2022. La hipótesis más económica es un cambio en el procedimiento de georreferenciación, que no se pudo verificar con documentación de la fuente; si la causa fuera otra, la lectura de la discontinuidad cambiaría, aunque no la del régimen municipal, que opera sobre el volumen y no sobre la posición.

Faltantes no aleatorios. Los campos con códigos centinela se tratan como MNAR por supuesto de trabajo. En accidentes fatales el aliento alcohólico se ignora 2.4 veces más seguido (sección 2.2): esa dependencia con la gravedad descarta MCAR, pero no distingue MAR de MNAR, porque el valor ausente no se observa. El modelo de conteo no usa esos campos, así que no lo afecta; cualquier modelo de severidad futuro tendrá que tratarlos explícitamente.

Una sola ventana de validación. La validación fuera de muestra se hizo en un solo año, 2024. Es la única prueba honesta disponible —un jerárquico con 2,270 efectos de celda ajusta el pasado casi a la perfección—, pero un solo año no permite estimar la variabilidad de las métricas entre ventanas, y 2024 pudo ser un año con más o menos cambios de régimen que el típico.

Escala anual. El jerárquico se ajusta sobre celda×año. La separabilidad espacio-tiempo es un supuesto no contrastado: el modelo impone un efecto de mes común a todas las celdas, que aportó poco en los GLM, sin probar una interacción celda×mes. El modelo no informa sobre estacionalidad local ni sobre horarios.

Cobertura territorial. Se retiraron las celdas sin accidentes en 6 años y las 74 celdas isla. La decisión se justifica porque una celda vacía en 379 mil registros no tiene red vial, pero implica que el modelo no predice para territorio donde la urbanización todavía no llega, que es donde crece la periferia.

5.4. Caminos que no funcionaron

Se documentan porque cada uno descarta una explicación y porque, sin el registro, alguien volvería a intentarlos.

BYM2. La especificación original del nivel de celda era BYM2 (Riebler et al., 2016), que separa un componente espacial ICAR de uno independiente y hace interpretable la

fracción espacial ϕ. No se identificó en ninguna de sus dos parametrizaciones: la no centrada llevó ϕ a 0 y la centrada a 1, con $\hat{R}$ de 2.06 y 1.65. El motivo es de estructura y no de ajuste fino del muestreador. Con 5 años de conteos por celda los datos fijan cada u_i casi por completo, y el reparto entre "espacial" e "independiente" solo lo sostienen los priors. La estructura espacial existe —el Moran de la tasa por celda neta del municipio es 0.41—; lo que falta es información para descomponerla. El CAR propio, con una sola varianza y un solo α, se identifica sin problema. La lección es general: BYM2 está pensado para mapeo de enfermedades con conteos escasos por área, y pierde su ventaja cuando cada área tiene información de sobra.

Rezago espacial en el GLM. Incluir el promedio de las vecinas como covariable, con un Moran de 0.65 en los conteos, parecía obvio. Su coeficiente fue -0.002 ($t = -0.5$). Fue el primer indicio de que el residual no era espacial fino sino municipal (sección 5.1).

Inflación de ceros. El ZINB con inflación constante mejora el AIC, pero reparte la probabilidad de cero estructural entre todas las celdas por igual, cuando el exceso está concentrado en unos pocos municipios y periodos. Ganar AIC con un mecanismo equivocado no es mejorar el modelo; el fenómeno se modeló donde ocurre, en el nivel municipal.

Innovaciones normales. Con una caminata aleatoria normal para el municipio, σ_{rw} salió en 0.61: inflada por los pocos municipios que saltan, y por tanto demasiado ancha para los que apenas se mueven. Con innovaciones t_3 bajó a 0.29, que describe al municipio típico, y los saltos quedan en las colas.

Deriva municipal. Una tendencia local por municipio, pensada para capturar el crecimiento de la periferia, se encogió a cero ($\sigma_d = 0.07$), introdujo 46 divergencias y no mejoró el CRPS. Con cinco años y cambios de régimen, los datos no distinguen una tendencia de una racha de innovaciones.

Ventanas de historia por AIC. Cuando el GLM recibe la historia completa y la reciente, elige la completa, porque en entrenamiento explica mejor 2019–2021 al incluirlos; fuera de muestra pierde. Es la razón por la que ninguna comparación del proyecto se hace con criterios de información sobre el periodo de ajuste, sino con la validación en 2024.

Lo que no se intentó. La función K de Ripley y la densidad kernel en su versión plana suponen que un accidente puede ocurrir en cualquier punto del plano; aquí solo puede ocurrir sobre la red vial, y el nulo plano sobreestimaría el agrupamiento. Las versiones restringidas a red (Okabe & Yamada, 2001) exigen la geometría de las calles, que el proyecto no tiene. Habrían confirmado algo ya establecido —que hay agrupamiento y a qué escalas—, así que se pospusieron hasta tener la red vial, que es también la covariable de exposición que falta (sección 6).

6. Conclusiones y trabajo futuro

A. Supuestos del modelo jerárquico y su verificación

La tabla 11 confronta los 13 supuestos del modelo de la ecuación (6) (M6) con la evidencia disponible: uno queda verificado, siete tienen evidencia parcial, cuatro carecen de contraste y uno no se cumple. *Parcial* significa que la evidencia es indirecta o cubre solo una parte del supuesto; *sin contraste*, que no se ejecutó ninguna prueba. Las cifras de M6 son salidas de `docs/modelo_jerarquico.pdf`, el render de `notebooks/modelo_jerarquico.qmd`; el modelo no se reajustó para este apéndice. La fila de la pertenencia municipal es un cálculo directo sobre `espacial.celdas()` y `atus_zmm_limpio_geo.parquet`, ausente de los *notebooks*.

Grafo de vecindad. Una versión anterior de `espacial.rejilla_hexagonal` calculaba los vértices de cada hexágono por separado, con senos y cosenos, y los vértices compartidos diferían en unos 4.7×10^{-10} m. `weights.Queen` solo une polígonos con coordenadas idénticas, así que el grafo perdía 1,085 de 5,284 aristas (20.5 %), quedaba en 120 componentes y contaba como islas a 29 celdas que sí tenían una vecina con accidentes. Las aserciones de simetría y ausencia de islas no lo detectaban. La rejilla actual calcula los vértices sobre una retícula entera, de modo que dos hexágonos vecinos llegan a los mismos flotantes, y `espacial.celdas()` contrasta el número de aristas con los pares de centroides a distancia $\sqrt{3}\,\ell$, un criterio independiente de la geometría de los polígonos. Con la corrección, la partición pasa de 2,241 a 2,270 celdas (74 islas en lugar de 103) y el I de Moran global de 0.648 a 0.654. Con el mismo muestreo de 1,000 + 2,000 iteraciones, α pasa de 0.848 a 0.917, σ_u de 2.38 a 2.61 y el CRPS de M6 de 6.166 a 6.093.

El grafo corregido sigue sin ser conexo: 35 componentes, y la mayor reúne el 93.7 % de las celdas. El modelo está bien definido, porque toda celda conserva al menos una vecina y $D - \alpha A$ es definida positiva para $\alpha < 1$ aunque el grafo esté desconexo. El encogimiento hacia las vecinas, en cambio, solo opera dentro de cada componente.

Convergencia. §3.4 exige el umbral a $\log \mu$ y lo reporta sin exigirlo en los hiperparámetros. α, β_0 y σ_m quedan en $\hat{R} = 1.02$ con 3,000 iteraciones de calentamiento y 4,000 muestras por cadena; con la mitad, α daba 1.04. La mezcla lenta de α es estructural: cerca de $\alpha = 1$ el CAR propio confunde la dependencia con σ_u. Su media es estable entre corridas y priors (0.917–0.921). El *notebook* no calcula $\hat{R}$ para $m_{j,a}$ ni para u_i por separado: la convergencia de $\log \mu$ cubre su suma con β_0, y la lectura individual de ambos efectos depende de que la mezcla lenta de β_0 no se traslade a ellos.

Alcance de la evidencia. La separabilidad y la exogeneidad figuran como verificadas en la tabla de supuestos del *notebook*, pero la evidencia citada allí mide otra cosa: la correlación de Spearman mide estabilidad entre años,

Tabla 11
Supuestos del modelo jerárquico, verificación aplicada, resultado y estado. Las desviaciones posteriores (d. p.), $\hat{R}$ y el tamaño efectivo de muestra (ESS) provienen de ArviZ; `az.summary` redondea $\hat{R}$ a dos decimales.

Supuesto	Verificación	Resultado	Estado
Verosimilitud NB con θ común, sin inflación de ceros	Poisson, NB2 y ZINB se compararon solo en el GLM celdaxmes (§4.2). En M6 hay cobertura y CRPS en 2024, sin rootograma, residuales cuantil ni conteo de ceros esperados	$\theta = 12.2$ (d. p. 0.447); cobertura del intervalo del 90 %: 87.2 %; 25.8 % de ceros en el panel de entrenamiento, sin esperado que comparar	Parcial
Independencia condicional de Y_{ia} dado μ_{ia}	Sin contraste: el I de Moran del residual se calculó para NB2, no para M6	NB2 en 2024: 0.303, y 0.056 sin la media municipal; M6: no calculado	Sin contraste
Separabilidad espacio–tiempo dentro del año	Sin contraste: no hay prueba de interacción celdaxmes. Todos los GLM imponen un efecto de mes común, y la correlación entre años no mide la forma intraanual	—	Sin contraste
u_i constante en 2019–2023	Spearman entre los conteos por celda de cada par de años (§4.1). M6 no tiene indicador de periodo	0.833 entre 2019 y 2024; 0.863–0.896 dentro de 2019–2021, 0.884–0.906 dentro de 2022–2024 y 0.800–0.839 entre bloques: el corte de 2022 queda sin modelar en u_i	Parcial
Caminata aleatoria de $m_{j,a}$	Trayectorias a posteriori frente a las series observadas (figura 10): comparación visual, dentro de muestra y sin estadístico	Reproducen los saltos de los municipios con cambio de régimen, a los que se ajustaron	Parcial
Innovaciones t_3	σ_{rw} con t_3 frente a innovaciones normales. $\nu = 3$ se fijó y no se estimó; la variante normal no tiene código en el `.qmd`	0.289 (d. p. 0.036) con t_3 y 0.61 con normales, esta sin intervalo	Parcial
Persistencia $m_{j,2024} = m_{j,2023}$	Observado frente a predicho en 2024, en total y por municipio (§4.4)	Total: 71,295 contra 70,810 (cociente predicho/observado 0.993). Por municipio, observado/predicho de 0.30 (Abasolo) a 2.56 (El Carmen): el total acierta porque errores de signo opuesto se compensan (§5.1)	No se cumple
Grafo de vecindad completo	`espacial.celdas()` falla si las aristas de A no coinciden con los pares de centroides a distancia $\sqrt{3}\ell$; el *notebook* cuenta las componentes conexas	5,325 aristas, 4.69 vecinas por celda. No conexo: 35 componentes, la mayor con 2,126 celdas (93.7 %). Ver el párrafo *Grafo de vecindad*	Verificado
Cada celda pertenece a un solo municipio (el modal)	Sin contraste en el *notebook*. Cálculo directo: accidentes fuera del municipio modal de su celda	10,559 de 379,160 accidentes (2.8 %) caen fuera; 430 de 2,270 celdas (18.9 %) tienen más de un municipio	Parcial
Exogeneidad de u_i respecto al municipio	Sin contraste: el *notebook* cita la construcción (CAR centrado en cero), que no es una prueba, y β_0 compite con la media de $\mathbf{u}$	—	Sin contraste
$m_{j,a}$ mide reporte y no riesgo	No contrastable con ATUS, sin una fuente externa de exposición o de siniestralidad (§5.1)	—	Sin contraste
Convergencia del MCMC	$\hat{R} < 1.01$, ESS mínimo de 400 y cero divergencias en $\log \mu$ (§3.4); en los hiperparámetros se reportan sin umbral	Cero divergencias. Cumplen $\log \mu$ ($\hat{R}$ máx. 1.002, ESS mín. 4,289), σ_u y θ ($\hat{R}$ 1.00) y σ_{rw} (1.01, ESS 259). Quedan en 1.02 α (ESS 219), β_0 (ESS 149) y σ_m (ESS 78)	Parcial
Los priors no dictan el resultado	Reajuste con priors alternativos en α, σ_u y θ (tabla 5), 1,000 muestras por cadena. Sin alternativa para β_0, σ_m ni σ_{rw}	α 0.919→0.921; θ 12.215→12.146; σ_{rw} 0.289→0.287; σ_u 2.606 sin cambio; CRPS 6.097→6.101; PAI 8.439 sin cambio. Dos divergencias; $\hat{R}$ máx. de $\log \mu$ 1.009	Parcial

no forma dentro del año, y un CAR centrado en cero es una elección del modelo, no un resultado. La afirmación de que u_i queda neto del municipio (§5.1) está condicionada a ambos supuestos y a que $m_{j,a}$ absorba todo el nivel. La validación en 2024 sostiene la distribución predictiva en conjunto (§4.4), en una sola ventana (§5.3), y no permite atribuir el acierto a un supuesto concreto.

B. Reproducibilidad

El entorno se reconstruye con `uv sync` desde `uv.lock`, que fija 115 paquetes, y los datos, con los comandos de `[project.scripts]` en `pyproject.toml` (tabla 12). Cada comando depende de la salida del anterior. `consolidar-atus` exige las descargas del INEGI en `data/raw/` (∼5 GB), fuera de git y de solo lectura; `atus_georreferenciado` y `atus_zmm`, con sus versiones GeoParquet, están versionados, de modo que un clon parte de `uv run limpiar-atus -geo`, único paso obligatorio para los *notebooks*. Los archivos `*_limpio*` no se versionan.

Notebooks. Los análisis son archivos Quarto (`.qmd`) en `notebooks/`, y ninguno lee la salida de otro, de modo que el orden de ejecución entre ellos no importa (tabla 13). El `.qmd` no guarda salidas: las cifras del reporte se contrastan con el PDF de `docs/`, que se produce con

```
PYTHONPATH=$PWD/src \
QUARTO_PYTHON=.venv/bin/python \
quarto render notebooks/<nombre>.qmd \
  --to html --execute-daemon-restart
chrome --headless --no-pdf-header-footer \
  --print-to-pdf=docs/<nombre>.pdf \
  notebooks/<nombre>.html
```

Tabla 12
Comandos del *pipeline*. Los archivos de salida están en `data/processed/`, salvo el indicado.

Comando	Entrada	Salida
`uv sync`	`uv.lock`	Entorno virtual `.venv/`
`uv run consolidar-atus [-geo]`	`data/raw/ATUS_20XX/*.csv`	`atus_georreferenciado.parquet` y, con `-geo`, `atus_georreferenciado_geo.parquet`
`uv run consolidar-atus -verificar`	`.shp` y `.csv` de `data/raw/`	Contraste por año en pantalla; no escribe archivos
`uv run zona-atus [-geo]`	`atus_georreferenciado.parquet`	`atus_zmm.parquet` y, con `-geo`, `atus_zmm_geo.parquet`
`uv run limpiar-atus [-geo]`	`atus_zmm.parquet`	`atus_zmm_limpio.parquet` y, con `-geo`, `atus_zmm_limpio_geo.parquet`
`uv run tabla-cruces`	`atus_zmm_limpio.parquet`	`docs/cruces_zmm.xlsx`

Tabla 13
Notebooks, insumo, sección del reporte que alimentan y semillas. Sin semilla significa que el código no usa generadores aleatorios.

Notebook	Insumo	Sección	Semillas
`calidad_datos`	`atus_zmm.parquet`	§2.2	Sin semilla
`analisis_espacial`	`atus_zmm_limpio_geo`	§4.1	42: `np.random.seed` (estado global, I de Moran con 999 y 199 permutaciones) y `seed` de `Moran_Local` y `G_Local`
`modelo_conteo`	`atus_zmm_limpio_geo`	§4.2	42: `default_rng` (residuales cuantil). Los `Moran` con 999 permutaciones usan `np.random` sin semilla
`modelo_jerarquico`	`atus_zmm_limpio_geo`	§4.3, §4.4	42 (`SEMILLA`): `default_rng` (simulación predictiva) y `random_seed` de `pm.sample`
`pronostico_2027`	`atus_zmm_limpio_geo`	No citado	42 (`SEMILLA`): `default_rng` y `random_seed` de `pm.sample`. Escribe `pronostico_2027_geo.parquet`
`analisis_multivariado`	`atus_zmm_limpio`	No citado	20260915: `default_rng` (submuestras) y `random_state` de la muestra de Kendall; 7: datos de control de normalidad; 0: `FactorAnalysis`
`patrones_espaciales`	`atus_zmm_limpio`	No citado	0: `KMeans`; 1, 7 y 42: estabilidad de la partición
`cruces_peatones`	`atus_zmm_limpio` y descargas por red	No citado	Sin semilla

El reporte se compila desde `docs/reporte/` con `latexmk -pdf main.tex`, y requiere `biber`. `notebooks/calidad_datos.ipynb`, `notebooks/revisiones.ipynb` y `notebooks/mapa_calor.py` no producen cifras de este reporte.

Versiones de software. La tabla 14 lista las versiones de `uv.lock`. El modelo se escribió en PyMC (Abril-Pla et al., 2023) y se muestreó con `nutpie`; `esda` y `libpysal` calculan los estadísticos espaciales y la contigüidad (Rey & Anselin, 2007; Rey et al., 2022). `arviz` es dependencia indirecta, a través de PyMC. Python se fija en 3.14 (`.python-version`, `requires-python = ">=3.14"`), sin fijar el parche. El repositorio no fija las versiones de Quarto, de la distribución de LaTeX ni de Chrome, ni la de `uv`; solo acota el empaquetador `uv_build` a `>=0.12.7,<0.13.0`.

Semillas. No hay una semilla global: `src/` no usa generadores aleatorios, y cada *notebook* fija las suyas (tabla 13). La de los tres *notebooks* de modelos y del análisis espacial es 42. En `modelo_jerarquico` el generador `rng` se consume en orden, así que los resultados de la simulación dependen de ejecutar las celdas en secuencia.

Tabla 14
Versiones fijadas en `uv.lock`.

Paquete	Versión	Paquete	Versión
`pymc`	6.3.2	`geopandas`	1.1.4
`pytensor`	3.3.2	`shapely`	2.1.2
`nutpie`	0.16.11	`pyproj`	3.7.2
`arviz`	1.3.0	`libpysal`	4.15.0
`numpy`	2.5.2	`esda`	2.10.0
`pandas`	3.0.5	`statsmodels`	0.15.0
`scipy`	1.18.1	`scikit-learn`	1.9.1
`matplotlib`	3.11.1	`pyarrow`	25.0.1

Límites de la reproducción. Primero, cuatro resultados de `modelo_jerarquico.qmd` constan solo en su prosa, sin celda que los produzca: los ajustes de BYM2 ($\hat{R}$ de 2.06 y 1.65), las innovaciones normales ($\sigma_{rw} = 0.61$), la deriva municipal ($\sigma_d = 0.07$, 46 divergencias) y el I de Moran de 0.41 neto del municipio. Segundo, en `modelo_conteo.qmd` los valores z de Moran dependen de permutaciones sin semilla; el estadístico I no. Dos ejecuciones completas de `modelo_jerarquico` y de `pronostico_2027` en la misma máquina, con semilla 42, dieron salidas idénticas salvo el tiempo de cómputo. La

igualdad entre máquinas o versiones no se comprobó: las semillas fijan el flujo aleatorio, no la aritmética de punto flotante de cada plataforma.

Referencias

Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C. J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C. C., Martin, O. A., Osthege, M., Vieira, R., Wiecki, T., & Zinkov, R. (2023). PyMC: a modern, and comprehensive probabilistic programming framework in Python. *PeerJ Computer Science*, *9*, e1516. https://doi.org/10.7717/peerj-cs.1516

Anselin, L. (1995). Local indicators of spatial association—LISA. *Geographical Analysis*, *27*(2), 93-115. https://doi.org/10.1111/j.1538-4632.1995.tb00338.x

Banerjee, S., Carlin, B. P., & Gelfand, A. E. (2014). *Hierarchical Modeling and Analysis for Spatial Data* (2.ª ed.). Chapman; Hall/CRC. https://doi.org/10.1201/b17115

Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, *57*(1), 289-300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x

Besag, J. (1974). Spatial interaction and the statistical analysis of lattice systems. *Journal of the Royal Statistical Society: Series B (Methodological)*, *36*(2), 192-225. https://doi.org/10.1111/j.2517-6161.1974.tb00999.x

Besag, J., York, J., & Mollié, A. (1991). Bayesian image restoration, with two applications in spatial statistics. *Annals of the Institute of Statistical Mathematics*, *43*(1), 1-20. https://doi.org/10.1007/BF00116466

Birch, C. P. D., Oom, S. P., & Beecham, J. A. (2007). Rectangular and hexagonal grids used for observation, experiment and simulation in ecology. *Ecological Modelling*, *206*(3–4), 347-359. https://doi.org/10.1016/j.ecolmodel.2007.03.041

Cameron, A. C., & Trivedi, P. K. (1990). Regression-based tests for overdispersion in the Poisson model. *Journal of Econometrics*, *46*(3), 347-364. https://doi.org/10.1016/0304-4076(90)90014-K

Chainey, S., Tompson, L., & Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, *21*(1–2), 4-28. https://doi.org/10.1057/palgrave.sj.8350066

Dunn, P. K., & Smyth, G. K. (1996). Randomized quantile residuals. *Journal of Computational and Graphical Statistics*, *5*(3), 236-244. https://doi.org/10.1080/10618600.1996.10474708

Elvik, R., & Mysen, A. B. (1999). Incomplete accident reporting: meta-analysis of studies made in 13 countries. *Transportation Research Record*, *1665*(1), 133-140. https://doi.org/10.3141/1665-18

Getis, A., & Ord, J. K. (1992). The analysis of spatial association by use of distance statistics. *Geographical Analysis*, *24*(3), 189-206. https://doi.org/10.1111/j.1538-4632.1992.tb00261.x

Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, *102*(477), 359-378. https://doi.org/10.1198/016214506000001437

Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn sampler: adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, *15*(47), 1593-1623.

Instituto Nacional de Estadística y Geografía. (2025). *Accidentes de tránsito terrestre en zonas urbanas y suburbanas (ATUS)*. https://www.inegi.org.mx/programas/accidentes/

Kleiber, C., & Zeileis, A. (2016). Visualizing count data regressions using rootograms. *The American Statistician*, *70*(3), 296-303. https://doi.org/10.1080/00031305.2016.1173590

Lambert, D. (1992). Zero-inflated Poisson regression, with an application to defects in manufacturing. *Technometrics*, *34*(1), 1-14. https://doi.org/10.2307/1269547

Lord, D., & Mannering, F. (2010). The statistical analysis of crash-frequency data: a review and assessment of methodological alternatives. *Transportation Research Part A: Policy and Practice*, *44*(5), 291-305. https://doi.org/10.1016/j.tra.2010.02.001

Lord, D., Washington, S. P., & Ivan, J. N. (2005). Poisson, Poisson-gamma and zero-inflated regression models of motor vehicle crashes: balancing statistical fit and theory. *Accident Analysis & Prevention*, *37*(1), 35-46. https://doi.org/10.1016/j.aap.2004.02.004

Moran, P. A. P. (1950). Notes on continuous stochastic phenomena. *Biometrika*, *37*(1/2), 17-23. https://doi.org/10.2307/2332142

Okabe, A., & Sugihara, K. (2012). *Spatial Analysis Along Networks: Statistical and Computational Methods*. John Wiley & Sons. https://doi.org/10.1002/9781119967101

Okabe, A., & Yamada, I. (2001). The K-function method on a network and its computational implementation. *Geographical Analysis*, *33*(3), 271-290. https://doi.org/10.1111/j.1538-4632.2001.tb00448.x

Openshaw, S. (1984). *The Modifiable Areal Unit Problem*. Geo Books.

Ord, J. K., & Getis, A. (1995). Local spatial autocorrelation statistics: distributional issues and an application. *Geographical Analysis*, *27*(4), 286-306. https://doi.org/10.1111/j.1538-4632.1995.tb00912.x

Rey, S. J., & Anselin, L. (2007). PySAL: a Python library of spatial analytical methods. *Review of Regional Studies*, *37*(1), 5-27. https://doi.org/10.52324/001c.8285

Rey, S. J., Anselin, L., Amaral, P., Arribas-Bel, D., Cortes, R. X., Gaboardi, J. D., Kang, W., Knaap, E., Li, Z., Lumnitz, S., Oshan, T. M., Shao, H., & Wolf, L. J. (2022). The PySAL ecosystem: philosophy and implementation. *Geographical Analysis*, *54*(3), 467-487. https://doi.org/10.1111/gean.12276

Riebler, A., Sørbye, S. H., Simpson, D., & Rue, H. (2016). An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, *25*(4), 1145-1165. https://doi.org/10.1177/0962280216660421

Rubin, D. B. (1976). Inference and missing data. *Biometrika*, *63*(3), 581-592. https://doi.org/10.1093/biomet/63.3.581

Secretaría de Desarrollo Agrario, Territorial y Urbano & Consejo Nacional de Población. (2018). *Sistema Urbano Nacional 2018* (inf. téc.). SEDATU y CONAPO. Ciudad de México.

Self, S. G., & Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, *82*(398), 605-610. https://doi.org/10.1080/01621459.1987.10478472

Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: an improved $\widehat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, *16*(2), 667-718. https://doi.org/10.1214/20-BA1221