Predicción espacial de accidentes de tránsito en la Zona Metropolitana de Monterrey

Eduardo Luna[a]

[a]*Tecnológico de Monterrey, Monterrey, Nuevo León, México*

INFORMACIÓN

Palabras clave:
accidentes de tránsito
geoestadística
modelo jerárquico bayesiano
INAR
Monterrey

RESUMEN

1. Introducción
2. Datos
2.1. Fuente y recorte a la ZMM
2.2. Calidad y propiedades de la base
2.3. Selección de variables
3. Metodología
3.1. Unidad espacial
3.2. Análisis espacial exploratorio
3.3. Modelos de conteo
3.4. Modelo jerárquico bayesiano
3.5. Validación fuera de muestra
4. Resultados
4.1. Estructura espacial de la siniestralidad
4.2. Modelos de conteo
4.3. Modelo jerárquico
4.4. Validación en 2024
5. Discusión

Los resultados de la sección 4 cuentan dos historias que conviene separar. Una es espacial y es robusta: la siniestralidad registrada en la ZMM se concentra en corredores, la estructura persiste entre años y sobrevive a la escala y a la corrección por pruebas múltiples. La otra es temporal y es administrativa: el nivel de cada municipio cambia de un año a otro por razones que no tienen que ver con el tránsito.

5.1. El régimen de reporte municipal como fuente principal de error

El supuesto implícito de cualquier modelo de conteos sobre registros administrativos es que el subregistro existe pero es estable: si un municipio captura la mitad de sus accidentes, los captura así todos los años, y el sesgo se absorbe en el intercepto. La literatura vial documenta que el subregistro es la norma y no la excepción, y que su nivel varía con la severidad y con el país (Elvik & Mysen, 1999). Lo que esta base muestra es que en la ZMM tampoco es estable en el tiempo. Santa Catarina pasa de 3 registros en 2020 a cerca de tres mil en 2023; Guadalupe alcanza su máximo en plena pandemia y cae a un tercio en 2024; Salinas Victoria alterna entre dos niveles año con año. Ninguna dinámica vial produce saltos de ese tamaño en un solo periodo: lo que cambia es la práctica de captura.

Tres resultados independientes apuntan a la misma causa. Primero, el residual de la Binomial Negativa tiene forma de municipio: su I de Moran cae de 0.31 a 0.07 al quitar la media municipal (sección 4.2), de modo que lo que parecía un proceso espacial fino que faltaba modelar eran 18 bloques con un nivel distinto cada uno. Eso explica también por qué el rezago espacial no aportó nada: las vecinas de una celda comparten municipio y se equivocan en la misma dirección. Segundo, el exceso de ceros sobre la Binomial Negativa se concentra en unos pocos pares municipio×periodo, con Santa Catarina antes de 2022 a la cabeza; son celdas cuyo municipio no reportaba, no celdas sin riesgo. Lord et al. (2005) advierten que la inflación de ceros en datos de accidentes suele ser un artefacto de subregistro o de una unidad de análisis mal elegida y no un segundo proceso generador; aquí el diagnóstico es explícito. Tercero, dos años recientes de historia predicen 2024 mejor que cinco, lo que solo tiene sentido si los años viejos describen un régimen de reporte que ya no rige.

La consecuencia de diseño fue convertir el diagnóstico en estructura: el modelo jerárquico separa un efecto municipal dinámico $m_{j,a}$, que absorbe *cuánto se reporta*, de un efecto espacial u_i por celda, que absorbe *dónde, dentro del municipio, se concentra*. La separación tiene un precio que hay que declarar: $m_{j,a}$ no es siniestralidad. Es la mezcla inseparable de riesgo real y de intensidad de captura, y con esta base no hay forma de repartirla. Lo que sí se gana es que u_i queda neto del régimen: es el primer producto del proyecto que compara a Guadalupe con Guadalupe.

La misma lógica pone un techo al pronóstico. El régimen de 2024 no está en los datos de 2019–2023, y ningún modelo entrenado con el pasado puede anticipar que un municipio empiece o deje de reportar. El pronóstico del jerárquico es por persistencia —toma el nivel municipal de 2023— y sus intervalos son, por construcción, un piso de la incertidumbre real: no incluyen el riesgo de cambio de régimen. La alternativa natural, propagar una innovación t_3 más, no está disponible: $\mathbb{E}[e^T] = \infty$ para cualquier t de Student, y la media predictiva y el CRPS dejarían de existir. Que el jerárquico cubra el 87 % con un intervalo nominal del 90 % aun sin ese término indica que el resto de la incertidumbre está bien representada; el faltante es precisamente el régimen.

5.2. Lo que la base puede y no puede decir

La distinción anterior permite delimitar con precisión el alcance de los resultados.

Lo que puede decir. Dónde se concentra el *reporte* de accidentes, con qué estructura espacial y con qué persistencia. El índice de Gini, el I de Moran y los mapas locales con FDR coinciden a 250, 500 y 1 000 m de lado, lo que descarta que la estructura sea un artefacto de la rejilla (Openshaw, 1984). El ranking de celdas de 2019 correlaciona 0,83 con el de 2024, con una pandemia de por medio. Y, dentro de cada municipio, la base sostiene un perfil de riesgo relativo u_i con la incertidumbre que corresponde a cada celda: las celdas con pocos accidentes no se encogen mucho en su estimación puntual, pero su intervalo es tres veces más ancho que el de las celdas con más de cien, y esa diferencia es información para decidir.

Lo que no puede decir. Primero, no distingue un municipio donde bajó el riesgo de uno que dejó de capturar accidentes; quien use $m_{j,a}$ o las series municipales como indicador de seguridad vial tiene que resolver esa ambigüedad por fuera, con otra fuente. Segundo, no anticipa cambios de régimen. Tercero, no dice *por qué* una celda es riesgosa: sin exposición (tránsito, kilómetros de vialidad) un corredor con muchos accidentes puede ser un corredor peligroso o un corredor transitado. La exposición es la covariable central de los modelos de frecuencia de accidentes (Lord & Mannering, 2010); sin ella, lo que aquí se estima es frecuencia y no tasa. Cuarto, no permite inferencia causal sobre intervenciones: todas las covariables son estructurales y ninguna es manipulable.

El PAI como síntesis. El índice de precisión predictiva al 5 % vale 8.4 en todos los modelos, desde el conteo histórico hasta el jerárquico. Es la expresión cuantitativa de los dos párrafos anteriores. El *dónde* lo decide el historial, que es lo que la base mide bien; las mejoras del jerárquico están en el *cuánto* y en el *con qué certeza* (CRPS 6.17 contra 6.56), que es donde el régimen pesa. El PAI es la métrica habitual para juzgar mapas de puntos calientes (Chainey et al., 2008), y moverlo exige covariables que varíen por celda y que el historial no contenga, y esas no están en ATUS.

5.3. Limitaciones

Geocodificación por intersección. ATUS georreferencia la intersección reportada, no el punto físico del choque: el 97,6 % de las coordenadas distintas corresponde a un único par de calles. La rejilla de 500 m tolera bien ese error de posición, pero cualquier análisis a escala de cuadra o de tramo hereda un dato discreto sobre unos 60 000 nodos, no un patrón de puntos continuo.

Cambio de procedimiento en 2022. La matriz de Spearman entre años tiene dos bloques, 2019–2021 y 2022–2024, que coinciden con la aparición del campo `OID` en los archivos del INEGI. La hipótesis más económica es un cambio en el procedimiento de georreferenciación. Se incorporó como indicador de periodo, pero no se pudo verificar con documentación de la fuente; si la causa fuera otra, la lectura de la discontinuidad cambiaría, aunque no la del régimen municipal, que opera sobre el volumen y no sobre la posición.

Faltantes no aleatorios. Los campos con códigos centinela tienen un mecanismo MNAR: en accidentes fatales el aliento alcohólico se ignora 2.4 veces más seguido (sección 2.2). El modelo de conteo no usa esos campos, así que no lo afecta; cualquier modelo de severidad futuro tendrá que tratarlos explícitamente.

Una sola ventana de validación. La validación fuera de muestra se hizo en un solo año, 2024. Es la única prueba honesta disponible —un jerárquico con 2 241 efectos de celda ajusta el pasado casi a la perfección—, pero un solo año no permite estimar la variabilidad de las métricas entre ventanas, y 2024 pudo ser un año con más o menos cambios de régimen que el típico.

Escala anual. El jerárquico se ajusta sobre celda×año. El supuesto de separabilidad espacio-tiempo está apoyado (el efecto de mes es común a todas las celdas y aportó casi nada), pero el modelo no dice nada sobre estacionalidad local ni sobre horarios, que son preguntas operativas.

Cobertura territorial. Se retiraron las celdas sin accidentes en 6 años y las 103 celdas isla. La decisión se justifica porque una celda vacía en 379 mil registros no tiene red vial, pero implica que el modelo no predice para territorio donde la urbanización todavía no llega, que es donde crece la periferia.

5.4. Caminos que no funcionaron

Se documentan porque cada uno descarta una explicación y porque, sin el registro, alguien volvería a intentarlos.

BYM2. La especificación original del nivel de celda era BYM2 (Riebler et al., 2016), que separa un componente espacial ICAR de uno independiente y hace interpretable la fracción espacial ϕ. No se identificó en ninguna de sus dos parametrizaciones: la no centrada llevó ϕ a 0 y la centrada a 1, con $\hat{R}$ de 2.06 y 1.65. El motivo es de estructura y no de ajuste fino del muestreador. Con 5 años de conteos por celda los datos fijan cada u_i casi por completo, y el reparto entre "espacial" e "independiente" solo lo sostienen los priors. La estructura espacial existe —el Moran de la tasa por celda neta del municipio es 0.41—; lo que falta es información para descomponerla. El CAR propio, con una sola varianza y un solo α, se identifica sin problema. La lección es general: BYM2 está pensado para mapeo de enfermedades con conteos escasos por área, y pierde su ventaja cuando cada área tiene información de sobra.

Rezago espacial en el GLM. Incluir el promedio de las vecinas como covariable, con un Moran de 0,65 en los conteos, parecía obvio. Su coeficiente fue $-0{,}002$ ($t = -0{,}6$).

Fue el primer indicio de que el residual no era espacial fino sino municipal (sección 5.1).

Inflación de ceros. El ZINB con inflación constante mejora el AIC, pero reparte la probabilidad de cero estructural entre todas las celdas por igual, cuando el exceso está concentrado en unos pocos municipios y periodos. Ganar AIC con un mecanismo equivocado no es mejorar el modelo; el fenómeno se modeló donde ocurre, en el nivel municipal.

Innovaciones normales. Con una caminata aleatoria normal para el municipio, σ_{rw} salió en 0.61: inflada por los pocos municipios que saltan, y por tanto demasiado ancha para los que apenas se mueven. Con innovaciones t_3 bajó a 0.29, que describe al municipio típico, y los saltos quedan en las colas.

Deriva municipal. Una tendencia local por municipio, pensada para capturar el crecimiento de la periferia, se encogió a cero ($\sigma_d = 0{,}07$), introdujo 46 divergencias y no mejoró el CRPS. Con cinco años y cambios de régimen, los datos no distinguen una tendencia de una racha de innovaciones.

Ventanas de historia por AIC. Cuando el GLM recibe la historia completa y la reciente, elige la completa, porque en entrenamiento explica mejor 2019–2021 al incluirlos; fuera de muestra pierde. Es la razón por la que ninguna comparación del proyecto se hace con criterios de información sobre el periodo de ajuste, sino con la validación en 2024.

Lo que no se intentó. La función K de Ripley y la densidad kernel en su versión plana suponen que un accidente puede ocurrir en cualquier punto del plano; aquí solo puede ocurrir sobre la red vial, y el nulo plano sobreestimaría el agrupamiento. Las versiones restringidas a red (Okabe & Yamada, 2001) exigen la geometría de las calles, que el proyecto no tiene. Habrían confirmado algo ya establecido —que hay agrupamiento y a qué escalas—, así que se pospusieron hasta tener la red vial, que es también la covariable de exposición que falta (sección 6).

6. Conclusiones y trabajo futuro

A. Supuestos del modelo jerárquico y su verificación

B. Reproducibilidad

Referencias

Chainey, S., Tompson, L., & Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, *21*(1–2), 4-28. https://doi.org/10.1057/palgrave.sj.8350066

Elvik, R., & Mysen, A. B. (1999). Incomplete accident reporting: meta-analysis of studies made in 13 countries. *Transportation Research Record*, *1665*(1), 133-140. https://doi.org/10.3141/1665-18

Instituto Nacional de Estadística y Geografía. (2025). *Accidentes de tránsito terrestre en zonas urbanas y suburbanas (ATUS)*. https://www.inegi.org.mx/programas/accidentes/

Lord, D., & Mannering, F. (2010). The statistical analysis of crash-frequency data: a review and assessment of methodological alternatives. *Transportation Research Part A: Policy and Practice*, *44*(5), 291-305. https://doi.org/10.1016/j.tra.2010.02.001

Lord, D., Washington, S. P., & Ivan, J. N. (2005). Poisson, Poisson-gamma and zero-inflated regression models of motor vehicle crashes: balancing statistical fit and theory. *Accident Analysis & Prevention*, *37*(1), 35-46. https://doi.org/10.1016/j.aap.2004.02.004

Okabe, A., & Yamada, I. (2001). The K-function method on a network and its computational implementation. *Geographical Analysis*, *33*(3), 271-290. https://doi.org/10.1111/j.1538-4632.2001.tb00448.x

Openshaw, S. (1984). *The Modifiable Areal Unit Problem*. Geo Books.

Riebler, A., Sørbye, S. H., Simpson, D., & Rue, H. (2016). An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, *25*(4), 1145-1165. https://doi.org/10.1177/0962280216660421