Predicción espacial de accidentes de tránsito en la Zona Metropolitana de Monterrey

Eduardo Luna[a]

[a]*Tecnológico de Monterrey, Monterrey, Nuevo León, México*

INFORMACIÓN

Palabras clave:
accidentes de tránsito
geoestadística
modelo jerárquico bayesiano
INLA
Monterrey

RESUMEN

1. Introducción
2. Datos
2.1. Fuente y recorte a la ZMM
2.2. Calidad y propiedades de la base
2.3. Selección de variables
3. Metodología
3.1. Unidad espacial
3.2. Análisis espacial exploratorio
3.3. Modelos de conteo
3.4. Modelo jerárquico bayesiano
3.5. Validación fuera de muestra
4. Resultados

Los resultados se presentan en el orden en que condicionaron las decisiones siguientes: primero la estructura espacial que justifica un enfoque territorial (§4.1); después la comparación de modelos de conteo, que reveló que el error dominante es municipal (§4.2); luego el ajuste del modelo jerárquico que se construyó en respuesta (§4.3), y al final la validación de todos contra 2024 (§4.4). Todas las cifras se refieren a la partición de 2,241 celdas hexagonales de 500 m de lado descrita en §3.1.

4.1. Estructura espacial de la siniestralidad

Concentración. Los accidentes de 2019–2024 se reparten de forma desigual entre las celdas (figura 1): la mediana por celda es 30 y el máximo 3,741. La curva de Lorenz da un **coeficiente de Gini de 0.766**. El 1 % de las celdas concentra el 14.9 % de los accidentes; el 5 %, el 43.7 %, y el 10 %, el 61.7 %. A escala de intersección el Gini es 0.752 y el 5 % de los puntos concentra el 58 % (figura 2). La concentración es similar en las dos escalas: es la firma de una distribución de cola pesada y no un artefacto de la agregación.

Autocorrelación global. Con pesos de contigüidad estandarizados por fila sobre $\log(1+n)$, el I **de Moran es 0.648**, con $z = 37$ frente a 999 permutaciones (figura 3); ninguna permutación se acerca al valor observado. Sobre el conteo crudo el estadístico es 0.57, de modo que la conclusión no depende de la transformación. Las celdas vecinas se parecen: un modelo que las trate como independientes subestimará sus errores estándar.

Sensibilidad a la escala. Repetir el análisis con lados de 250 y 1,000 m (cuadro 1) muestra el efecto de escala

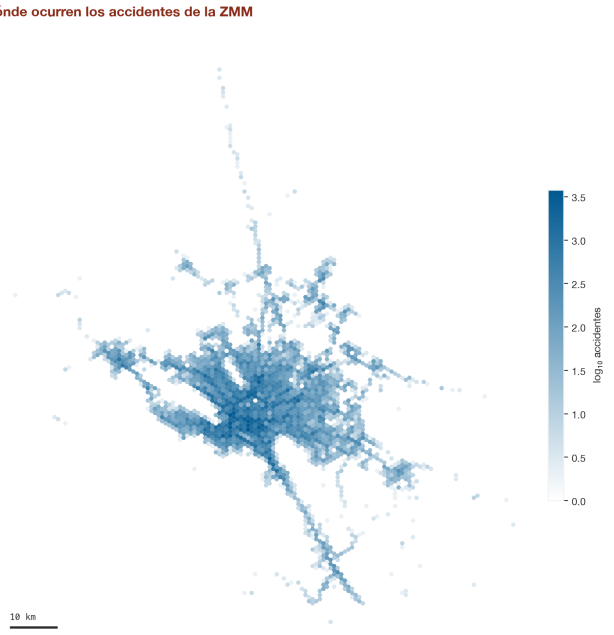


Figura 1: Accidentes por celda hexagonal, 2019–2024, en escala logarítmica.

Tabla 1
Sensibilidad de la autocorrelación y la concentración al tamaño de la celda.

Lado (m)	Celdas	I	Gini	Top 5 %
250	6 145	0,524	0,746	44,8 %
500	2 241	0,648	0,756	42,6 %
1 000	815	0,721	0,788	43,5 %

esperado en el I de Moran, que crece con la agregación de 0.52 a 0.72, mientras que el 5 % superior concentra 43–45 % de los accidentes en las tres rejillas. La autocorrelación es una propiedad del fenómeno y no de la rejilla elegida.

Estructura local. Con 2,241 pruebas al 5 % se esperan del orden de 112 falsos positivos por azar, por lo que los estadísticos locales se corrigieron con Benjamini–Hochberg (Benjamini & Hochberg, 1995). Con la corrección, **el LISA (Anselin, 1995) pasa de 682 celdas significativas a 287** (−58 %), y el G_i^* (Ord & Getis, 1995), de 732 a 383. Lo que sobrevive (figura 4) es un núcleo compacto de 266 celdas

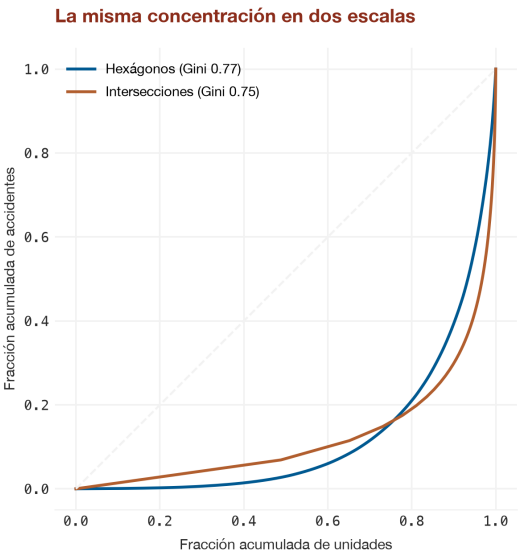


Figura 2: Curvas de Lorenz por celda hexagonal y por intersección.

Alto–Alto sobre la mancha urbana consolidada, 17 Bajo–Bajo en la periferia y solo cuatro atípicos espaciales (uno Alto–Bajo y tres Bajo–Alto). No aparecen puntos calientes aislados: el riesgo se organiza en corredores, no en esquinas sueltas. Las 303 celdas calientes del G_i^* —el 13.5 % del territorio con red vial, 197 km^2— concentran el 55 % de los accidentes.

Persistencia. La estructura no es propia de un año. El I de Moran anual se mantiene entre 0.60 y 0.69 de 2019 a 2024, y el ranking de celdas de 2019 tiene una **correlación de Spearman de 0.83 con el de 2024**, con la pandemia de por medio (figura 5). La matriz de correlaciones tiene además dos bloques: ∼0.90 dentro de 2019–2021 y dentro de 2022–2024, y ∼0.82 entre bloques. El corte coincide con la aparición del campo `OID` en los archivos del INEGI a partir de 2022; por eso los modelos incluyen un indicador de periodo.

La prueba operativa de persistencia es el índice de precisión predictiva (PAI) (Chainey et al., 2008): la fracción de accidentes capturada dividida entre la fracción de territorio seleccionada. **Eligiendo el 5 % de las celdas con más accidentes en 2019–2023 se captura el 42 % de los accidentes de 2024: PAI de 8.4.** Este resultado no usa ningún modelo —solo contar y ordenar— y es la referencia que cualquier modelo tiene que superar.

4.2. Modelos de conteo

Sobredispersión. En el panel de celda×mes (161 352 filas, 56 % de ceros) la razón varianza/media marginal es 12,9. Condicionando en la historia de la celda, log h_i, el estadístico $\chi^2_{\text{Pearson}}/gl$ del GLM de Poisson cae a 1,38: la historia absorbe casi toda la heterogeneidad, pero lo que queda es inequívoco. La prueba de Cameron y Trivedi (1990) estima $\hat{\alpha} = 0{,}096$ con $t = 59$. La Binomial Negativa NB2 estima $\theta = 5{,}5$ y mejora el AIC en unos 13 000 puntos respecto a Poisson y en 600 respecto a NB1. Como $1/\theta = 0$ está en la frontera del espacio paramétrico, la razón de verosimilitudes se evalúa contra una mezcla 50:50 de una masa en cero y una χ^2_1 (Self & Liang, 1987); el rechazo de Poisson se mantiene con cualquier convención.

El rootograma colgante (Kleiber & Zeileis, 2016) hace visible la diferencia (figura 6): Poisson subpredice los ceros en unas 4 500 celdas-mes y sobrepredice los unos en 2 900; NB2 corrige casi todo el desajuste. Los residuales cuantil aleatorizados de NB2 sobre 2024 (Dunn & Smyth, 1996) tienen desviación estándar de 1,12 en lugar de 1, con una cola derecha más pesada que la normal (figura 7): queda dispersión que el modelo no captura, y la sección siguiente muestra de dónde viene.

Exceso de ceros. A NB2 le falta el 3,3 % de los ceros. Un ZINB con inflación constante estima $\hat{\pi} = 0{,}026$ y mejora el AIC en 1 200, pero el exceso no está repartido: ocho pares municipio×periodo explican dos tercios de él, con Santa Catarina en prepandemia y pandemia a la cabeza. Ese municipio registró 128, 3 y 77 accidentes en 2019, 2020 y 2021, y 1 793 en 2022. Los ceros "estructurales" son celdas de municipios que no reportaban, no celdas sin riesgo, por lo que no se adoptó un modelo de inflación de ceros.

Comparación fuera de muestra. El cuadro 2 resume la validación en 2024 de los modelos de conteo a escala celda×mes.

Cuatro resultados se desprenden de esta comparación:

1. **El PAI es idéntico en M0–M3.** Con $\beta_h = 1{,}01$ y covariables que solo varían en el tiempo, la predicción de cada celda es h_i multiplicada por un factor común, y el ranking de celdas coincide con el del histórico (Spearman = 1,000). Un GLM con covariables temporales cambia el *cuánto* y la incertidumbre, pero no el *dónde*.
2. **El rezago espacial no aporta nada**: su coeficiente es −0,002 ($t = -0{,}6$), pese a la autocorrelación de 0,65 en los conteos.
3. **Dos años recientes predicen mejor que cinco**: el CRPS de M4 es 0,847 contra 0,886 de M2, y el promedio simple de 2022–2023 (M0r) es el mejor de la tabla. Cuando el modelo recibe ambas historias elige la completa, porque en entrenamiento explica mejor 2019–2021 al contenerlos; solo la validación fuera de muestra revela que generaliza peor.
4. **El residual tiene forma de municipio.** El I de Moran del residual de NB2 en 2024 es 0,31 y cae a 0,07 al restar la media de cada municipio (figura 8). La autocorrelación residual no es un proceso espacial fino: son 18 bloques con un nivel propio. Por eso el rezago no ayudó: las vecinas de una celda de Guadalupe también están en Guadalupe y se equivocan en la misma dirección.

Las series anuales por municipio (figura 9) explican el patrón: Santa Catarina pasa de 3 accidentes en 2020 a 2 904

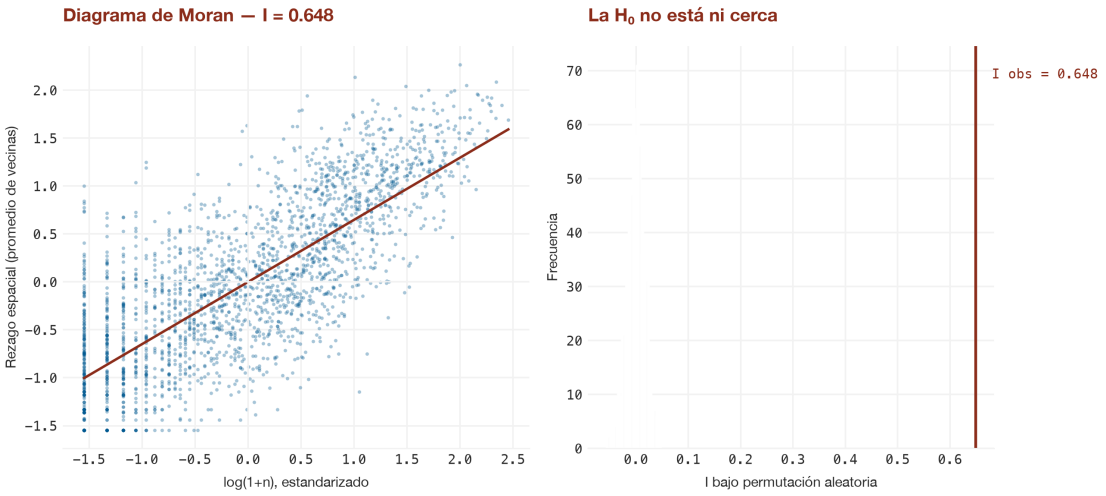


Figura 3: Izquierda: diagrama de dispersión de Moran sobre $\log(1+n)$ estandarizado; la pendiente es $I = 0{,}648$. Derecha: distribución de I bajo 999 permutaciones aleatorias, concentrada alrededor de cero, frente al valor observado.

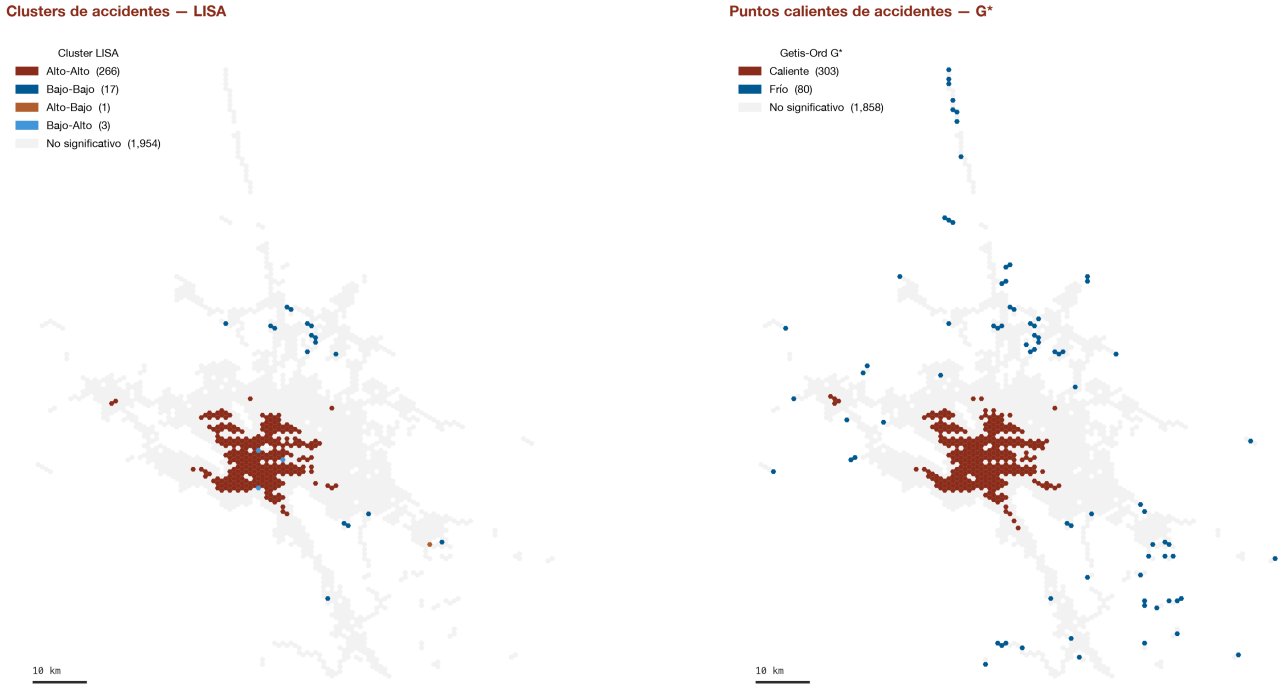


Figura 4: Izquierda: conglomerados LISA. Derecha: puntos calientes y fríos del G_i^* de Getis–Ord. Ambos mapas sobre la misma rejilla de celdas hexagonales, con control de la tasa de falsos descubrimientos al 5 %.

Tabla 2
Validación en 2024 a escala celda×mes. Devianza y MAE miden el acierto en la media; CRPS y cobertura, en la distribución; PAI, en la selección del 5 % de celdas. En negritas, el mejor CRPS.

Modelo	Devianza	MAE	CRPS	Cobertura 90 %	PAI 5 %
M0: histórico 2019–2023	40 737	1,246	0,909	89,8 %	8,41
M0r: histórico 2022–2023	35 652	1,196	**0,844**	92,0 %	8,38
M1: Poisson	39 705	1,247	0,895	90,2 %	8,41
M2: NB2	39 701	1,254	0,886	93,9 %	8,41
M3: NB2 + rezago espacial	39 702	1,254	0,886	93,9 %	8,41
M4: NB2, historia 2022–2023	35 701	1,200	0,847	92,0 %	8,38

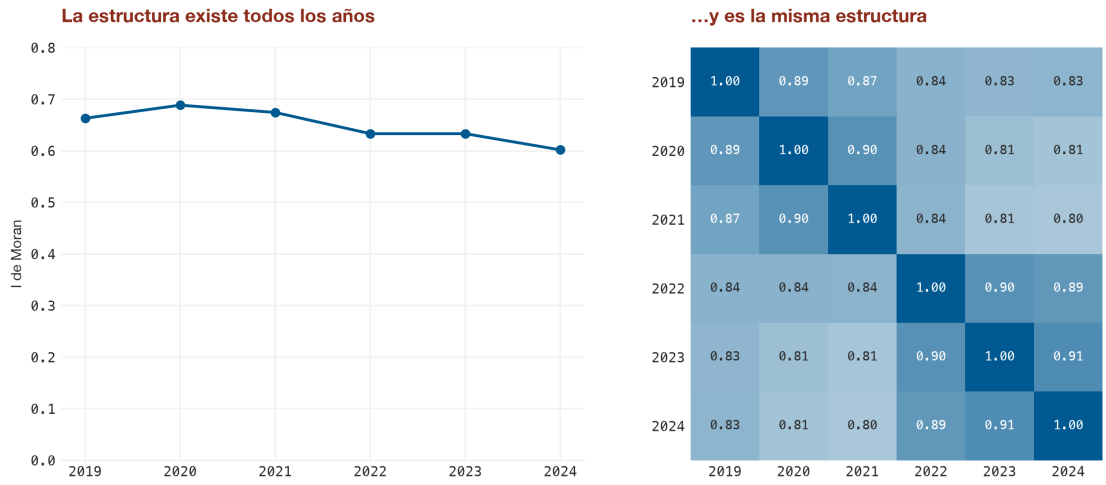


Figura 5: Izquierda: I de Moran por año. Derecha: correlación de Spearman entre los conteos por celda de cada par de años; se distinguen los bloques 2019–2021 y 2022–2024.

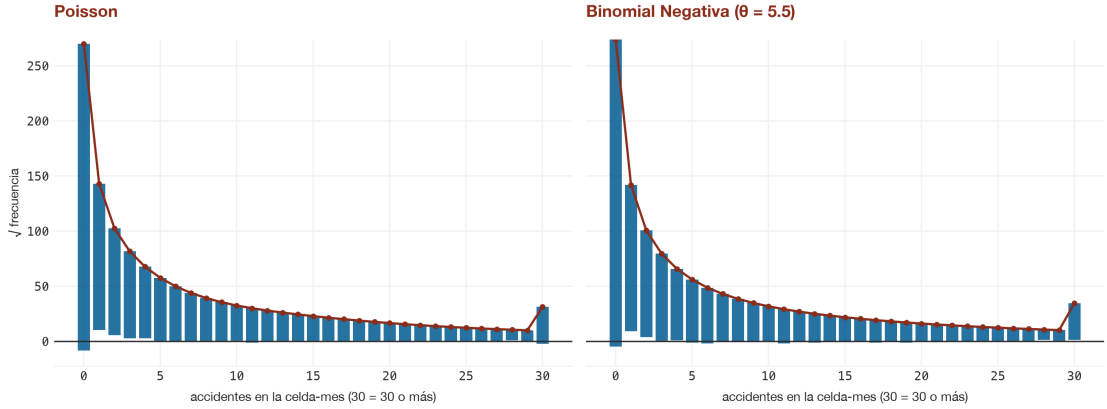


Figura 6: Rootogramas colgantes de Poisson y NB2 en el panel celda×mes. Las barras cuelgan de la frecuencia esperada (línea); si su base toca el cero, el modelo ajusta ese valor.

en 2023; Guadalupe alcanza su máximo en plena pandemia y cae a un tercio en 2024; Salinas Victoria alterna 286, 827, 351 y 821. Ninguna dinámica vial produce saltos de esa magnitud: lo que cambia de un año a otro es la práctica de captura de cada municipio. El supuesto de subregistro estable no se sostiene, y esta es la fuente dominante del error de predicción (§5).

4.3. Modelo jerárquico

BYM2 no se identifica La especificación con efecto espacial BYM2 (Riebler et al., 2016) se ajustó en sus dos parametrizaciones y ninguna convergió (cuadro 3). En la no centrada, la fracción espacial colapsa a $\phi \to 0{,}0001$; en la centrada, $\sigma_s \to 13$ y $\phi \to 0{,}9998$. Con cinco años de conteos por celda los datos fijan cada u_i casi por completo, y su reparto entre componente espacial e independiente solo lo sostienen los *priors*. La estructura espacial existe —el I de Moran de la tasa por celda, neta de la media municipal, es 0,41—, pero no hay información para dividirla entre dos componentes. El modelo final usa un CAR propio, con una sola varianza y un solo parámetro de dependencia.

Tabla 3
Intentos de ajuste de BYM2.

Parametrización	Resultado	$\hat{R}(\phi)$
No centrada	$\phi \to 0{,}0001$: desaparece la parte espacial	2,06
Centrada	$\phi \to 0{,}9998$, $\sigma_s \to 13$: desaparece la parte independiente	1,65

Diagnósticos de convergencia El modelo final (cuatro cadenas NUTS con `nutpie`, 1 000 iteraciones de calentamiento y 2 000 muestras por cadena) se ajustó en cuatro minutos **sin divergencias**. Sobre las 11 205 cantidades $\log \mu_{ia}$ —las que el modelo identifica— el $\hat{R}$ máximo (Vehtari et al., 2021) es 1,005 y el tamaño efectivo de muestra mínimo es 2 441. El intercepto β_0 y σ_m mezclan peor porque comparten información con el nivel medio de $\mathbf{u}$; ninguna conclusión depende de ellos por separado.

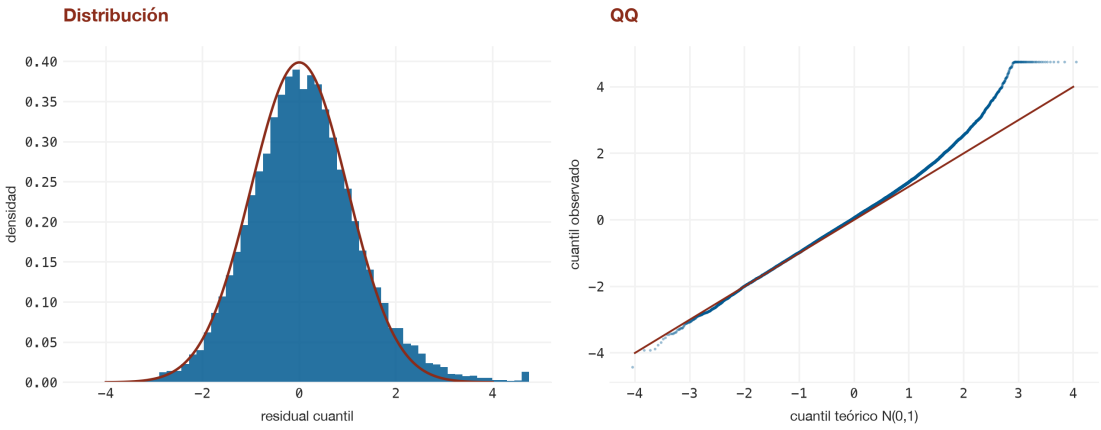


Figura 7: Residuales cuantil aleatorizados de NB2 sobre 2024: histograma frente a la densidad $N(0,1)$ y gráfico QQ.

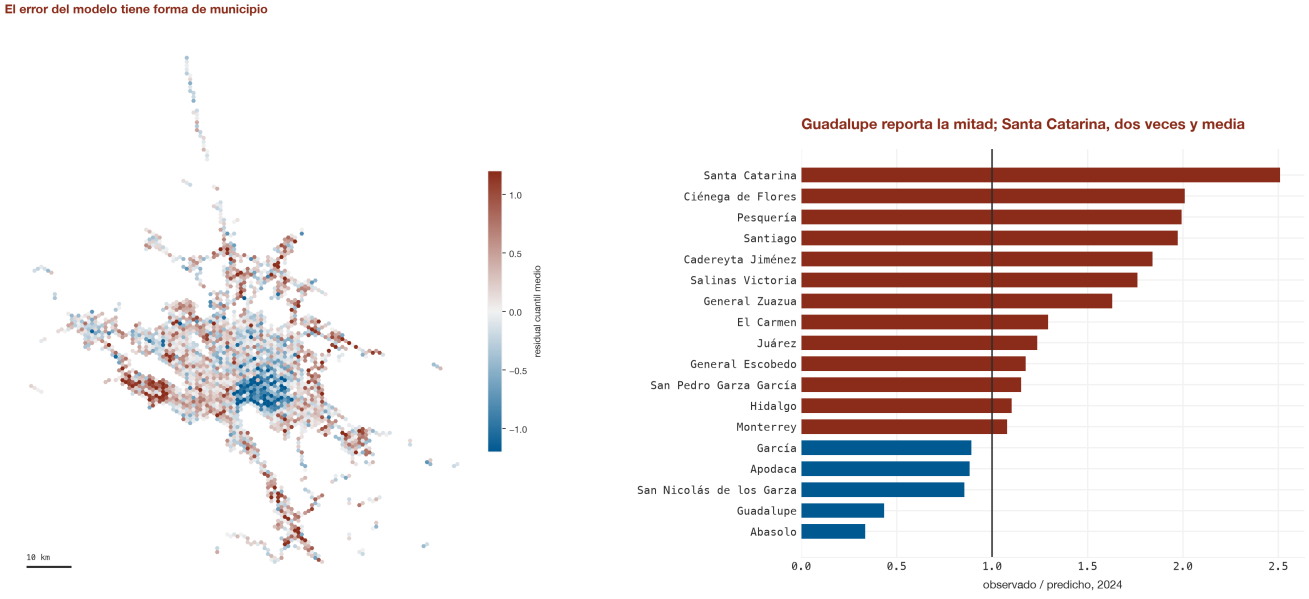


Figura 8: Izquierda: residual cuantil medio por celda en 2024 (NB2). Derecha: cociente entre accidentes observados y predichos por municipio en 2024.

Hiperparámetros El cuadro 4 resume la posterior. La dependencia espacial neta del municipio es fuerte ($\alpha = 0.85$). La sobredispersión a escala anual es moderada ($\theta = 12{,}2$, frente a 5,5 a escala mensual). El municipio típico cambia su nivel de reporte en un factor de $e^{0{,}29} \approx 1{,}34$ al año, y dentro de un mismo municipio las celdas difieren en órdenes de magnitud ($\sigma_u = 2{,}38$). Al reajustar con *priors* alternativos (α uniforme, σ_u con escala doble, θ con media 5 en lugar de 20) los cuatro valores cambian en el tercer decimal: los datos dominan a los priors. Con innovaciones normales en la caminata municipal, σ_{rw} se estimaba en 0,61, inflada por unos pocos saltos; con innovaciones t_3 baja a 0,29.

Trayectorias municipales. Los efectos $m_{j,a}$ reproducen las series observadas (figura 10): el salto de Santa Catarina en 2022, el descenso sostenido de Guadalupe desde 2020 y el pico aislado de Salinas Victoria. El intervalo es angosto en los municipios grandes (Monterrey, San Nicolás de los Garza) y ancho en los pequeños (Abasolo, Ciénega de Flores), como corresponde a la cantidad de información de cada uno.

Tabla 4
Hiperparámetros a posteriori del modelo jerárquico.

Parámetro	Media	IC 94 %
α	0,85	[0,81; 0,88]
θ	12,2	
σ_{rw}	0,29	
σ_u	2,38	

Perfil espacial neto del municipio. El efecto u_i mide cuánto más o menos riesgo tiene cada celda que el promedio

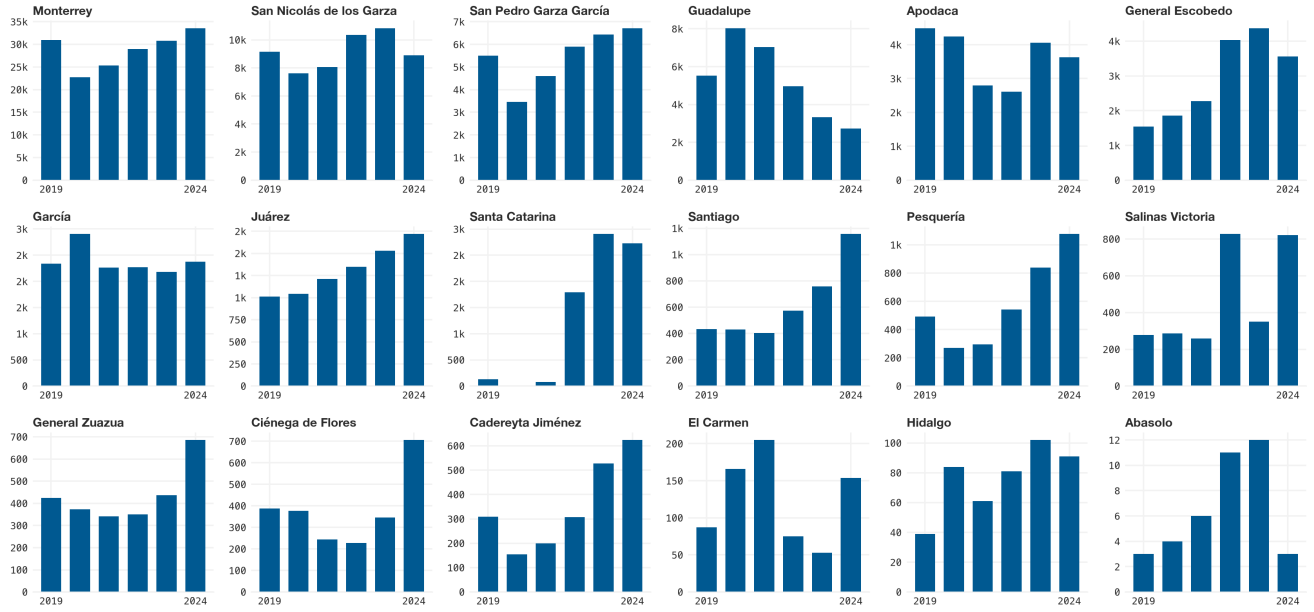


Figura 9: Accidentes registrados por año en cada uno de los 18 municipios de la ZMM, 2019–2024. Cada panel tiene su propia escala vertical.

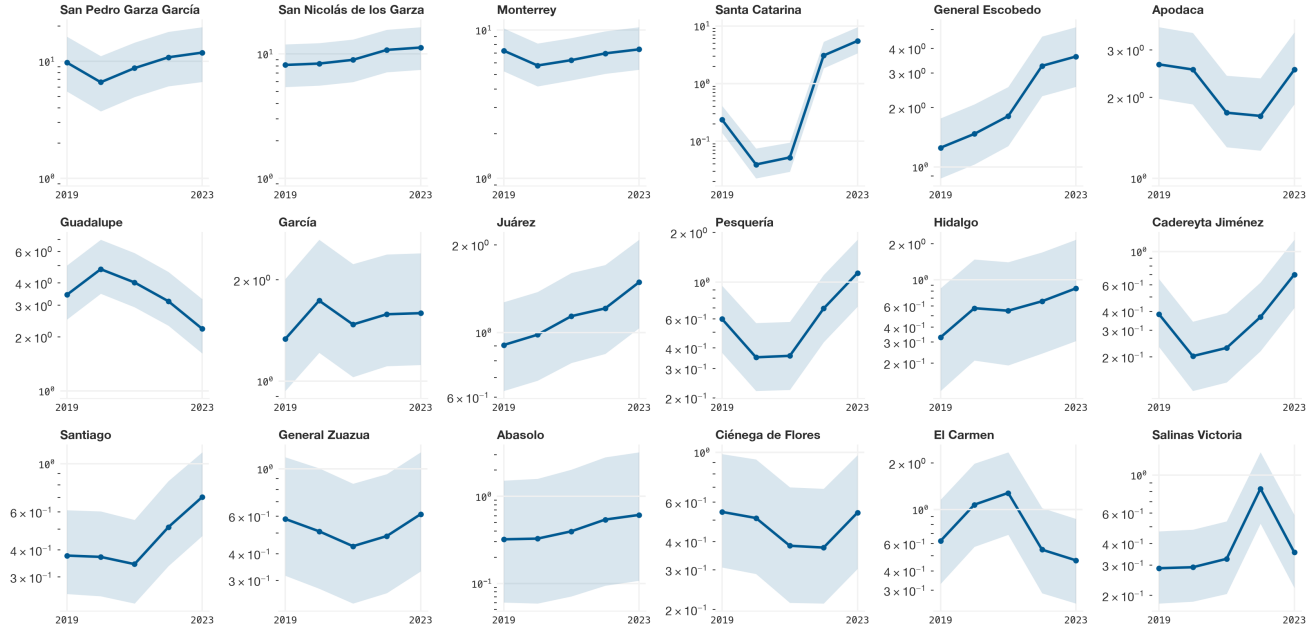


Figura 10: Efecto municipal $e^{m_{j,a}}$ a posteriori, 2019–2023: mediana e intervalo del 90 %, en escala logarítmica. Cada panel es un régimen de reporte.

de su municipio, estimado con la información de la celda y la de sus vecinas (figura 11). Es el primer mapa del proyecto que no depende de cuánto reporta cada municipio: cada celda se compara con su propio municipio. Los corredores viales principales aparecen con $u_i > 0$, y las colonias interiores y los bordes de la mancha urbana, con $u_i < 0$.

En las 618 celdas con cinco accidentes o menos en cinco años, el modelo encoge poco la estimación puntual respecto al estimador ingenuo (12 %), pero su incertidumbre es el triple que la de las celdas con más de cien accidentes (desviación posterior de 0.75 contra 0.25 en escala log; figura 12). Dos celdas con el mismo u_i y distinta incertidumbre no justifican la misma intervención.

4.4. Validación en 2024

El pronóstico del modelo jerárquico se obtiene por simulación: para cada muestra posterior se toma el nivel municipal de 2023, se combina con u_i y se simula un conteo Binomial Negativo. Es, por tanto, un pronóstico por

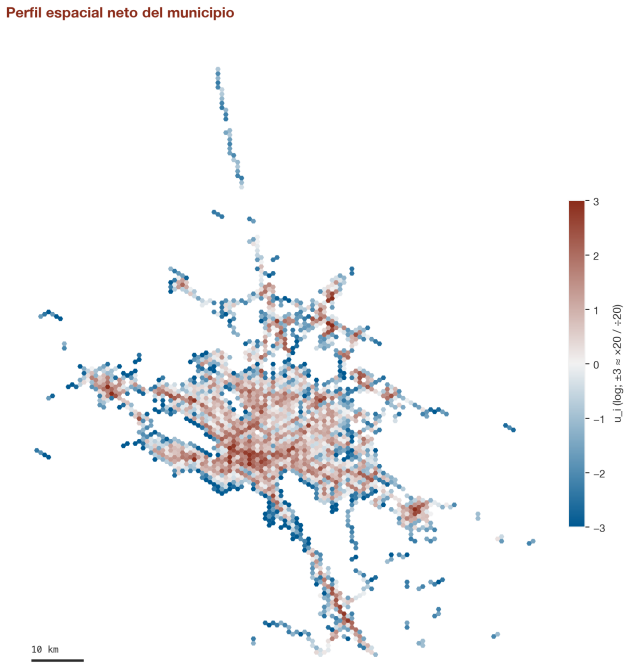


Figura 11: Mediana a posteriori de u_i, riesgo relativo de cada celda respecto a su municipio (escala log; ±3 equivale a un factor de ≈ 20).

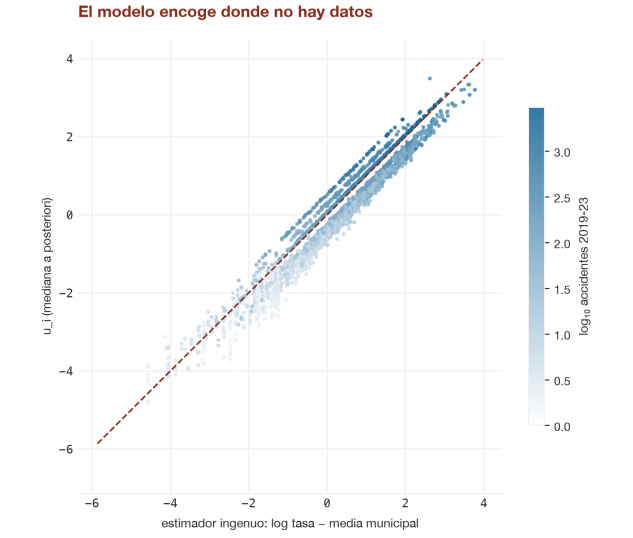


Figura 12: Estimador ingenuo (log tasa menos media municipal) contra la mediana a posteriori de u_i. El color indica los accidentes de cada celda en entrenamiento; las celdas con pocos datos se encogen hacia su municipio y sus vecinas.

persistencia del régimen municipal (§3.5). Los *baselines* se recalculan a escala celda×año para que la comparación sea directa (cuadro 5).

- **Calibración del total.** El jerárquico predice 70 815 accidentes para 2024 contra 71 249 observados: un error del 0,6 %.

Tabla 5
Validación en 2024 a escala celda×año. M6 es el modelo jerárquico con CAR y efecto municipal.

Modelo	MAE	CRPS	Cob. 90 %	PAI
M0	9,59	8,04	63 %	8,41
M0r	8,15	6,56	68 %	8,38
M4	8,18	6,93	**90 %**	8,38
M6	8,19	**6,17**	87 %	8,42

- **Media.** Empata con M0r en MAE (8,19 contra 8,15). Lo predecible de 2024 es el nivel reciente de cada municipio debido al perfil estable de cada celda, y un promedio bien elegido ya captura esa media.
- **Distribución.** Mejora el CRPS (Gneiting & Raftery, 2007) del mejor *baseline* en un 6 % (6,17 contra 6,56). El intervalo del 90 % de M0r cubre solo el 68 % de las celdas, porque supone un Poisson sin sobredispersión ni régimen; el del jerárquico cubre el 87 %, cerca de su nivel nominal, aun sin incorporar el riesgo de cambio de régimen. M4 cubre el 90 % a costa de un CRPS peor (6,93): sus intervalos son más anchos de lo necesario.
- **Selección de zonas.** El PAI al 5 % es 8,42, prácticamente el mismo que el del histórico. El *shrinkage* reordena la cola de la distribución de celdas, no la cabeza, que es donde se decide la selección.

Dos variantes se evaluaron y descartaron. La primera pronosticaba 2024 con una innovación t_3 adicional en el nivel municipal; como $\mathbb{E}[e^T] = \infty$ para cualquier t de Student, la media predictiva no existe, y numéricamente la suma de medias dio 2,3 millones de accidentes contra 71 mil observados, con valores que cambiaban con la semilla. La segunda añadía una deriva por municipio para capturar el crecimiento periférico: la posterior la encogió a cero ($\sigma_d = 0{,}07$), produjo 46 divergencias y no mejoró el CRPS. Con cinco años y saltos de régimen, los datos no distinguen una tendencia de una racha de innovaciones.

El PAI al 5 % se mantuvo en 8.4 en todos los modelos, desde el conteo histórico hasta el jerárquico: el *dónde* lo determina el historial de cada celda. Lo que el modelo jerárquico añade es una distribución predictiva calibrada y un perfil espacial neto del régimen de reporte municipal.

5. Discusión

6. Conclusiones y trabajo futuro

A. Supuestos del modelo jerárquico y su verificación

B. Reproducibilidad

Referencias

Anselin, L. (1995). Local indicators of spatial association—LISA. *Geographical Analysis*, *27*(2), 93-115. https://doi.org/10.1111/j.1538-4632.1995.tb00338.x

Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, *57*(1), 289-300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x

Cameron, A. C., & Trivedi, P. K. (1990). Regression-based tests for overdispersion in the Poisson model. *Journal of Econometrics*, *46*(3), 347-364. https://doi.org/10.1016/0304-4076(90)90014-K

Chainey, S., Tompson, L., & Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, *21*(1–2), 4-28. https://doi.org/10.1057/palgrave.sj.8350066

Dunn, P. K., & Smyth, G. K. (1996). Randomized quantile residuals. *Journal of Computational and Graphical Statistics*, *5*(3), 236-244. https://doi.org/10.1080/10618600.1996.10474708

Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, *102*(477), 359-378. https://doi.org/10.1198/016214506000001437

Instituto Nacional de Estadística y Geografía. (2025). Accidentes de tránsito terrestre en zonas urbanas y suburbanas (ATUS).

Kleiber, C., & Zeileis, A. (2016). Visualizing count data regressions using rootograms. *The American Statistician*, *70*(3), 296-303. https://doi.org/10.1080/00031305.2016.1173590

Ord, J. K., & Getis, A. (1995). Local spatial autocorrelation statistics: distributional issues and an application. *Geographical Analysis*, *27*(4), 286-306. https://doi.org/10.1111/j.1538-4632.1995.tb00912.x

Riebler, A., Sørbye, S. H., Simpson, D., & Rue, H. (2016). An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, *25*(4), 1145-1165. https://doi.org/10.1177/0962280216660421

Self, S. G., & Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, *82*(398), 605-610. https://doi.org/10.1080/01621459.1987.10478472

Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: an improved $\widehat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, *16*(2), 667-718. https://doi.org/10.1214/20-BA1221