

Predicción espacial de accidentes de tránsito en la Zona Metropolitana de Monterrey

Procedimientos, razonamiento y resultados del proyecto GeoStats

Eduardo Luna

Tecnológico de Monterrey

Septiembre de 2026

Resumen

Este reporte documenta el recorrido metodológico completo del proyecto: desde la pregunta original —predecir cuántos accidentes de tránsito ocurrirán y en qué lugares de la Zona Metropolitana de Monterrey (ZMM)— hasta un modelo bayesiano jerárquico validado fuera de muestra. Está escrito para que el equipo entienda no solo *qué* se hizo, sino *por qué* se tomó cada decisión y qué evidencia la sostiene. Los hallazgos principales son tres. Primero, la siniestralidad de la ZMM tiene estructura espacial fuerte y persistente: el 5 % del territorio con red vial concentra el 44 % de los accidentes, la autocorrelación espacial es alta (I de Moran = 0,65) y el ranking de zonas de 2019 correlaciona 0,83 con el de 2024. Segundo, la fuente dominante del error de predicción no es estadística sino administrativa: los municipios cambian de *régimen de reporte* de un año a otro, y ningún modelo puede anticipar eso desde el pasado. Tercero, el modelo jerárquico final (Binomial Negativa con efecto municipal dinámico y efecto espacial CAR por celda) supera al mejor *baseline* en calidad distribucional (CRPS 6,17 contra 6,56) y produce el primer mapa de riesgo relativo neto del régimen municipal, pero no mueve el índice de precisión predictiva (PAI 8,4), que está determinado por el historial. Se documentan también los caminos que no funcionaron y por qué.

Índice

1. La pregunta y cómo se reformuló	3
2. Los datos	3
2.1. Fuente y recorte	3
2.2. Tres propiedades que condicionan todo lo demás	3
2.3. Selección de variables	4
3. La unidad espacial	4
4. Análisis espacial	4
4.1. Concentración	4
4.2. Autocorrelación global	5
4.3. Sensibilidad a la escala	5
4.4. Estructura local: LISA y G^* de Getis–Ord	6
4.5. Persistencia: ¿el mapa de 2019 predice el de 2024?	6
4.6. Lo que no se hizo	7

5. Modelos de conteo	7
5.1. El panel y el protocolo	7
5.2. Poisson y sobredispersión	7
5.3. Binomial Negativa	8
5.4. Ceros: por qué no ZINB	8
5.5. El resultado que reorganizó el proyecto	8
6. El modelo jerárquico	10
6.1. Especificación	10
6.2. Por qué CAR propio y no BYM2	11
6.3. Ajuste y diagnósticos	11
6.4. El producto: el perfil espacial neto del municipio	12
6.5. Validación en 2024	13
7. Hallazgos transversales	14
7.1. El PAI no se movió en ningún notebook	14
7.2. Lo que la base puede y no puede decir	14
7.3. Decisiones metodológicas que conviene recordar	15
8. Siguiendo pasos	15
A. Reproducibilidad	15
B. Supuestos del modelo jerárquico y su verificación	16

1. La pregunta y cómo se reformuló

La pregunta original del equipo era: *¿cuántos accidentes viales habrá, y en qué AGEBs?* La propuesta inicial contemplaba un proceso de Poisson para el total, una distribución de probabilidad sobre AGEBs para el reparto, y como alternativa un clasificador de Bayes. Tres observaciones reorganizaron el problema antes de tocar un solo dato.

Las dos etapas son un solo modelo. Si los conteos por unidad son Poisson independientes, $N_i \sim \text{Poisson}(\lambda_i)$, entonces el total es Poisson con media $\sum_i \lambda_i$ y el reparto condicional al total es multinomial con probabilidades $\lambda_i / \sum_j \lambda_j$. Modelar λ_i por unidad contesta *cuántos y dónde* de una sola tabla; construir dos modelos y pegarlos obliga a mantener la coherencia a mano y pierde la propagación de incertidumbre.

Un clasificador contesta otra pregunta. Un clasificador estima $P(\text{lugar} \mid \text{accidente})$: dado que ocurrió un accidente, dónde fue. Nunca dice cuántos habrá. Además, Naive Bayes supone independencia condicional entre predictores, que aquí es falsa de forma evidente (hora, día, tipo de vehículo y lugar están enlazados). Se descartó.

Lo que se predice es una intensidad, no un evento. A escala fina un accidente individual es casi aleatorio. Lo que se puede estimar es la *tasa esperada* de cada unidad —qué tan cargada está la moneda de cada lugar—, no el lanzamiento. Con esa tasa se construyen el ranking, el total y el mapa. Fijar esa expectativa desde el inicio evita prometer lo que ningún modelo entrega.

Decisión: marco de modelado

Panel de conteos por unidad espacial y periodo; modelo lineal generalizado de conteos con estructura jerárquica; validación temporal fuera de muestra.

2. Los datos

2.1. Fuente y recorte

La base es *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas* (ATUS) del INEGI, en su versión georreferenciada 2019–2024: 1 317 810 registros nacionales con 50 campos. El recorte a la ZMM —los 18 municipios del Sistema Urbano Nacional— deja **379 294 registros**, el 100 % con coordenadas WGS 84. El panel de la ZMM está balanceado (los mismos 18 municipios los seis años), lo que no ocurre a nivel nacional (91 municipios en 2019, 198 en 2024) y es la razón de que las comparaciones temporales se hagan solo sobre el recorte.

2.2. Tres propiedades que condicionan todo lo demás

- Los faltantes están codificados como valores válidos.** El INEGI no usa nulos: “se ignora” es un código del catálogo. Solo el 25 % de los registros tiene información completa en los seis campos con centinelas, y el mecanismo es MNAR (en accidentes fatales el aliento alcohólico se ignora 2,4 veces más seguido). La limpieza *nunca borra filas ni imputa*: solo agrega columnas derivadas donde `isna()` dice la verdad.
- Los registros están referenciados a intersecciones.** El 98,4 % trae dos vialidades, y el 97,6 % de las coordenadas distintas corresponde a un único par de calles: ATUS geocodifica la intersección reportada, no el punto físico. Lo que existe es un conteo sobre ~60 000 nodos con nombre, no un patrón de puntos continuo. Esto invalida las técnicas planas (KDE, K de Ripley) y sugiere que el AGEB descarta resolución que el dato ya trae.

3. **La variable URBANA distingue intersección de tramo.** Sus códigos no significan “urbano/no urbano” sino “en intersección” (96,6 % en la ZMM) y “fuera de intersección”. Es la variable que valida el punto anterior desde el propio diccionario.

2.3. Selección de variables

Las 51 columnas se clasificaron por un criterio que no es estadístico sino lógico: si la variable describe el *dónde y cuándo* (estructural: existe haya accidente o no) o el *accidente en sí* (consecuente: solo existe después del hecho). Las consecuentes —tipo de accidente, vehículos, víctimas, conductor— **no pueden ser predictores del conteo**; sirven para estratificar, para modelos de severidad y para el descriptivo. Quedaron 15 estructurales como predictores potenciales, 18 consecuentes para descriptivo, 5 con reservas y 5 descartadas (CINTURON con 75 % de ausencia, MINUTOS con preferencia de dígito, CAPAROD sin varianza, EDO constante, y los dos conteos de “otras víctimas” casi vacíos).

3. La unidad espacial

Se propuso inicialmente el AGEB y se descartó como unidad principal por tres razones, todas verificables:

- **Fronteras sobre avenidas.** Los límites de AGEB se trazan frecuentemente sobre vialidades principales, que es justo donde caen los accidentes. Un choque en la avenida Constitución cae en la frontera entre dos polígonos y su asignación es arbitraria. Es el problema de la unidad de área modificable (MAUP) en su forma más dañina para este fenómeno.
- **Área heterogénea.** Un AGEB del centro mide 0,2 km² y uno periférico varios; comparar conteos exige un denominador que casi nunca está.
- **Vecindad ambigua.** En polígonos irregulares el número de vecinos va de 1 a 20, y la matriz de pesos espaciales hereda esa irregularidad.

Decisión: rejilla hexagonal de 500 m de lado

Hexágonos regulares de 0,65 km² (comparables a un AGEB urbano) en proyección UTM 14N. Área constante (el conteo es la densidad), sin sesgo de frontera (la rejilla no sabe dónde están las calles), seis vecinos idénticos. Se conservan solo las celdas con al menos un accidente en seis años —una celda vacía en 379 mil registros no tiene red vial, no es riesgo cero— y se retiran las 103 celdas isla (sin vecinas con accidentes; 0,07 % de los registros). Quedan **2 241 celdas**. El AGEB pasa de ser la unidad a ser una fuente futura de covariables.

La partición vive en `geostats.espacial.celdas()` y es la misma en los tres notebooks de análisis; cada uno verifica con un `assert` que obtiene las mismas 2 241 celdas. La sensibilidad a la escala se midió repitiendo lo esencial con lados de 250 y 1 000 m (§4.3).

4. Análisis espacial

4.1. Concentración

La curva de Lorenz de los conteos por celda da un **Gini de 0,766**. El 1 % de las celdas concentra el 14,9 % de los accidentes; el 5 %, el 43,7 %; el 10 %, el 61,7 %. A escala de intersección el Gini es 0,752 y el 5 % de los puntos concentra el 58 %. La concentración es la misma en todas las escalas: es la firma de una distribución de cola pesada, y por sí sola justifica un enfoque territorial.

Dónde ocurren los accidentes de la ZMM




Figura 1: Accidentes por celda hexagonal, 2019–2024, en escala logarítmica. La mediana por celda es 30; el máximo, 3 741.

4.2. Autocorrelación global

Con pesos de contigüidad estandarizados por fila y la variable $\log(1 + n)$ (el conteo crudo tiene una cola que cinco celdas dominarían), el ***I* de Moran es 0,648**, con z de permutación de 37 sobre 999 barajadas. Sobre el conteo crudo es 0,57: la conclusión no depende de la transformación. Las celdas no son independientes; un modelo que las trate así subestima sus errores estándar.

4.3. Sensibilidad a la escala

Lado (m)	Área (km ²)	Celdas	<i>I</i> de Moran	Gini	Top 5 % concentra
250	0,16	6 145	0,524	0,746	44,8 %
500	0,65	2 241	0,648	0,756	42,6 %
1 000	2,60	815	0,721	0,788	43,5 %

Tabla 1: El *I* de Moran crece con la agregación (efecto de escala esperado); la concentración no cambia. La autocorrelación es una propiedad del fenómeno, no de la rejilla.

4.4. Estructura local: LISA y G^* de Getis–Ord

Ambos estadísticos se calculan celda por celda con inferencia por permutación. Con 2 241 pruebas al 5 % se esperan ~ 112 falsos positivos por azar, así que se aplica corrección de Benjamini–Hochberg. El efecto es material: **el LISA pasa de 682 celdas “significativas” a 287 (–58 %)**, y el G^* de 732 a 383. Sin corregir, casi la mitad del mapa de puntos calientes sería ruido.

Lo que sobrevive: 266 celdas Alto–Alto que forman un núcleo compacto sobre la mancha urbana consolidada, 17 Bajo–Bajo, y solo 4 atípicos espaciales. No hay puntos calientes aislados: *el riesgo es de corredor, no de esquina*. Las 303 celdas calientes del G^* —el 13,5 % del territorio con red vial, 197 km²— concentran el 55 % de los accidentes.




Figura 2: Izquierda: clusters LISA. Derecha: puntos calientes G^* . Ambos con FDR al 5 %. Dos estadísticos con lógica distinta convergen en la misma estructura.

4.5. Persistencia: ¿el mapa de 2019 predice el de 2024?

Es la sección que decide si el proyecto predictivo tiene sentido. El I de Moran se mantiene entre 0,60 y 0,69 los seis años, y el ranking de celdas de 2019 correlaciona **0,833 (Spearman) con el de 2024**, con una pandemia en medio. La prueba operativa es el índice de precisión predictiva (PAI): la fracción de accidentes capturada dividida entre la fracción de territorio seleccionada. **Eligiendo el 5 % de las celdas con los datos de 2019–2023 se captura el 42 % de los accidentes de 2024: PAI 8,4.** Esto es sin modelo —contar y ordenar— y es la cota que cualquier modelo tiene que superar.




Figura 3: Izquierda: I de Moran por año. Derecha: Spearman entre los conteos por celda de cada par de años. La matriz tiene dos bloques, 2019–2021 y 2022–2024.

Hallazgo no previsto. La matriz de Spearman tiene dos bloques ($\sim 0,90$ dentro de 2019–2021 y de 2022–2024; $\sim 0,82$ entre bloques). Coincide con que el campo `OID` —el identificador que genera QGIS al georreferenciar— solo existe en los archivos de 2022 en adelante. La hipótesis más económica es un cambio en el procedimiento de georreferenciación del INEGI. Se incorporó al modelo como indicador de periodo.

4.6. Lo que no se hizo

La función K de Ripley y la densidad kernel en sus versiones planas suponen que un evento puede ocurrir en cualquier punto del plano; aquí solo puede ocurrir sobre la red vial, y usarlas sobreestimaría el agrupamiento contra un nulo imposible. Las versiones restringidas a red exigen la geometría de las calles, que no está en el repositorio. Se decidió no correrlas: contestarían una pregunta ya contestada (hay agrupamiento, y a qué escalas) a un costo alto.

5. Modelos de conteo

5.1. El panel y el protocolo

Panel de **2 241 celdas** $\times$ **72 meses** = **161 352 filas**, con los ceros explícitos (el 56 % de las filas). Entrenamiento 2019–2023, prueba 2024. Regla fijada desde el inicio: *ningún modelo se compara en los datos con que se ajustó*. Métricas: devianza de Poisson y MAE ($\hat{\mu}$ acierta la media?), CRPS y cobertura del intervalo del 90 % ($\hat{\mu}$ acierta la distribución?), PAI ($\hat{\mu}$ sirve para elegir dónde intervenir?).

Covariables, todas estructurales: mes (factor), periodo (prepandemia / pandemia / 2022 en adelante) y $\log h_i$, el promedio mensual histórico de la celda calculado solo con entrenamiento. Su coeficiente es interpretable: $\beta_h = 1$ significa que la historia entra como *offset*; $\beta_h < 1$ significaría encogimiento hacia la media.

5.2. Poisson y sobredispersión

El GLM de Poisson se ajusta sabiendo que fallará, para documentar cómo. La razón varianza/media del panel es 12,9 (marginal); condicionando en $\log h$ cae a $\chi^2_{\text{Pearson}}/gl = 1,38$: la historia de la celda absorbe casi toda la heterogeneidad. Lo que queda es inequívoco: la prueba de Cameron–Trivedi da $\hat{\alpha} = 0,096$ con $t = 59$.

5.3. Binomial Negativa

La mezcla Poisson–Gamma (NB2) con $\theta = 5,5$ corrige la varianza: $\text{Var}(Y) = \mu + \mu^2/\theta$. Supera a NB1 (varianza lineal) por 600 puntos de AIC y a Poisson por 13 000. La prueba de razón de verosimilitudes está en la frontera del espacio paramétrico ($1/\theta = 0$), y su distribución nula es una mezcla 50:50 de una masa en cero y una χ_1^2 ; el p correcto es la mitad del de tabla. El rootograma colgante muestra el ajuste: Poisson subpredice los ceros en 4 500 y sobrepredice los unos en 2 900; NB2 lo corrige casi del todo.




Figura 4: Rootogramas colgantes. Las barras cuelgan de la frecuencia esperada; si tocan el cero, el modelo ajusta ese valor.

5.4. Ceros: por qué no ZINB

A NB2 le faltan el 3,3 % de los ceros. Un ZINB con inflación constante estima $\hat{\pi} = 0,026$ y mejora el AIC en 1 200. Pero la pregunta útil no es si ponerle un modelo sino *de dónde salen*: ocho pares municipio×periodo explican dos tercios del exceso, con Santa Catarina en prepandemia y pandemia a la cabeza. Ese municipio registró 128, 3 y 77 accidentes en 2019, 2020 y 2021, y 1 793 en 2022. Los ceros “estructurales” son celdas cuyo municipio no reportaba, no celdas sin riesgo. Un ZINB con inflación constante repartiría esa probabilidad entre todas las celdas por igual: exactamente lo contrario de lo que pasa.

Decisión: sin inflación de ceros

El exceso de ceros es un fenómeno de régimen de reporte por municipio y se modela como tal en la jerarquía, no como una segunda ecuación.

5.5. El resultado que reorganizó el proyecto

Modelo (hex×mes)	Devianza	MAE	CRPS	Cobertura 90 %	PAI 5 %
M0 histórico 2019–23	40 737	1,246	0,909	89,8 %	8,41
M0r histórico 2022–23	35 652	1,196	0,844	92,0 %	8,38
M1 Poisson	39 705	1,247	0,895	90,2 %	8,41
M2 NB2	39 701	1,254	0,886	93,9 %	8,41
M3 NB2 + rezago espacial	39 702	1,254	0,886	93,9 %	8,41
M4 NB2, historia 2022–23	35 701	1,200	0,847	92,0 %	8,38

Tabla 2: Validación en 2024 a escala celda×mes.

Tres cosas se leen en la tabla y una cuarta se lee en el mapa:

1. **El PAI es idéntico en M0–M3.** No es coincidencia: con $\beta_h = 1,01$ y covariables que solo varían en el tiempo, la predicción de cada celda es h_i por un factor común. El ranking es el del histórico (Spearman = 1,000). *Un GLM con covariables temporales no puede mover el dónde; solo el cuánto y el con qué certeza.*
2. **El rezago espacial no aporta nada** (coeficiente $-0,002$, $t = -0,6$), pese a un Moran de 0,65 sobre los conteos.
3. **Dos años recientes predicen mejor que cinco** (CRPS 0,847 contra 0,886). Y cuando el modelo recibe ambas historias elige la completa y pierde: en entrenamiento la historia larga explica mejor 2019–2021 porque los incluye. Es la razón de que el AIC no pueda comparar ventanas de historia y de que solo cuente la validación fuera de muestra.
4. **El residual tiene forma de municipio.** El I de Moran del residual de NB2 es 0,31; al quitar la media por municipio cae a 0,07. No queda un proceso espacial fino que modelar: quedan 18 bloques con un nivel distinto cada uno. Por eso el rezago no ayudó: las vecinas de una celda de Guadalupe también están en Guadalupe y se equivocan igual.

El error del modelo tiene forma de municipio




Figura 5: Izquierda: residual cuantil medio por celda en 2024 (NB2). Derecha: cociente observado/predicho por municipio. Guadalupe tuvo el 43 % de lo que su historia predice; Santa Catarina, 2,5 veces más.




Figura 6: Accidentes registrados por año en cada municipio. Santa Catarina registró 3 en 2020 y 2904 en 2023; Guadalupe alcanzó su máximo en plena pandemia y cayó a un tercio en 2024; Salinas Victoria alterna 286, 827, 351, 821.

El supuesto de subregistro estable es falso, y es la fuente dominante del error. Las series municipales no miden siniestralidad: miden la práctica de captura de cada municipio cambiando de un año a otro. Cualquier modelo sobre esta base es un modelo de *reportes*. Esto se sabía cualitativamente por la tasa de captura de CINTURON y ALIENTO; el conteo mismo lo confirma con magnitudes que ninguna dinámica vial produce.

6. El modelo jerárquico

6.1. Especificación

El notebook anterior decidió la especificación: Binomial Negativa, municipio como nivel con efecto que cambia en el tiempo, y efecto espacial por celda para el *shrinkage*. Para la celda i , en el municipio $j(i)$, en el año a :

$$Y_{ia} \sim \text{BinomialNegativa}(\mu_{ia}, \theta), \quad (1)$$

$$\log \mu_{ia} = \beta_0 + m_{j(i),a} + u_i. \quad (2)$$

El municipio absorbe *cuánto se reporta*; la celda absorbe *dónde, dentro del municipio, se concentra*. Es la conclusión de §5.5 convertida en estructura.

Nivel municipal. Caminata aleatoria con innovaciones de colas pesadas:

$$m_{j,2019} = \sigma_m z_j, \quad z \sim \text{NormalSumaCero}(1); \quad m_{j,a} = m_{j,a-1} + \sigma_{rw} \varepsilon_{j,a}, \quad \varepsilon \sim t_3. \quad (3)$$

La suma cero identifica β_0 . Las innovaciones son t y no normales por lo que mostraron las series: la mayoría de los municipios se mueve poco y unos pocos saltan. Con normales, σ_{rw} salía 0,61 (inflado por los saltos); con t_3 , 0,29.

Nivel de celda. CAR propio:

$$\mathbf{u} \sim \mathcal{N}(\mathbf{0}, \sigma_u^2 (D - \alpha A)^{-1}), \quad (4)$$

con A la adyacencia de los hexágonos, D la diagonal de grados y $\alpha \in (0,1)$ la dependencia espacial.

Panel anual. El modelo se ajusta sobre celda×año (11 205 filas de entrenamiento) y no celda×mes. El efecto de mes es común a todas las celdas y aportó casi nada sobre un promedio bien elegido ($M4 \approx M0r$); toda la estructura de interés vive en el nivel anual. Es el supuesto de separabilidad espacio-tiempo, apoyado por el Spearman de 0,83 entre años. Y NUTS sobre 161 mil observaciones con 2 300 parámetros tarda horas; sobre 11 mil, minutos.

6.2. Por qué CAR propio y no BYM2

La propuesta original era BYM2, $u_i = \sigma(\sqrt{1-\phi}v_i + \sqrt{\phi}s_i)$, con v independiente, s ICAR y ϕ interpretable como fracción espacial. Se intentó en las dos parametrizaciones y no se identificó:

Parametrización	Resultado	$\hat{R}$ de ϕ
No centrada	$\phi \rightarrow 0,0001$: la parte espacial desaparece	2,06
Centrada	$\sigma_s \rightarrow 13$, $\phi \rightarrow 0,9998$: la parte independiente desaparece	1,65

El motivo es de estructura, no de *tuning*. Con cinco años de conteos por celda, los datos fijan cada u_i casi por completo; la descomposición en “espacial” e “independiente” solo la sostienen los priors, y el muestreador cae en el modo degenerado más cercano. La estructura espacial *existe* —el Moran de la tasa por celda tras quitar la media municipal es 0,41—; lo que no existe es información para repartirla entre dos componentes. El CAR propio tiene una sola varianza y un solo α , es un prior propio y se identifica con datos fuertes.

6.3. Ajuste y diagnósticos

Cuatro cadenas NUTS (`nutpie`), 1 000 iteraciones de calentamiento y 2 000 muestras, en 4 minutos. **Cero divergencias**; sobre las 11 205 cantidades $\log \mu_{ia}$ —que son las identificadas— el $\hat{R}$ máximo es 1,005 y el ESS mínimo 2 441. β_0 y σ_m mezclan peor porque comparten información con el nivel medio de $\mathbf{u}$; no se usan solos en ninguna conclusión.

Parámetro	Media	IC 94 %	Lectura
α	0,85	[0,81; 0,88]	Dependencia espacial fuerte, neta del municipio
θ	12,2		Sobredispersión moderada a escala anual (5,5 a escala mensual)
σ_{rw}	0,29		El municipio típico cambia $\times 1,34$ al año
σ_u	2,38		Las celdas difieren en órdenes de magnitud dentro del municipio

Tabla 3: Hiperparámetros a posteriori. Con priors alternativos (α uniforme, σ_u el doble de ancho, θ con media 5 en vez de 20) los cuatro cambian en el tercer decimal: los datos dominan.




Figura 7: Efecto municipal $m_{j,a}$ a posteriori (mediana e intervalo del 90 %), en escala multiplicativa. Cada panel es un régimen de reporte; el intervalo es angosto en los municipios grandes y ancho en los pequeños.

6.4. El producto: el perfil espacial neto del municipio

u_i es cuánto más o menos riesgo tiene cada celda que el promedio de su municipio, estimado con la información de la celda y de sus vecinas. En las 618 celdas con cinco accidentes o menos en cinco años, el modelo encoge poco la estimación puntual (12 %) —el prior es ancho y deja hablar a los datos— pero **triplica la incertidumbre** respecto a las celdas con más de cien (0,75 contra 0,25 en escala log). Es el *shrinkage* proporcional a la ignorancia que motivó el enfoque: dos celdas con el mismo u_i y distinta incertidumbre no merecen la misma intervención.

Perfil espacial neto del municipio




Figura 8: u_i : riesgo relativo de cada celda respecto a su municipio. Es el primer mapa de la serie que no depende de cuánto reporta cada municipio: Guadalupe se compara con Guadalupe. Los corredores aparecen en rojo; las colonias interiores y los bordes, en azul.

6.5. Validación en 2024

El pronóstico es una simulación del modelo: para cada muestra posterior se toma el nivel municipal de 2023, se combina con u_i y se simula un conteo Binomial Negativo. Los *baselines* se recalculan a escala anual.

Modelo (hex×año)	MAE	CRPS	Cobertura 90 %	PAI 5 %
M0 media 2019–23	9,59	8,04	63 %	8,41
M0r media 2022–23	8,15	6,56	68 %	8,38
M4 NB2, historia reciente	8,18	6,93	90 %	8,38
M6 jerárquico CAR + municipio	8,19	6,17	87 %	8,42

Tabla 4: Validación en 2024 a escala anual. El jerárquico calibra el total al 1 % (70 815 predichos contra 71 249 observados).

El jerárquico **empata con M0r en MAE y lo supera en CRPS** (un 6 %). El empate en MAE dice que la mediana de ambos apunta al mismo sitio: lo predecible de 2024 es “el nivel reciente de cada municipio por el perfil estable de cada celda”, y un promedio bien elegido ya lo

captura. La ventaja en CRPS dice que la *distribución* es mejor: el intervalo del 90 % de M0r cubre el 68 % (es un Poisson que ignora la sobredispersión y el régimen); el del jerárquico cubre el 87 %, sin incluir siquiera el riesgo de cambio de régimen. Un intervalo que no cubre lo que dice cubrir no sirve para decidir.

Por qué el pronóstico es por persistencia. Pronosticar 2024 con una innovación t_3 más es lo que el modelo sugiere, pero $\mathbb{E}[e^T] = \infty$ para cualquier t de Student: ni la media predictiva ni el CRPS existen. Se verificó numéricamente: la suma de medias con innovación t dio 2,3 millones contra 71 mil observados, y cambia con la semilla. El pronóstico es por tanto *condicional a que ningún municipio cambie de régimen en 2024*, y sus intervalos son un piso de la incertidumbre real.

Se probó además una **deriva por municipio** (tendencia local) para capturar el crecimiento periférico: el modelo la encogió a cero ($\sigma_d = 0,07$), introdujo 46 divergencias y no mejoró el CRPS. Con cinco años y saltos de régimen, los datos no distinguen una tendencia de una racha de innovaciones. Se descartó.

7. Hallazgos transversales

7.1. El PAI no se movió en ningún notebook

Desde el análisis espacial hasta el jerárquico, el PAI al 5 % es 8,4. Es la conclusión más firme del proyecto: *el dónde lo decide el historial*, y ningún término temporal ni espacial lo cambia. El *shrinkage* reordena la cola de la distribución, no la cabeza, que es donde se decide. Para mover el PAI hacen falta covariables que varíen por celda y que el historial no contenga —exposición vial, uso de suelo, población— y eso es dato externo.

7.2. Lo que la base puede y no puede decir

- Puede decir dónde se concentra el reporte de accidentes, con qué estructura espacial y con qué persistencia. Eso es robusto a todo lo que se probó.
- Puede separar el nivel de reporte de cada municipio del perfil de cada celda, y estimar el segundo con la incertidumbre que corresponde.
- No puede distinguir un municipio donde bajó el riesgo de uno que dejó de capturar accidentes. $m_{j,a}$ es reporte, no siniestralidad. Quien use los resultados debe hacer esa distinción por fuera.
- No puede anticipar un cambio de régimen: que Santa Catarina empezara a reportar en 2022 o Guadalupe dejara de hacerlo en 2023 no está en los datos previos. Ese es el techo de medir siniestralidad con reportes administrativos, y hay que decirlo en cada entrega.

7.3. Decisiones metodológicas que conviene recordar

Decisión	Razón
Hexágonos, no AGEB	Fronteras de AGEB sobre avenidas; área constante; vecindad regular
$\log(1 + n)$ para Moran	La cola pesada dominaría un estadístico de productos cruzados; verificado con el crudo
FDR en todo mapa local	2 241 pruebas $\Rightarrow \sim 112$ falsos positivos; la corrección retira más de la mitad
NB2, no Poisson	Cameron–Trivedi $t = 59$; rootograma
Sin ZINB	Los ceros en exceso son municipios sin reportar, no un segundo proceso
Sin K de Ripley plana	Los eventos viven en la red; el nulo plano es imposible
Panel anual en el jerárquico	Separabilidad ($M4 \approx M0r$) y cómputo
CAR propio, no BYM2	BYM2 no se identifica con datos fuertes; documentado con los dos intentos
Innovaciones t_3	Los saltos municipales inflaban σ_{rw} al doble con normales
Pronóstico por persistencia	$\mathbb{E}[e^T] = \infty$; la media y el CRPS no existirían
Sin deriva municipal	Se encoge a cero, 46 divergencias, no mejora
Validación solo en 2024	Un jerárquico con 2 241 efectos ajusta el pasado casi perfecto; eso no es evidencia

8. Siguiendo pasos

En orden de costo–beneficio:

1. **Kilómetros de vialidad por celda** (OpenStreetMap o Red Nacional de Caminos). Es el mejor proxy de exposición disponible, entra como *offset*, y es la única vía identificada para mover el PAI. Convierte el modelo de “dónde hay accidentes” en “dónde hay más de los que el tráfico justifica”.
2. **Marco geoestadístico y Censo 2020** por AGEB, interpolados a hexágonos: población, densidad, marginación. Covariables de contexto.
3. **Modelo de severidad**, condicionado a que hubo accidente. Las variables consecuentes (tipo, vehículos, víctimas) son sus predictores naturales, y `TIPACCID↔gravedad` tiene la V de Cramér más alta de la base (0,49).
4. **Desagregación mensual** del pronóstico anual con el perfil estacional fijo, si hace falta operativamente.
5. Solo con la red vial ya descargada: K de Ripley y KDE restringidas a red, como complemento descriptivo.

A. Reproducibilidad

Todo el pipeline está en el repositorio, en Python 3.14 gestionado con `uv`. Los datos crudos (`data/raw/`) son las descargas del INEGI sin modificar; todo lo demás se regenera:

```
uv sync
uv run consolidar-atus --geo      # raw -> parquet nacional
uv run zona-atus --geo           # recorte a la ZMM
uv run limpiar-atus --geo        # columnas derivadas (nunca borra ni imputa)
```

Los notebooks son Quarto (`.qmd`) y cada uno tiene su PDF en `docs/`: `calidad_datos`, `analisis_multivariado`, `analisis_espacial`, `modelo_conteo`, `modelo_jerarquico`. La partición hexagonal vive en `geostats.espacial` y los tres últimos notebooks verifican que obtienen las mismas 2 241 celdas.

Software. `geopandas` 1.1, `libpysal/esda` para pesos y estadísticos espaciales, `statsmodels` 0.15 para los GLM, `PyMC` 6.3 con `nutpie` para el MCMC, `arviz` para diagnósticos. Semilla 42 en todo; los resultados del MCMC se reproducen al tercer decimal.

B. Supuestos del modelo jerárquico y su verificación

Supuesto	Verificación	Estado
Separabilidad espacio-tiempo	Spearman 0,83 entre 2019 y 2024	Apoyado
Régimen municipal como caminata aleatoria	Trayectorias a posteriori vs. series	Apoyado
Innovaciones de colas pesadas	σ_{rw} : 0,61 con normal, 0,29 con t_3	Apoyado
Grafo de vecindad correcto y conexo	Sin islas; simetría verificada	Verificado
Convergencia del MCMC	$\hat{R}$, ESS sobre $\log \mu$; 0 divergencias	Verificado
Priors no dictan el resultado	Reajuste con priors alternativos	Verificado
Subregistro estable por municipio	Series anuales por municipio	Violado
Sin cambio de régimen en 2024	No verificable desde el pasado	Declarado